



ME951 - Estatística e Probabilidade I

Parte 15

1S2024

Intervalo de Confiança

Eleições



[Vídeo: Pesquisa Eleitoral - JN - 20/08/2018](#)

Introdução

- Vimos que podemos utilizar uma estatística, como \bar{X} (\hat{p}), para estimar um parâmetro populacional, como a média populacional μ (proporção populacional p).
- Após coletarmos uma amostra aleatória calculamos \bar{x} , que é a nossa estimativa para μ . Chamamos esta estimativa de **estimativa pontual**.
- Uma estimativa pontual fornece apenas um único valor plausível para o parâmetro. E sabemos que ela pode ser diferente para cada amostra obtida: distribuição amostral.
- O ideal é que se reporte não só a estimativa, mas também a sua imprecisão.
- Duas maneiras: fornecer a estimativa juntamente com o seu **erro padrão** ou fornecer um intervalo de valores plausíveis para o parâmetro de interesse (**intervalo de confiança**).

Introdução

Suponha que queremos estimar o parâmetro populacional θ através de um intervalo.

Um intervalo de confiança (IC) para θ é sempre da forma:

estimativa \pm margem de erro

$\hat{\theta} \pm$ margem de erro

Sendo:

- $\hat{\theta}$ uma estimativa pontual de θ
- **margem de erro:** quantidade que depende da distribuição amostral do estimador pontual de θ , do grau de confiança pré-estabelecido e do erro padrão da estimativa

Intervalo de Confiança como Estimativa de p

Distribuição Amostral de \hat{p}

Temos uma população com proporção p e variância $p(1 - p)$ desconhecidos.

Retira-se uma amostra aleatória de tamanho n e calcula-se a proporção amostral \hat{p} para estimar o parâmetro populacional desconhecido p .

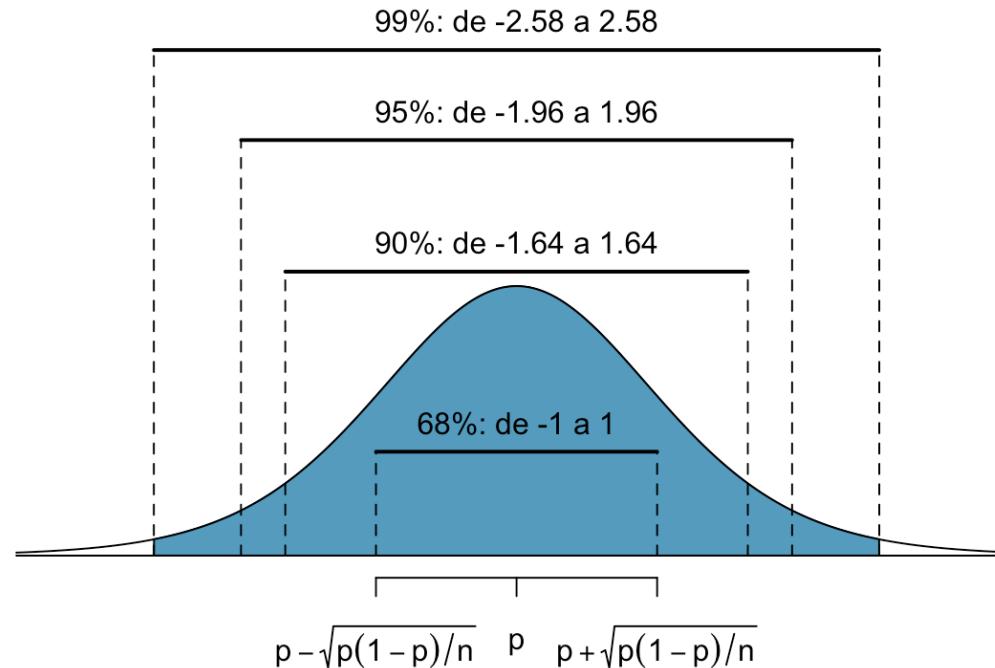
Temos as propriedades:

$$E(\hat{p}) = p \quad Var(\hat{p}) = \frac{p(1 - p)}{n} \quad EP(\hat{p}) = \sqrt{\frac{p(1 - p)}{n}}$$

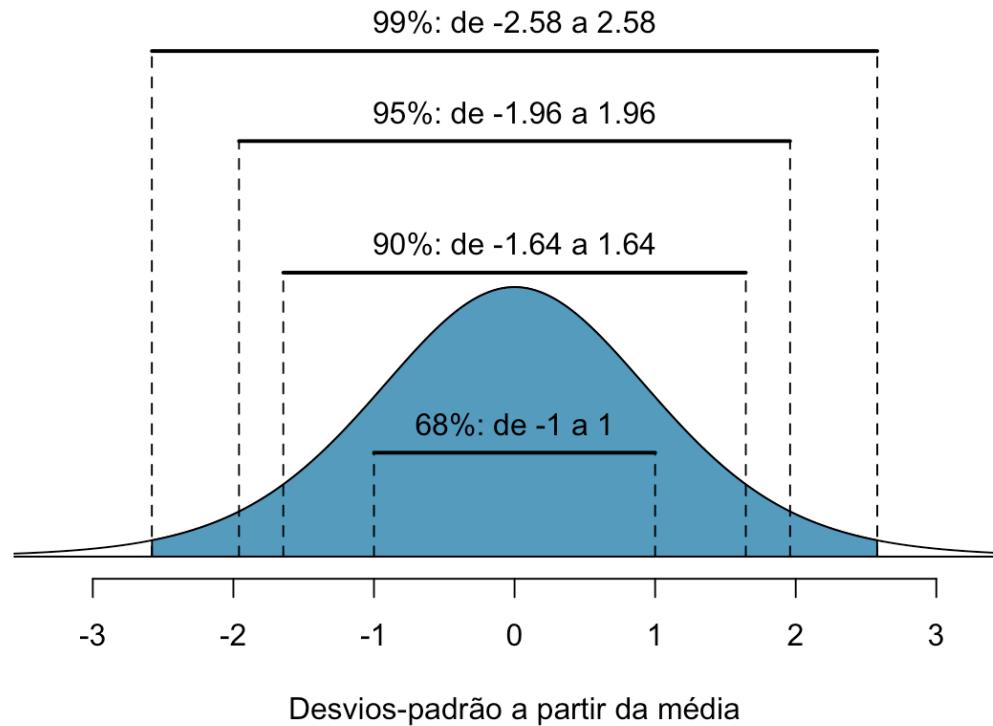
Pelo Teorema do Limite Central: a distribuição amostral de \hat{p} aproxima-se da seguinte **distribuição Normal** quando n for suficientemente grande:

$$\hat{p} \sim \mathcal{N}\left(p, \frac{p(1 - p)}{n}\right)$$

Distribuição Amostral de \hat{p}



$$Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0, 1)$$



Qual a probabilidade de que o estimador \hat{p} esteja distante do valor verdadeiro, p , em no máximo 1 erro-padrão?

$$P \left(|\hat{p} - p| \leq \sqrt{\frac{p(1-p)}{n}} \right)$$

$$\begin{aligned} P \left(|\hat{p} - p| \leq \sqrt{\frac{p(1-p)}{n}} \right) &= P \left(-\sqrt{\frac{p(1-p)}{n}} \leq \hat{p} - p \leq \sqrt{\frac{p(1-p)}{n}} \right) \\ &= P \left(-1 \leq \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \leq 1 \right) \\ &= P(-1 \leq Z \leq 1) \\ &= 0.68 \end{aligned}$$

Qual a probabilidade de que o estimador \hat{p} esteja distante do valor verdadeiro, p , em no máximo 1.96 erro-padrão?

$$P \left(|\hat{p} - p| \leq 1.96 \sqrt{\frac{p(1-p)}{n}} \right)$$

$$\begin{aligned} P \left(|\hat{p} - p| \leq 1.96 \sqrt{\frac{p(1-p)}{n}} \right) &= P \left(-1.96 \sqrt{\frac{p(1-p)}{n}} \leq \hat{p} - p \leq 1.96 \sqrt{\frac{p(1-p)}{n}} \right) \\ &= P \left(-1.96 \leq \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \leq 1.96 \right) \\ &= P(-1.96 \leq Z \leq 1.96) \\ &= 0.95 \end{aligned}$$

Intervalo de confiança de 95%

$$IC(p, 95\%) = \left[\hat{p} - 1.96 \sqrt{\frac{p(1-p)}{n}}; \hat{p} + 1.96 \sqrt{\frac{p(1-p)}{n}} \right]$$

Intervalo de confiança de 90%

$$IC(p, 90\%) = \left[\hat{p} - 1.64 \sqrt{\frac{p(1-p)}{n}}; \hat{p} + 1.64 \sqrt{\frac{p(1-p)}{n}} \right]$$

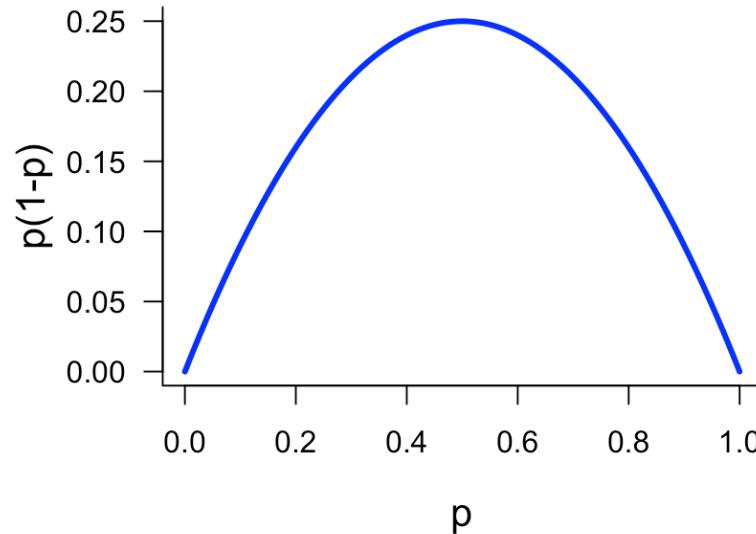
Intervalo de confiança de 99%

$$IC(p, 99\%) = \left[\hat{p} - 2.58 \sqrt{\frac{p(1-p)}{n}}; \hat{p} + 2.58 \sqrt{\frac{p(1-p)}{n}} \right]$$

Qual o problema?

Sabemos $p(1 - p)$?

Não sabemos $p(1 - p)$, porém:



A função $p(1 - p)$ atinge o valor máximo quando $p = 1/2$, ou seja,
 $p(1 - p) \leq \frac{1}{4}$.

Intervalo de confiança para p

Vimos que $p(1 - p) \leq \frac{1}{4}$, então erro padrão é maximizado por:

$$\sqrt{\frac{p(1-p)}{n}} \leq \sqrt{\frac{1}{4n}} \iff -\sqrt{\frac{p(1-p)}{n}} \geq -\sqrt{\frac{1}{4n}}$$

Portanto, $IC(p, 95\%) = \left[\hat{p} - 1.96\sqrt{\frac{1}{4n}}; \hat{p} + 1.96\sqrt{\frac{1}{4n}} \right]$.

Caso geral (conservador): Um IC de $100(1 - \alpha)\%$ para p é dado por

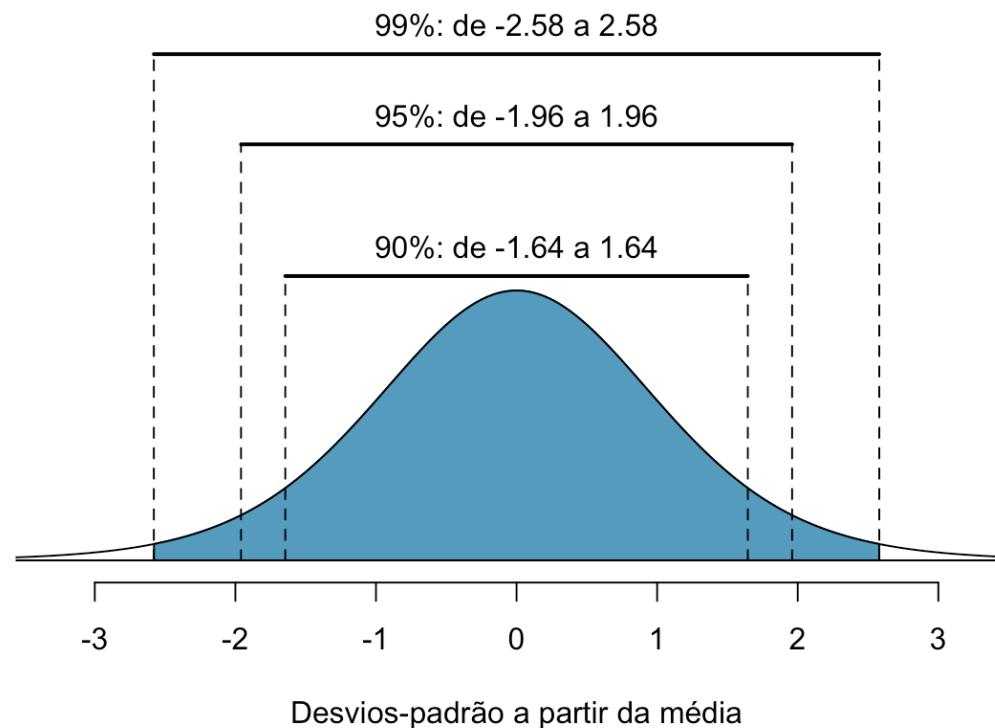
$$IC(p, 1 - \alpha) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{1}{4n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{1}{4n}} \right]$$

em que $z_{\alpha/2}$ é tal que:

$$P(-z_{\alpha/2} < Z < z_{\alpha/2}) = 1 - \alpha$$

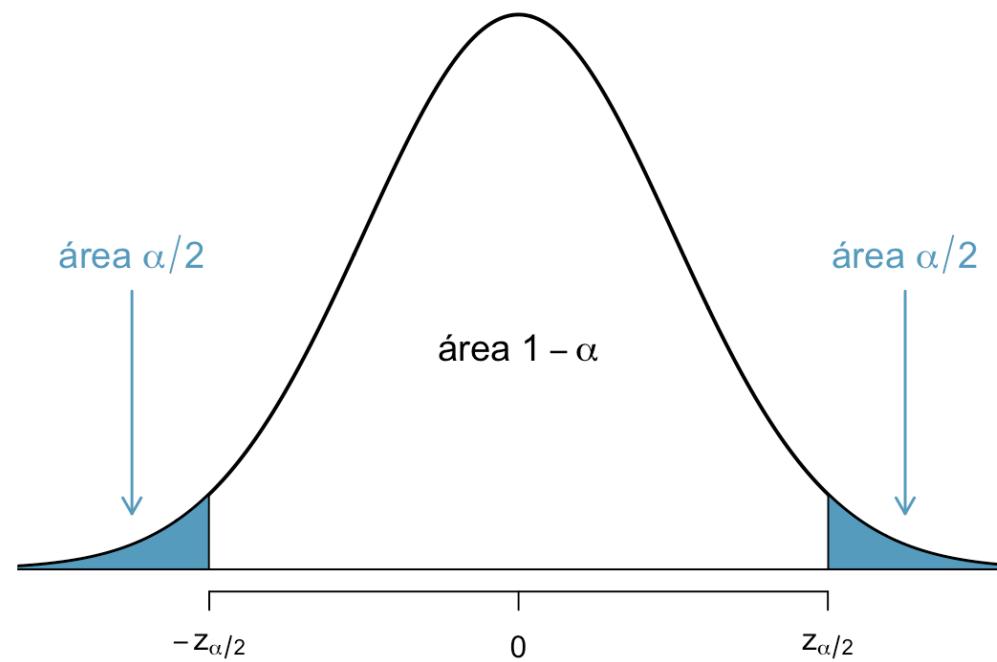
Como encontrar $z_{\alpha/2}$

$$P(|Z| \leq z_{\alpha/2}) = P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha$$



Como encontrar $z_{\alpha/2}$

$$P(|Z| \leq z_{\alpha/2}) = P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha$$



Como encontrar $z_{\alpha/2}$

Seja $Z \sim N(0, 1)$. O percentil $z_{\alpha/2}$ é tal que $1 - \alpha = P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2})$

Como determinar $z_{\alpha/2}$?

$$\begin{aligned}1 - \alpha &= P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = P(Z \leq z_{\alpha/2}) - P(Z \leq -z_{\alpha/2}) \\&= P(Z \leq z_{\alpha/2}) - P(Z \geq z_{\alpha/2}) \\&= P(Z \leq z_{\alpha/2}) - [1 - P(Z \leq z_{\alpha/2})] \\&= 2P(Z \leq z_{\alpha/2}) - 1 \\&= 2\Phi(z_{\alpha/2}) - 1\end{aligned}$$

$$\text{Portanto, } 1 - \frac{\alpha}{2} = \Phi(z_{\alpha/2}) \quad \Rightarrow \quad \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) = z_{\alpha/2}$$

Procure na tabela o valor de z tal que a probabilidade acumulada até o valor de z , isto é $P(Z \leq z) = \Phi(z)$, seja $1 - \alpha/2$.

Exemplo

Encontrar $z_{0.05}$ tal que $0.90 = P(-z_{0.05} \leq Z \leq z_{0.05})$.

Tabela I: Distribuição Normal Padrão Acumulada



Fornece $\Phi(z) = P(-\infty < Z \leq z)$, para todo z , de 0,01 em 0,01, desde $z = 0,00$ até $z = 3,59$
A distribuição de Z é Normal(0;1)

| z | 0,00 | 0,01 | 0,02 | 0,03 | 0,04 | 0,05 | 0,06 | 0,07 | 0,08 | 0,09 |
|------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
| 0,0 | 0,5000 | 0,5040 | 0,5080 | 0,5120 | 0,5160 | 0,5199 | 0,5239 | 0,5279 | 0,5319 | 0,5359 |
| 0,1 | 0,5398 | 0,5438 | 0,5478 | 0,5517 | 0,5557 | 0,5596 | 0,5636 | 0,5675 | 0,5714 | 0,5753 |
| 0,2 | 0,5793 | 0,5832 | 0,5871 | 0,5910 | 0,5948 | 0,5987 | 0,6026 | 0,6064 | 0,6103 | 0,6141 |
| 0,3 | 0,6179 | 0,6217 | 0,6255 | 0,6293 | 0,6331 | 0,6368 | 0,6406 | 0,6443 | 0,6480 | 0,6517 |
| 0,4 | 0,6554 | 0,6591 | 0,6628 | 0,6664 | 0,6700 | 0,6736 | 0,6772 | 0,6808 | 0,6844 | 0,6879 |
| 0,5 | 0,6915 | 0,6950 | 0,6985 | 0,7019 | 0,7054 | 0,7088 | 0,7123 | 0,7157 | 0,7190 | 0,7224 |
| 0,6 | 0,7257 | 0,7291 | 0,7324 | 0,7357 | 0,7389 | 0,7422 | 0,7454 | 0,7486 | 0,7517 | 0,7549 |
| 0,7 | 0,7580 | 0,7611 | 0,7642 | 0,7673 | 0,7704 | 0,7734 | 0,7764 | 0,7794 | 0,7823 | 0,7852 |
| 0,8 | 0,7881 | 0,7910 | 0,7939 | 0,7967 | 0,7995 | 0,8023 | 0,8051 | 0,8078 | 0,8106 | 0,8133 |
| 0,9 | 0,8159 | 0,8186 | 0,8212 | 0,8238 | 0,8264 | 0,8289 | 0,8315 | 0,8340 | 0,8365 | 0,8389 |
| 1,0 | 0,8413 | 0,8438 | 0,8461 | 0,8485 | 0,8508 | 0,8531 | 0,8554 | 0,8577 | 0,8599 | 0,8621 |
| 1,1 | 0,8643 | 0,8665 | 0,8686 | 0,8708 | 0,8729 | 0,8749 | 0,8770 | 0,8790 | 0,8810 | 0,8830 |
| 1,2 | 0,8849 | 0,8869 | 0,8888 | 0,8907 | 0,8925 | 0,8944 | 0,8962 | 0,8980 | 0,8997 | 0,9015 |
| 1,3 | 0,9032 | 0,9049 | 0,9066 | 0,9082 | 0,9099 | 0,9115 | 0,9131 | 0,9147 | 0,9162 | 0,9177 |
| 1,4 | 0,9192 | 0,9207 | 0,9222 | 0,9236 | 0,9251 | 0,9265 | 0,9279 | 0,9292 | 0,9306 | 0,9319 |
| 1,5 | 0,9332 | 0,9345 | 0,9357 | 0,9370 | 0,9382 | 0,9394 | 0,9406 | 0,9418 | 0,9429 | 0,9441 |
| 1,6 | 0,9452 | 0,9463 | 0,9474 | 0,9484 | 0,9495 | 0,9505 | 0,9515 | 0,9525 | 0,9535 | 0,9545 |
| 1,7 | 0,9554 | 0,9564 | 0,9573 | 0,9582 | 0,9591 | 0,9599 | 0,9608 | 0,9616 | 0,9625 | 0,9633 |
| 1,8 | 0,9641 | 0,9649 | 0,9656 | 0,9664 | 0,9671 | 0,9678 | 0,9686 | 0,9693 | 0,9699 | 0,9706 |
| 1,9 | 0,9713 | 0,9719 | 0,9726 | 0,9732 | 0,9738 | 0,9744 | 0,9750 | 0,9756 | 0,9761 | 0,9767 |
| 2,0 | 0,9772 | 0,9778 | 0,9783 | 0,9788 | 0,9793 | 0,9798 | 0,9803 | 0,9808 | 0,9812 | 0,9817 |

Pela tabela, $z_{0.05} = 1.64$.

Exemplo

Numa pesquisa de mercado, $n = 400$ pessoas foram entrevistadas (usando amostra aleatória) sobre preferência do produto da marca A, e 60% destas pessoas preferiam a marca A.

Encontre um IC de 95% para a proporção de pessoas que preferem a marca A.

Pelo resultado da pesquisa, $\hat{p} = 0.6$.

Logo, o IC com grau de confiança $1 - \alpha = 0.95$ é dado por:

$$\begin{aligned} IC(p, 0.95) &= \left[0.6 - 1.96 \frac{1}{\sqrt{1600}}; 0.6 + 1.96 \frac{1}{\sqrt{1600}} \right] \\ &= [0.6 - 0.049; 0.6 + 0.049] \\ &= [0.551; 0.649] \end{aligned}$$

Exemplo

Suponha que em $n = 400$ entrevistados, tivéssemos obtido $k = 80$ respostas de pessoas que preferem a marca A.

Vamos obter um intervalo de confiança para p , com grau de confiança de 90%:

- $\hat{p} = \frac{80}{400} = 0.2$
- $1 - \alpha = 0.90$. Então $\alpha/2 = 0.05 \rightarrow z_{\alpha/2} = z_{0.05} = 1.64$

$$\begin{aligned} IC_1(p, 0.90) &= \left[0.2 - 1.64 \frac{1}{\sqrt{1600}}; 0.2 + 1.64 \frac{1}{\sqrt{1600}} \right] \\ &= [0.2 - 0.041; 0.2 + 0.041] \\ &= [0.159; 0.241] \end{aligned}$$

Exemplo

E se usarmos a estimativa \hat{p} para também estimar o erro padrão $\sqrt{\frac{p(1-p)}{n}}$?

Podemos construir o seguinte IC de $100(1 - \alpha)\%$

$$IC(p, 1 - \alpha) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right]$$

Para os dados do exemplo anterior,

$$\begin{aligned} IC_2(p, 0.90) &= \left[0.2 - 1.64 \sqrt{\frac{(0.2)(0.8)}{400}}; 0.2 + 1.64 \sqrt{\frac{(0.2)(0.8)}{400}} \right] \\ &= [0.2 - 0.033; 0.2 + 0.033] \\ &= [0.167; 0.233] \end{aligned}$$

Exemplo

O intervalo que utiliza \hat{p} também para estimar o erro padrão tem menor margem de erro e, portanto, menor amplitude do que o intervalo que utiliza o fato de $p(1 - p) \leq \frac{1}{4}$. Por isso esse último é chamado de **conservador**.

Veja as amplitudes dos IC 's que encontramos no exemplo anterior:

- $IC_1(p, 0.90) = [0.159; 0.241] \Rightarrow A_1 = 0.241 - 0.159 = 0.082$
- $IC_2(p, 0.90) = [0.167; 0.233] \Rightarrow A_2 = 0.233 - 0.167 = 0.066$

A amplitude é o dobro da margem de erro.

Intervalo de Confiança para p

Em resumo, os intervalos de $100(1 - \alpha)\%$ de confiança para p podem então ser de duas formas:

1. Método Conservador

$$IC_1(p, 1 - \alpha) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{1}{4n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{1}{4n}} \right]$$

2. Usando \hat{p} para estimar o erro padrão

$$IC_2(p, 1 - \alpha) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right]$$

Veja que nos dois casos, os IC 's são da forma $\hat{p} \pm$ margem de erro

Exemplo: Universitários Não Fumantes

De uma amostra aleatória de 100 alunos de uma universidade, 82 afirmaram ser não fumantes.

Construa um intervalo de confiança de 99% para a proporção de não fumantes entre todos os alunos da universidade.

$$\hat{p} = 0.82, n = 100, \alpha = 0.01, \text{ e } z_{0.005} = 2.58$$

$$\begin{aligned} IC_1(p, 0.99) &= \left[\hat{p} - z_{0.005} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}; \hat{p} + z_{0.005} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right] \\ &= \left[0.82 - 2.58 \sqrt{\frac{(0.82)(0.18)}{100}}; 0.82 + 2.58 \sqrt{\frac{(0.82)(0.18)}{100}} \right] \\ &= [0.82 - 0.10; 0.82 + 0.10] \\ &= [0.72; 0.92] \end{aligned}$$

Exemplo: Universitários Não Fumantes

Podemos também calcular o IC de 99% pelo método conservador:

$$\begin{aligned} IC_2(p, 0.99) &= \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{1}{4n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{1}{4n}} \right] \\ &= \left[0.82 - 2.58 \sqrt{\frac{1}{400}}; 0.82 + 2.58 \sqrt{\frac{1}{400}} \right] \\ &= [0.82 - 0.13; 0.82 + 0.13] \\ &= [0.69; 0.95] \end{aligned}$$

Interpretação: Com um grau de confiança de 99%, estimamos que a proporção de não fumantes entre os alunos está entre 72% e 92% (resultado do slide anterior).

E pelo método conservador, com um grau de confiança de 99%, estimamos que a proporção de não fumantes entre os alunos está entre 69% e 95%.

Exemplo: A esposa deve sacrificar a carreira?

Pesquisa do [GSS](#). Você concorda ou não com a seguinte frase: “é mais importante para um esposa ajudar a carreira do marido do que ter uma carreira própria.”

A última vez que esta pergunta foi incluída no [GSS](#) foi em 1998 onde 1823 pessoas responderam e 19% concordaram.

- Calcule e interprete o IC de 95% para a proporção na população que concorda com a frase.
- Encontre e interprete a margem de erro do IC de 95%.

Exemplo: A esposa deve sacrificar a carreira?

Calcule e interprete o IC de 95% para a proporção na população que concorda com a frase.

$$\hat{p} = 0.19, n = 1823, \alpha = 0.05, \text{ e } z_{0.025} = 1.96$$

Então,

$$\begin{aligned} IC(p, 0.95) &= \left[\hat{p} - 1.96 \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}; \hat{p} + 1.96 \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right] \\ &= \left[0.19 - 1.96 \sqrt{\frac{0.19(1 - 0.19)}{1823}}; 0.19 + 1.96 \sqrt{\frac{0.19(1 - 0.19)}{1823}} \right] \\ &= [0.19 - 0.02; 0.19 + 0.02] \\ &= [0.17; 0.21] \end{aligned}$$

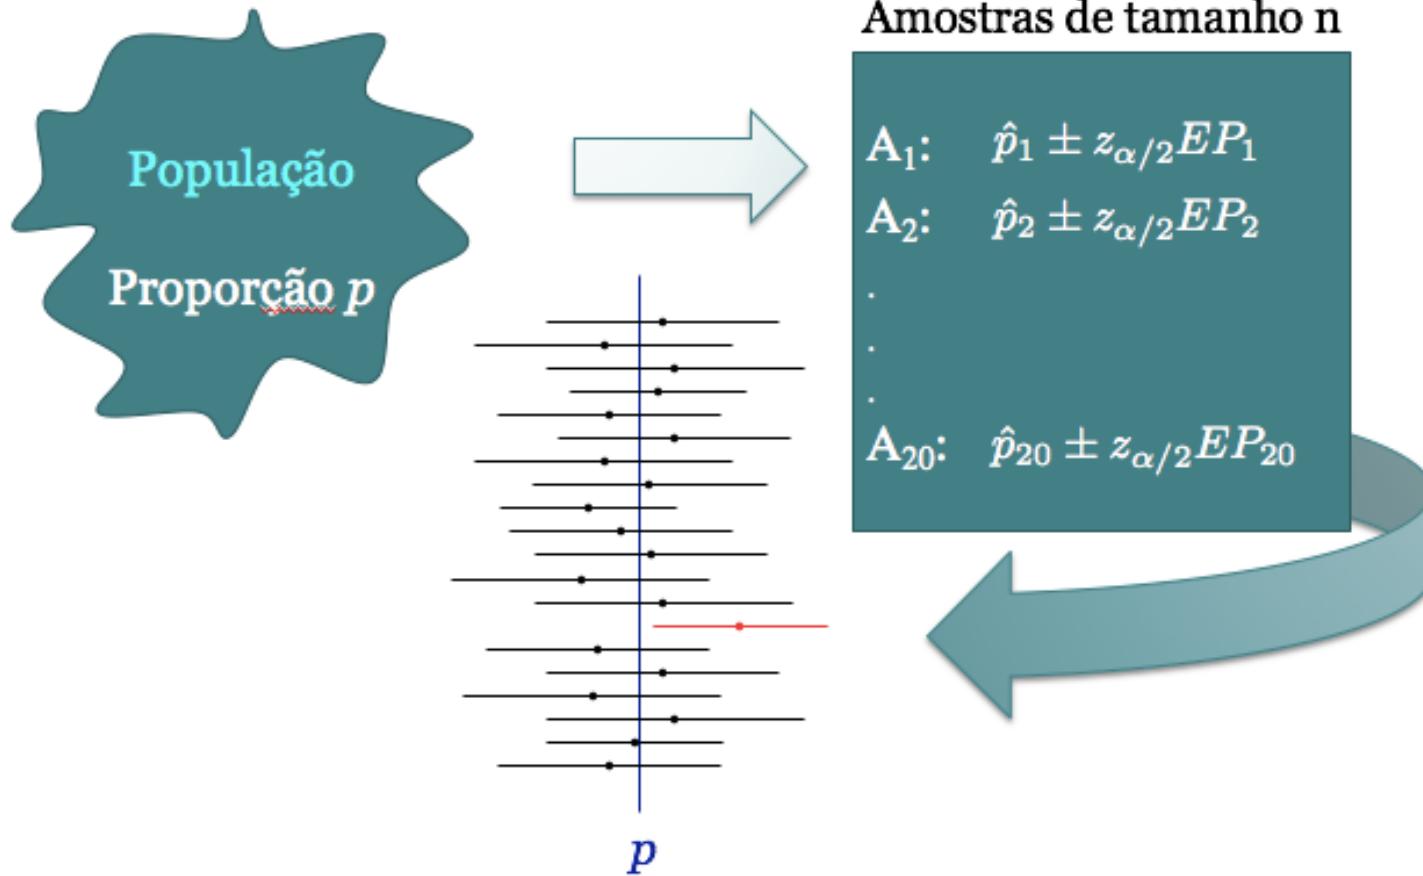
Interpretação do Intervalo de Confiança

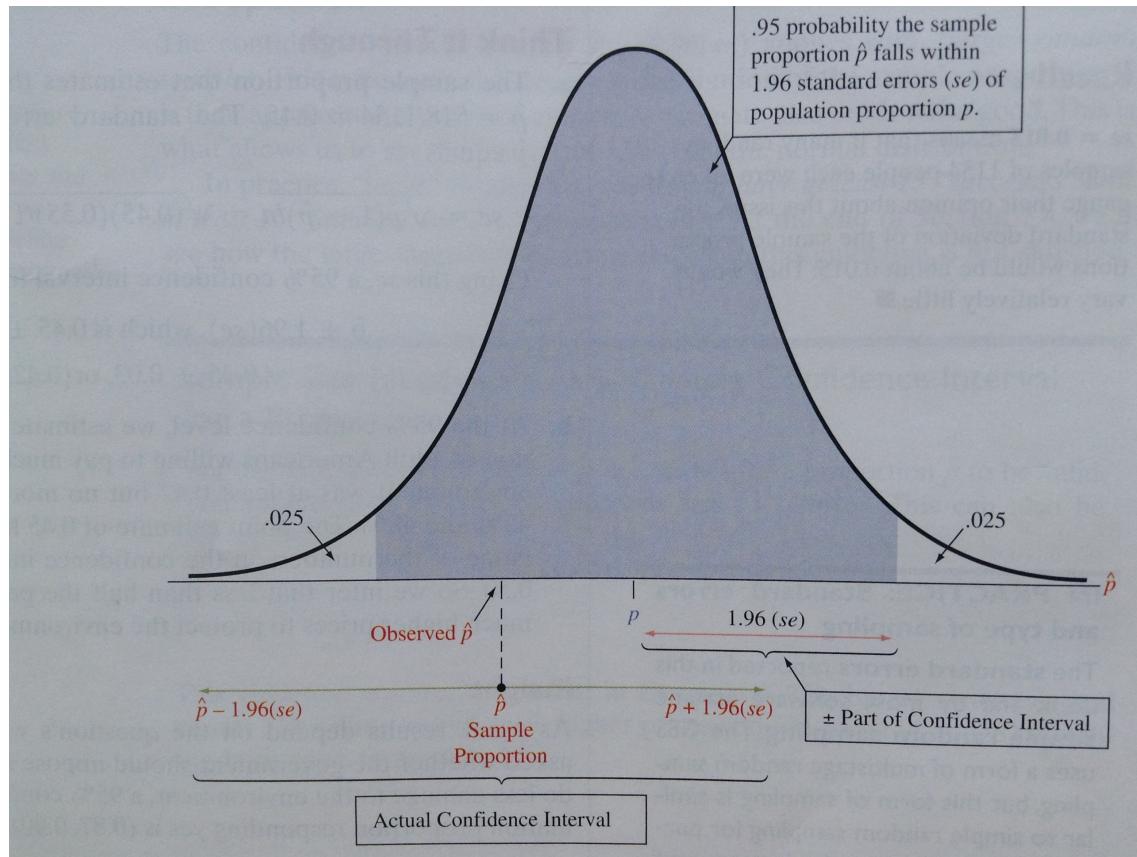
Interpretação: Se várias amostras aleatórias forem retiradas da população e calcularmos um IC de 95% para cada amostra, cerca de 95% desses intervalos irão conter a verdadeira proporção na população, p .

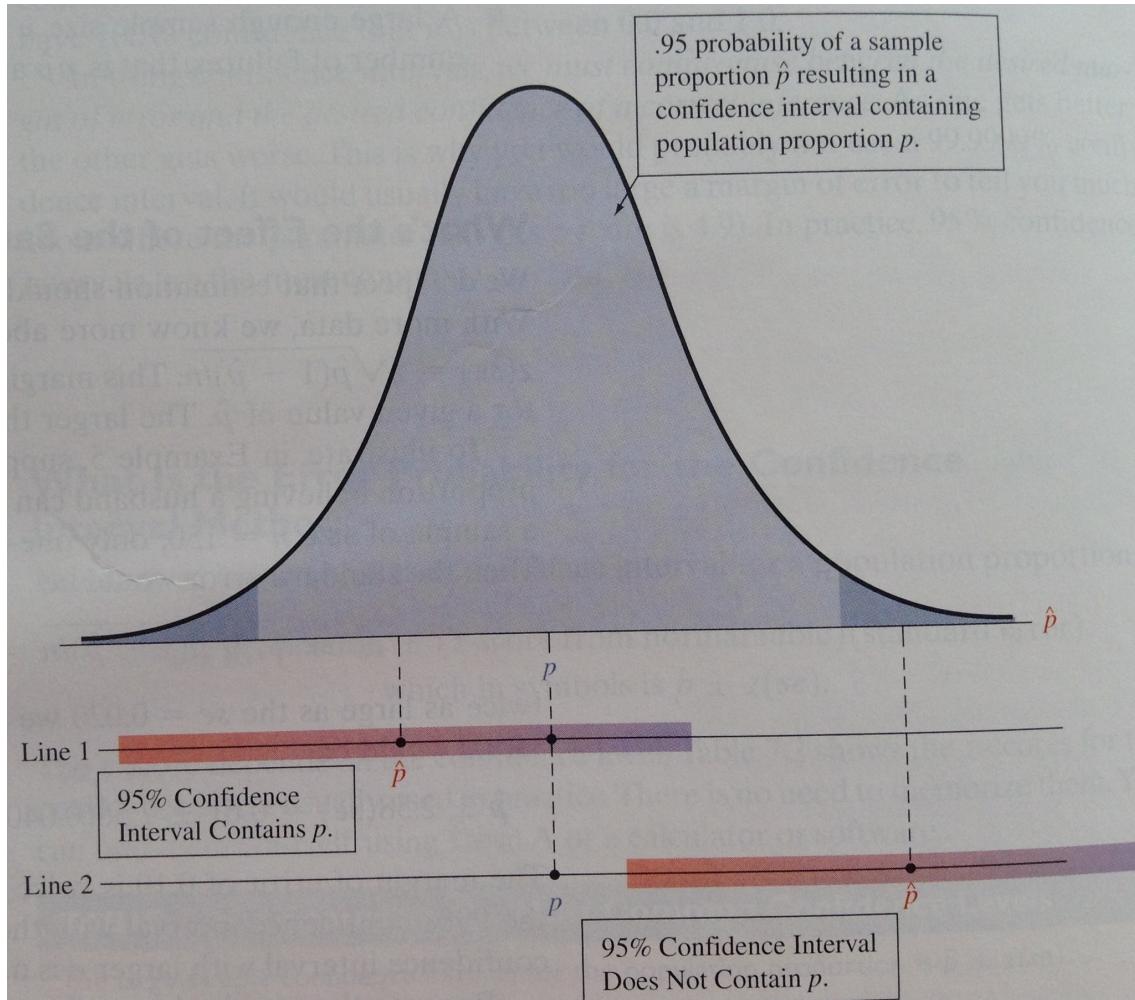
INCORRETO: Dizer que “a probabilidade de que p esteja dentro do intervalo é 95%”

Por que incorreto? p é uma constante, não é variável aleatória. Ou p está no intervalo calculado ou não está.

Interpretação do Intervalo de Confiança







Exemplo (continuação)

Um IC de 95% para p é: $[0.17; 0.21]$

A margem de erro (metade do comprimento do IC) é:

$$ME = 1.96 \sqrt{\frac{0.19(1 - 0.19)}{1823}} = 0.02$$

$$P(|\hat{p} - p| < 0.02) = 0.95$$

Interpretação: Com probabilidade 0.95, o erro ao usar a proporção amostral para estimar a proporção populacional não excede 0.02.

Curiosidade: em 1977 a pergunta foi feita pela primeira vez no [GSS](#). $\hat{p} = 0.57$ e IC de 95% foi $[0.55; 0.59]$.

Exemplo: Proteção ao Meio Ambiente

Na teoria, muita gente se considera “*eco-friendly*”. Mas e na prática?

Pergunta: Você pagaria mais para um produto em favor ao meio ambiente?

Em 2000, [GSS](#) perguntou: “Você estaria disposto a pagar mais pela gasolina para proteger o ambiente?”

Entre $n = 1154$ participantes, 518 responderam que sim.

- Encontre IC 95% para a proporção da população que concorda.
- Interprete.

Exemplo (continuação)

Estimativa: $\hat{p} = 518/1154 = 0.45$

erro padrão (desvio padrão da estimativa): $EP(\hat{p}) = \sqrt{\frac{(0.45)(1-0.45)}{1154}} = 0.015$

Margem de erro: $1.96EP(\hat{p}) = 0.03$

$$\begin{aligned} IC(p, 0.95) &= \left[0.45 - 1.96\sqrt{\frac{(0.45)(0.55)}{1154}}; 0.45 + 1.96\sqrt{\frac{(0.45)(0.55)}{1154}} \right] \\ &= [0.45 - 0.03; 0.45 + 0.03] \\ &= [0.42; 0.48] \end{aligned}$$

Interpretação: Com grau de confiança de 95%, estimamos que a proporção populacional que concorda em pagar mais está entre 0.42 e 0.48. A estimativa pontual, 0.45, tem margem de erro de 3%.

Exemplo (continuação)

E se estivéssemos interessados na proporção que não pagaria mais?

Estimativa: $\hat{p} = 1 - 518/1154 = 0.55$

erro padrão (desvio padrão da estimativa): $EP(\hat{p}) = \sqrt{\frac{(0.55)(1-0.55)}{1154}} = 0.015$

Margem de erro: $1.96EP(\hat{p}) = 0.03$

$$\begin{aligned} IC(p, 0.95) &= \left[0.55 - 1.96\sqrt{\frac{(0.55)(0.45)}{1154}}; 0.55 + 1.96\sqrt{\frac{(0.55)(0.45)}{1154}} \right] \\ &= [0.55 - 0.03; 0.55 + 0.03] \\ &= [0.52; 0.58] \end{aligned}$$

Interpretação: Com grau de confiança de 95%, estimamos que a proporção populacional que não pagaria mais está entre 0.52 e 0.58. A estimativa pontual, 0.55, tem margem de erro de 3%.

Exemplo: Esposa vs Marido

Pergunta: Se a esposa quer ter um filho, mas o marido não, é justo que ele se recuse a ter um filho?

GSS: 598 responderam, 366 acham justo. Encontre um *IC* de 99%.

Estimativa: $\hat{p} = 366/598 = 0.61$

erro padrão (desvio padrão da estimativa): $EP(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = 0.02$

Margem de erro: $2.58EP(\hat{p}) = 0.05$

$$IC(p, 0.99) = [0.61 - 0.05 ; 0.61 + 0.05] = [0.56 ; 0.66]$$

Com grau de confiança igual a 99%, estimamos que a proporção populacional que concorda está entre 0.56 e 0.66. A estimativa pontual, 0.61, tem margem de erro de 5%.

Exemplo (continuação)

E o IC de 95%?

Margem de erro: $1.96EP(\hat{p}) = 1.96 \times 0.02 = 0.04$

$$\begin{aligned} IC(p, 0.95) &= [0.61 - 0.04 ; 0.61 + 0.04] \\ &= [0.57 ; 0.65] \end{aligned}$$

Com grau de confiança igual a 95%, estimamos que a proporção populacional que concorda está entre 0.57 e 0.65. A estimativa pontual, 0.61, tem margem de erro de 4%.

Com maior grau de confiança, temos uma margem de erro um pouco maior.

Tamanho da amostra para estimar p

Exemplo: Datafolha

A Datafolha quer fazer uma pesquisa de boca-de-urna para predizer o resultado de uma eleição com apenas dois candidatos.

Seleciona então uma a.a. de eleitores e pergunta em quem cada um votou. Para esta pesquisa, o Datafolha quer uma margem de erro de 4%. Qual o tamanho de amostra necessário?

- O grau de confiança é 95% e $IC(p, 0.95) = \hat{p} \pm 1.96 \times EP(\hat{p})$
- Erro padrão de \hat{p} é $EP(\hat{p}) = \sqrt{p(1 - p)/n}$
- Margem de erro: $1.96 \times EP(\hat{p}) = 1.96\sqrt{p(1 - p)/n}$
- Margem de erro desejada é 0.04. Então, o tamanho amostral necessário n é:

$$1.96\sqrt{\frac{p(1 - p)}{n}} = 0.04 \quad \Rightarrow \quad n = \frac{1.96^2 p(1 - p)}{0.04^2}$$

Exemplo: Datafolha

Problema é que não conhecemos p .

Assim como para encontrar os IC 's, podemos usar o método conservador ou então usar informações obtidas em pesquisas anteriores (caso existam).

Método Conservador:

- Lembre que $p(1 - p)/n$ é a variância da estimativa \hat{p} e já vimos anteriormente que $p(1 - p) \leq 1/4$.
- Então,

$$n = \frac{1.96^2 \times (1/4)}{0.04^2} = 600$$

Exemplo: Datafolha

Outra alternativa

- O Datafolha fez uma pesquisa na semana passada e o resultado foi 58% votariam no candidato *A* e 42% no *B*.
- Podemos usar então estas estimativas:

$$n = \frac{1.96^2 \hat{p}(1 - \hat{p})}{0.04^2} = \frac{1.96^2(0.58)(0.42)}{0.04^2} = 585$$

- Uma a.a. de tamanho 585 deverá resultar numa margem de erro de 4% para um IC de 95% para a proporção da população que vota no candidato *A*.

Exemplo: Campeonato Brasileiro

Uma firma de propaganda está interessada em estimar a proporção de domicílios que estão assistindo a final do campeonato brasileiro de futebol.

Para isso, está planejando ligar para os domicílios selecionados aleatoriamente a partir de uma lista.

Qual o tamanho da amostra necessário se a firma quer 90% de confiança de que a estimativa obtida tenha uma margem de erro igual a 0.02?

Exemplo: Campeonato Brasileiro

Método conservador: $IC(p, 1 - \alpha) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{1}{4n}} ; \hat{p} + z_{\alpha/2} \sqrt{\frac{1}{4n}} \right]$

Margem de erro 0.02: $z_{\alpha/2} \sqrt{\frac{1}{4n}} = 0.02$

Como eles querem 90% de confiança, $\alpha = 0.10$ e $z_{0.05} = 1.645$

$$1.645 \sqrt{1/4n} = 0.02 \iff 1/4n = (0.02/1.645)^2 \Rightarrow n = 1691.3$$

Tamanho amostral: 1692.

Em geral, para uma margem de erro m :

$$n = \left(\frac{z_{\alpha/2}}{2m} \right)^2$$

Exemplo: Mulheres em uma Escola

Suponha que $p = 30\%$ dos estudantes de uma escola sejam mulheres.

Coletamos uma amostra aleatória simples de $n = 10$ estudantes e calculamos a proporção de mulheres na amostra, ou seja, \hat{p} .

Qual a probabilidade de que \hat{p} difira de p em menos de 0.01? E se $n = 50$?

Adaptado de: Morettin & Bussab, Estatística Básica 5^a edição, pág 276.

Solução: Temos que a probabilidade que desejamos encontrar é dada por

$$P(|\hat{p} - p| < 0.01) = P(-0.01 < \hat{p} - p < 0.01)$$

onde p é o valor verdadeiro da proporção de mulheres, e \hat{p} a proporção observada na amostra.

Exemplo: Mulheres em uma Escola

Seja X_i a v.a. indicando se a pessoa i é mulher, ou seja, $X_i \sim \text{Bernoulli}(0.3)$.

Então sabemos que $\mathbb{E}(X_i) = p = 0.3$ e $Var(X_i) = p(1 - p) = 0.21$.

Coletamos uma amostra de tamanho n : X_1, \dots, X_n . Calculamos a proporção de mulheres na amostra:

$$\bar{X}_n = \frac{S_n}{n} = \frac{X_1 + \dots + X_n}{n}$$

Sabemos que $\mathbb{E}(\bar{X}_n) = \mathbb{E}(X_i) = p = 0.3$ e $Var(\bar{X}_n) = \frac{p(1-p)}{n} = \frac{0.21}{10} = 0.021$.

Pelo TCL, quando n é grande,

$$\bar{X}_n = \hat{p} \sim N(p, p(1 - p)/n) = N(0.3, 0.021)$$

Exemplo: Mulheres em uma Escola

A probabilidade que queremos calcular é:

$$\begin{aligned} P(|\hat{p} - p| < 0.01) &= P(-0.01 < \hat{p} - p < 0.01) \\ P\left(-\frac{0.01}{\sqrt{Var(\hat{p})}} < \frac{\hat{p} - p}{\sqrt{Var(\hat{p})}} < \frac{0.01}{\sqrt{Var(\hat{p})}}\right) \\ P\left(\frac{-0.01}{\sqrt{0.021}} < Z < \frac{0.01}{\sqrt{0.021}}\right) &= P(-0.07 < Z < 0.07) = 0.056. \end{aligned}$$

Mas $n = 10$ é grande o suficiente?

Podemos comparar essa probabilidade com o resultado exato!

Exemplo: Mulheres em uma Escola

Não sabemos a distribuição de \hat{p} , mas sabemos que X_i são v.a. independentes e identicamente distribuidas Bernoulli(0.3).

Portanto, $\sum_{i=1}^n X_i \sim Bin(10, 0.3)$ e $\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$.

Então,

$$\begin{aligned} P(|\hat{p} - p| < 0.01) &= P(-0.01 < \hat{p} - p < 0.01) \\ &= P(-0.01n < n\hat{p} - np < 0.01n) \\ &= P\left(-0.1 < \sum_{i=1}^n X_i - 3 < 0.1\right) \\ &= P\left(2.9 < \sum_{i=1}^n X_i < 3.1\right) \end{aligned}$$

Exemplo: Mulheres em uma Escola

Como $\sum X_i$ assume somente valores inteiros, temos que

$$\begin{aligned} P(|\hat{p} - p| < 0.01) &= P\left(2.9 < \sum_{i=1}^n X_i < 3.1\right) \\ &= P\left(\sum_{i=1}^n X_i = 3\right) \\ &= \binom{10}{3}(0.3)^3(0.7)^7 = 0.267. \end{aligned}$$

Temos uma probabilidade que é 5 vezes maior que a aproximação.

Exemplo: Mulheres em uma Escola

Considere agora $n = 50$. Nesse caso, a variância é $\frac{p(1-p)}{n} = 0.0042$ e, portanto, a probabilidade aproximada é:

$$\begin{aligned} P(|\hat{p} - p| < 0.01) &\approx P\left(|Z| < \frac{0.01}{\sqrt{0.0042}}\right) = P(-0.154 < Z < 0.154) \\ &= 0.12239 \end{aligned}$$

A probabilidade exata agora é dada por:

$$\begin{aligned} P(|\hat{p} - p| < 0.01) &= P\left(\left|\sum_{i=1}^n X_i - 50(0.3)\right| < 0.5\right) \\ &= P\left(\sum_{i=1}^n X_i = 15\right) = \binom{50}{15}(0.3)^{15}(0.7)^{35} = 0.12235. \end{aligned}$$

A diferença agora é muito menor e, à medida que $n \rightarrow \infty$ ela tende a 0, pelo TCL. A aproximação só é válida para grandes tamanhos de amostra.

Exercício: Intervalo de Confiança para proporções

Suponha que estejamos interessados em estimar a porcentagem de consumidores de um certo produto. Se a amostra de tamanho 300 forneceu 100 indivíduos que consomem o dado produto, determine:

1. O intervalo de 95% de confiança para p . Interprete o resultado.
2. O tamanho da amostra para que o erro da estimativa não exceda 0.02 unidades com probabilidade de 95%. Interprete o resultado.

Fonte: Morettin & Bussab, Estatística Básica 5^a edição, pág 309.

Intervalo de Confiança para proporções

1. O intervalo de confiança de 95% é dado por:

$$\text{IC}(p; 0.95) = 0.333 \pm 1.96 \sqrt{\frac{0.333 \times 0.667}{300}} = 0.333 \pm 0.053$$

Ou simplesmente (0.280; 0.387).

Interpretação: Se pudéssemos construir um grande número de intervalos aleatórios para p , todos baseados em amostras de tamanho n, 95% deles conteriam o parâmetro p .

Intervalo de Confiança para proporções

- 1.
2. Utilizando a estimativa da amostra observada ($\hat{p} = 0.333$), temos que n é dado por

$$n = \left(\frac{1.96}{0.02} \right)^2 \times 0.333 \times 0.667 \cong 2134.$$

Contudo, frequentemente devemos determinar o tamanho da amostra antes de realizar qualquer experimento, isto é, sem nenhuma informação prévia de p . Se esse for o caso, devemos considerar o caso em que a variância da amostra é a pior possível.

Intervalo de Confiança para proporções

- 1.
2. Utilizando o valor máximo de $p(1 - p)$, isto é, $1/4$, obtemos

$$n = \left(\frac{1.96}{0.02} \right)^2 \times \frac{1}{4} \cong 2401$$

Interpretação: Utilizando o tamanho amostral encontrado, teremos uma probabilidade de 95% de que a proporção amostral não difira do verdadeiro valor de p em menos que 2%.

Note que a prática de obter amostras pequenas para examinar p , e aí determinar o tamanho amostral sem utilizar o “pior caso”, é no que consiste a idéia de **amostras piloto**.

Leituras

- [Ross](#): capítulo 8.
- [OpenIntro](#): seção 4.2.
- Magalhães: seção 7.4.

Slides produzidos pelos professores:

- Samara Kiihl
- Tatiana Benaglia
- Larissa Matos
- Benilton Carvalho

