ME720 - Modelos Lineares Generalizados

Profa. Larissa Avila Matos

Resolução Atividade

Questão 1

```
ajustePoisson <-function(y,X,init,eps=1e-6,maxiter=50){</pre>
  beta <- init
 n < -dim(X)[1]
 p=length(t(beta))
  out <- matrix(NA, nrow=maxiter+1,ncol=p)</pre>
  out[1,] <- t(init)
  i <- 1
  continue <- T
  while (continue) {
    i <- i+1
    beta.o <- beta
    W<-diag(n)
    diag(W)<-exp(X%*%beta.o)</pre>
    mu<-exp(X%*%beta.o)</pre>
    beta <- beta.o + solve(t(X)%*%W%*%X)%*%t(X)%*%(y-mu)
      if(sum(is.na(beta))>0){stop("NA nas estimativas")}
    out[i,] <- t(beta)</pre>
    continue <- (abs(beta-beta.o) > eps) && (i <= maxiter)</pre>
  if (i > maxiter) {
    warning("Máximo número de iterações atingido")
 }
  out <- out[!is.na(out[,1]),]
  est=out[i,]
  v.ajustado <- exp(X%*%est)
  preditor.linear=X%*%est
  desvio \leftarrow sum(2*(y*(ifelse(y==0,0,log(y))-log(v.ajustado))-y+v.ajustado))
  AIC <- -2*(sum(dpois(y,v.ajustado,log=T))) + 2*p
  BIC <- -2*(sum(dpois(y,v.ajustado,log=T))) + 2*p*log(n)
   H < -diag(sqrtm(W)%*%X%*%solve(t(X)%*%W%*%X)%*%t(X)%*%solve(sqrtm(W))) 
  res <- sqrt(2*(y*(ifelse(y==0,0,log(y))-log(v.ajustado))-y+v.ajustado))/sqrt(1-H)
  residuos <- ifelse(y-v.ajustado>0,res,-res)
  residuos.pearson <- (y-v.ajustado)/sqrt(v.ajustado*(1-H))
  W<-diag(length(y))
  diag(W)<-exp(X%*%est)</pre>
  I=t(X)%*%W%*%X
  se=sqrt(diag(solve(I)))
  z.value=est/se
  p.value=pnorm(abs(z.value), lower.tail = F)
  z.alpha<-qnorm(0.975)
 LI=est-z.alpha*se
  LS=est+z.alpha*se
  saida<-list(out=out, est=est, iter=i, se=se, v.ajustado=v.ajustado, preditor.linear=preditor.linear,
              z.value=z.value, p.value=p.value, LI=LI, LS=LS,AIC=AIC, BIC=BIC, desvio=desvio, gl.res=(n-p),
              residuos=residuos, residuos.pearson=residuos.pearson)
  return(saida)
```

```
mlgPoisson = function(y,X,init,eps=1e-6,maxiter=50){
  # Validações
 ly <- length(y)</pre>
 if (nrow(X) != ly){stop("Número de linhas na matriz X difere do número de observações em y")}
 if (ncol(X) != nrow(init)){stop("Valores inválidos para os parâmetros iniciais")}
 if(maxiter <= 0 | maxiter %1 != 0) stop("maxiter precisa ser um inteiro positivo.")
 if(eps <=0 | eps > 1) stop("O erro precisa pertencer ao intervalo (0,1]")
 # Outputs
 out = ajustePoisson(y,X,init,eps=1e-6,maxiter=50)
 betas = round(out$est, 4)
         = round(out$se, 4)
 z.value = round(out$z.value, 4)
 p.value = out$p.value
        = round(out$LI, 2)
 LI
         = round(out$LS, 2)
 LS
 # Criterios
 desvio = round(out$desvio,3)
 desvioinf = matrix(c(desvio,out$gl.res),1,2)
 AIC
       = round(out$AIC,3)
        = round(out$BIC,3)
 BIC
 iter = out$iter
   Estimativas
                   = cbind(betas, se, z. value, p. value)
   colx
                 = ncol(as.matrix(X))
   namesx = paste0('x',1)
   IC=paste0('[',LI[1],';',LS[1],"]")
   if(ncol(as.matrix(X))>1)
     for(i in 2:ncol(as.matrix(X))){namesx = cbind(namesx, paste0('x',i))
     IC = rbind(IC,paste0('[',LI[i],';',LS[i],"]"))}
   Estimativas<-data.frame(Estimativas,IC=IC)</pre>
   dimnames(Estimativas) = list(c(namesx[1:colx]),c("Estimativas", "SE", "valor z", "p-valor", "IC's"))
   dimnames(desvioinf) = list(c('Desvio: '),c(" ", 'g.1'))
   names(iter) = c('Número de iterações: ')
   criteria = as.matrix(c(AIC,BIC))
   dimnames(criteria) = list(c("AIC:", "BIC:"),c(" "))
   cat('\n')
   cat('----
            -----\n')
             MLG para o modelo Poisson com fução de ligação log
   print(Estimativas)
   cat('-----\n')
   print(desvioinf)
   cat('-----
   print(iter)
   cat('----
   cat('Critérios de seleção do Modelo \n')
   print(criteria)
   cat('----
 class(out) <- "mlgPoisson"</pre>
 return(invisible(out))
```

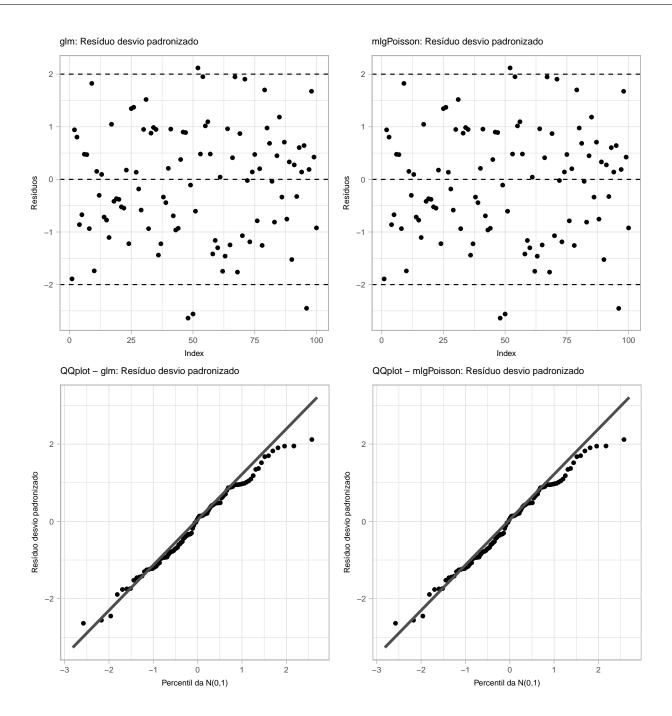
Exemplo Exposição de Bactérias

```
bacterias <- c(175,108,95,82,71,50,49,31,28,17,16,11)
exposicao<-c(1,2,3,4,5,6,7,8,9,10,11,12)
Ajuste glm:
fit<-glm(bacterias~exposicao,family=poisson(link = "log"))</pre>
summary(fit)
Call:
glm(formula = bacterias ~ exposicao, family = poisson(link = "log"))
Deviance Residuals:
             1Q
                  Median
                                3Q
-1.7703 -0.5715 -0.1019 0.5496
Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) 5.30557 0.06348 83.58 <2e-16 ***
                      0.01270 -18.02 <2e-16 ***
exposicao -0.22890
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Dispersion parameter for poisson family taken to be 1)
   Null deviance: 393.6292 on 11 degrees of freedom
Residual deviance: 8.4215 on 10 degrees of freedom
AIC: 80.182
Number of Fisher Scoring iterations: 4
Ajuste glmPoisson:
X<-cbind(rep(1,length(exposicao)),exposicao)</pre>
init<-matrix(solve(t(X)%*%X)%*%t(X)%*%sqrt(bacterias),2,1)
fit.mlg<-mlgPoisson(bacterias, X, init, eps=1e-6, maxiter=50)</pre>
      MLG para o modelo Poisson com fução de ligação log
                                 p-valor
  Estimativas SE valor z
                                                   IC's
     5.3056 0.0635 83.5750 0.000000e+00 [5.18;5.43]
x1
      -0.2289 0.0127 -18.0234 6.386627e-73 [-0.25;-0.2]
x2
               g.l
Desvio: 8.422 10
Número de iterações:
Critérios de seleção do Modelo
AIC: 80.182
BIC: 86.122
Resíduo desvio padronizado:
residuos<-cbind(residuals.glm(fit),fit.mlg$residuos)
colnames(residuos)<-c("glm","mlgPoisson")</pre>
residuos
         glm mlgPoisson
  1.14871848 1.15037616
 -1.77034442 -1.77216391
3 -0.64055838 -0.64105455
   0.15107587 0.15117908
4
   0.84173046 0.84236463
```

```
-0.14314040 -0.14328145
   1.27943323 1.28119813
8 -0.22657370 -0.22701238
  0.45220360 0.45340480
10 -0.78002614 -0.78278823
11 -0.06067891 -0.06095752
12 -0.54845042 -0.55163662
# residuals.glm(object, type), com type = c("deviance", "pearson", "working", "response", "partial")
Resíduo de pearson padronizado:
residuos<-cbind(residuals.glm(fit,type = "pearson"),fit.mlg$residuos.pearson)</pre>
colnames(residuos)<-c("glm","mlgPoisson")</pre>
residuos
          glm mlgPoisson
   1.16596377 1.16764635
1
  -1.72344485 -1.72521613
  -0.63372990 -0.63422077
4
   0.15149889 0.15160239
5
   0.85634914 0.85699432
6
 -0.14266151 -0.14280209
   1.32157970 1.32340274
8 -0.22506270 -0.22549845
  0.45888083 0.46009976
10 -0.75724781 -0.75992923
11 -0.06052647 -0.06080437
12 -0.53431842 -0.53742251
Valores ajustados:
valores.ajustados<-cbind(bacterias,fit$fitted.values,fit.mlg$v.ajustado)
colnames(valores.ajustados)<-c("bacterias","glm","mlgPoisson")</pre>
valores.ajustados
                  glm mlgPoisson
  bacterias
        175 160.24051 160.24051
1
2
        108 127.45716 127.45716
3
         95 101.38091 101.38091
4
         82 80.63955 80.63955
5
         71 64.14163
                        64.14163
         50 51.01900
                       51.01900
6
         49 40.58110
                        40.58110
8
         31 32.27868
                        32.27868
9
         28 25.67484
                        25.67484
         17 20.42206
                        20.42206
10
         16 16.24394
                        16.24394
11
12
         11 12.92062
                        12.92062
Preditor Linear:
preditor.linear<-cbind(fit$linear.predictors,fit.mlg$preditor.linear)</pre>
colnames(preditor.linear)<-c("glm","mlgPoisson")</pre>
preditor.linear
        glm mlgPoisson
1 5.076676 5.076676
2 4.847780
              4.847780
  4.618885
              4.618885
   4.389989
              4.389989
   4.161094
              4.161094
   3.932198
               3.932198
   3.703302
              3.703302
8 3.474407
              3.474407
   3.245511
              3.245511
10 3.016616
              3.016616
11 2.787720
              2.787720
12 2.558825
             2.558825
```

Questão 1.c

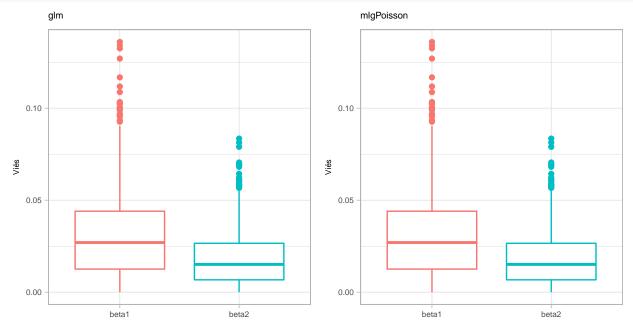
```
Gerando um conjunto de dados:
x=cbind(rep(1,100),runif(100,0,2))
beta < -c(1,3)
y=rpois(n=100,lambda=exp(x%*%beta))
Ajuste usando o glm:
fit=glm(y~x-1,family=poisson(link = "log"))
summary(fit)
Call:
glm(formula = y ~ x - 1, family = poisson(link = "log"))
Deviance Residuals:
    Min
           1Q
                    Median
                                 ЗQ
-2.63742 -0.87580
                  0.06836
                            0.81999
                                      2.11842
Coefficients:
  Estimate Std. Error z value Pr(>|z|)
x1 0.98779 0.04154 23.78 <2e-16 ***
x2 3.00987 0.02487 121.02 <2e-16 ***
Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
(Dispersion parameter for poisson family taken to be 1)
   Null deviance: 172159.99 on 100 degrees of freedom
Residual deviance: 114.85 on 98 degrees of freedom
AIC: 693.58
Number of Fisher Scoring iterations: 4
Ajuste usando a função criada:
init=solve(t(x)%*%x)%*%t(x)%*%sqrt(y)
fit.mlg<-mlgPoisson(y,x,init,eps=1e-6,maxiter=50)</pre>
     MLG para o modelo Poisson com fução de ligação log
               SE valor z
  Estimativas
                                  p-valor
      0.9878 0.0415 23.7785 2.788136e-125 [0.91;1.07]
      3.0099 0.0249 121.0170 0.000000e+00 [2.96;3.06]
                g.l
Desvio: 114.855 98
-----
Número de iterações:
                 21
Critérios de seleção do Modelo
AIC: 693.575
BIC: 707.996
```



Questão 1.d - Estudo de simulação.

```
N=1000
betasglm<-betas<-matrix(NA,N,2)</pre>
aicglm<-aic<-desvioglm<-desvio<-NULL
for(i in 1:N){
  set.seed(1000*i)
  x=cbind(rep(1,100),runif(100,0,2))
  beta < -c(1,3)
  y=rpois(n=100,lambda=exp(x%*%beta))
  fit.glm=glm(y~x-1,family=poisson(link = "log"))
  betasglm[i,]<-fit.glm$coef</pre>
  aicglm[i]<-fit.glm$aic
  desvioglm[i]<-fit.glm$deviance</pre>
  init < -matrix(solve(t(x)%*%x)%*%t(x)%*%sqrt(y),2,1)
  fit.mlgPoisson=ajustePoisson(y,x,init,eps=1e-6,maxiter=100)
  betas[i, ]<-fit.mlgPoisson$est</pre>
  aic[i]<-fit.mlgPoisson$AIC
```

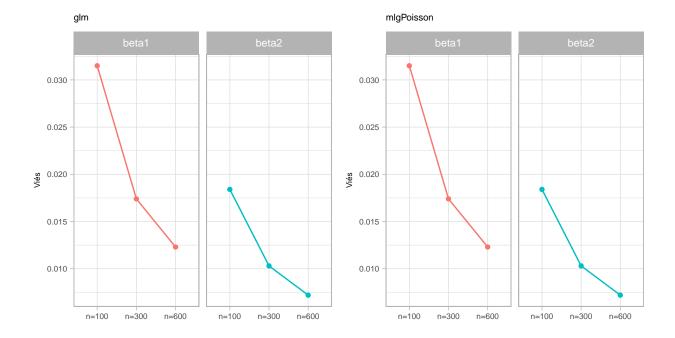
```
desvio[i] <-fit.mlgPoisson$desvio
}
beta <-matrix(c(1,3),1000,2,byrow=T)
viesglm <-abs(betasglm-beta)
vies <-abs(betas-beta)</pre>
```



	glm	mlgPoisson
β_1	1.0003	1.0003
β_2	2.9999	2.9999
AIC	684.744	684.744
Desvio	98.887	98.887

Questão 1.e - Estudo de simulação.

	n=100		n=300		n=600	
	$_{ m glm}$	mlgPoisson	$_{ m glm}$	mlgPoisson	$_{ m glm}$	mlgPoisson
β_1	1.0003	1.0003	0.9999	0.9999	0.9996	0.9996
β_2	2.9999	2.9999	3	3	3.0002	3.0002
AIC	684.744	684.744	2051.196	2051.196	4099.517	4099.517
Desvio	98.887	98.887	302.329	302.329	606.15	606.15



Questão 3

Gerando um conjunto de dados:

```
x1=rnorm(100,10,2)
x2=rnorm(100,5,1)
x=cbind(x1,x2)
beta<-c(-1,2)
y=rbinom(n = 100, size = 1, prob = exp(x%*%beta)/(1+exp(x%*%beta)))</pre>
```

Ajuste usando o glm:

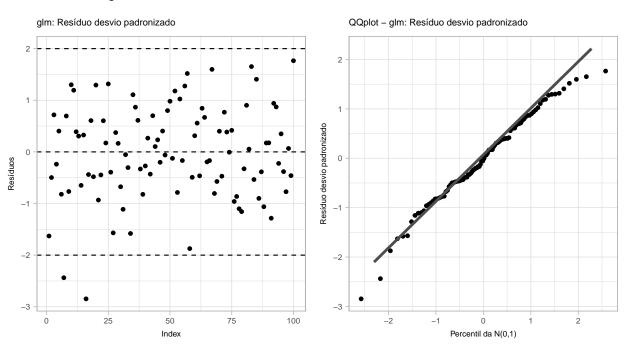
```
fit=glm(y~x1+x2-1,family=binomial(link = "logit"))
summary(fit)
```

```
Call:
glm(formula = y \sim x1 + x2 - 1, family = binomial(link = "logit"))
Deviance Residuals:
    Min
               1Q
                     Median
                                   ЗQ
                                            Max
-2.84641
         -0.50652 -0.02992
                              0.62527
                                        1.76608
Coefficients:
  Estimate Std. Error z value Pr(>|z|)
             0.1926 -4.985 6.19e-07 ***
x1 -0.9601
               0.3904 4.942 7.74e-07 ***
   1.9293
x2
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Dispersion parameter for binomial family taken to be 1)
   Null deviance: 138.629 on 100 degrees of freedom
```

Number of Fisher Scoring iterations: 6

AIC: 83.162

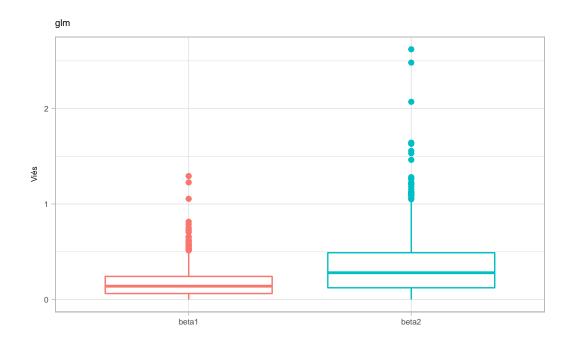
Residual deviance: 79.162 on 98 degrees of freedom



Questão 3.d - Estudo de simulação.

```
N=1000
betasglm<-matrix(NA,N,2)</pre>
aicglm<-desvioglm<-NULL
for(i in 1:N){
set.seed(1000*i)
x1=rnorm(100,10,2)
x2=rnorm(100,5,1)
x = cbind(x1, x2)
beta < -c(-1,2)
y=rbinom(n = 100, size = 1, prob = \exp(x\%*\%beta)/(1+\exp(x\%*\%beta)))
fit.glm=glm(y~x1+x2-1,family=binomial(link = "logit"))
betasglm[i,]<-fit.glm$coef</pre>
aicglm[i]<-fit.glm$aic</pre>
desvioglm[i]<-fit.glm$deviance</pre>
beta <- matrix (c(-1,2),1000,2,byrow=T)
```

```
viesglm<-abs(betasglm-beta)</pre>
```



	n=100	n=300	n=500
β_1 (-1)	-1.0536	-1.018	-1.0116
β_2 (2)	2.1059	2.0378	2.0226
AIC	77.416	227.604	377.958
Desvio	73.416	223.604	373.958

