

ME720 - Modelos Lineares Generalizados

Parte 5 - Poder do teste e determinação do tamanho da amostra
em modelos normais lineares

Profa. **Larissa Avila Matos**

Poder do teste

Sabemos que,

- α = probabilidade do erro do tipo I = $P(\text{Rejeitar } H_0 | H_0 \text{ é verdadeira})$;
- β = probabilidade do erro do tipo II = $P(\text{Não rejeitar } H_0 | H_0 \text{ é falsa})$;
- ψ = poder do teste = $1 - \beta = P(\text{Rejeitar } H_0 | H_0 \text{ é falsa})$.

Em geral, em qualquer experimento, a probabilidade do erro do tipo I é controlada (α).

A probabilidade do erro do tipo II (consequentemente o poder do teste) não é, em geral, controlada.

Como determinar tamanhos de amostra (por tratamento/no geral) que garantam um poder mínimo?

Como calcular o poder do teste, para um dado experimento?

Distribuição qui-quadrado não central

Sejam $X_1, X_2, \dots, X_n \stackrel{ind}{\sim} N(\mu_i, \sigma_i^2)$.

Defina $Y = \sum_{i=1}^n \left(\frac{X_i}{\sigma_i}\right)^2$. Dizemos então que Y tem distribuição qui-quadrado não central com n graus de liberdade e parâmetro de não-centralidade $\delta = \sum_{i=1}^n \left(\frac{\mu_i}{\sigma_i}\right)^2$.

Notação: $Y \sim \chi_{(n,\delta)}^2$, cuja fdp é dada por

$$f_Y(y) = \sum_{i=0}^{\infty} \frac{e^{-\delta/2} (\delta/2)^i}{i!} f_{W_{n+2i}}(y) \mathbb{1}_{(0,\infty)}(y),$$

em que $W_{n+2i} \sim \chi_{(n+2i)}^2$.

Se $\delta = 0$, então $Y \sim \chi_{(n)}^2$.

Distribuição F não central

Seja V uma outra v.a., independente de Y , $V \sim \chi^2_{(m)}$.

Defina $F = \frac{Y/n}{V/m}$. Então, F tem distribuição F não central com graus de liberdade, n e m e parâmetro de não centralidade δ .

Notação: $F \sim F_{(n,m,\delta)}$, cuja fdp é dada por

$$\begin{aligned} f_F(f) &= \sum_{i=0}^{\infty} \frac{e^{-\delta/2} (\delta/2)^i}{\beta(m/2, n/2 + i) i!} \left(\frac{n}{m}\right)^{n/2+i} \left(\frac{m}{m + nf}\right)^{(n+m)/2+i} \\ &\times f^{n/2-1+i} \mathbb{1}_{(0,\infty)}(f), \end{aligned}$$

em que $\beta(a, b) = \int_0^1 x^{a-1} (1-x)^{b-1} dx$.

Modelo para um único fator

As observações podem ser descritas pelo modelo,

$$Y_{ij} = \mu + \alpha_i + \xi_{ij},$$

com $i = 1, 2, \dots, k$ (grupos); $j = 1, \dots, n$ (u.e).

- Erros $\xi_{ij} \stackrel{i.i.d}{\sim} N(0, \sigma^2)$.
- μ, α_i não aleatórios.
- Restrição: $\alpha_1 = 0$ (Casela de Referência).

Hipótese de interesse (primário)

$$H_0 : \quad \alpha_2 = \alpha_3 = \dots = \alpha_k = 0 \quad vs$$

$$H_1 : \quad \text{pelo menos uma desigualdade.}$$

Lembremos que, sob H_0 , $V = SQF/\sigma^2 \sim \chi_{(k-1)}^2$.

Independentemente de H_0 ser verdadeira, $W = SQR/\sigma^2 \sim \chi_{(n-k)}^2$.

Assim, sob H_0 $F = \frac{V/(k-1)}{W/(n-k)} \sim F_{(k-1, n-k)}$.

Lembrando que,

$$\mathbb{E}(SQF) = (k-1)\sigma^2 + n \sum_{i=1}^k (\mu_i - \bar{\mu})^2, \quad \text{com} \quad \bar{\mu} = \frac{1}{k} \sum_{i=1}^k \mu_i$$

No caso da parametrização casela de referência, tem-se que $\mu_i - \bar{\mu} = \alpha_i - \bar{\alpha}$,
 $\bar{\alpha} = \frac{1}{k} \sum_{i=1}^k \alpha_i$.

Assim,

$$\mathbb{E}(SQF/\sigma^2) = \underbrace{(k-1)}_{\text{graus de liberdade}} + \underbrace{\frac{n}{\sigma^2} \sum_{i=1}^k (\alpha_i - \bar{\alpha})^2}_{\text{parâmetro de não centralidade}}.$$

Assim, se H_0 não for verdadeira, então

$$V \sim \chi^2_{(k-1, \delta)}, \delta = n \frac{\sum_{i=1}^k (\alpha_i - \bar{\alpha})^2}{\sigma^2}.$$

Portanto,

$$\mathbb{E}(SQF/\sigma^2) = (k - 1) + \delta.$$

Segue-se que, sob H_1 , $F \sim F_{(k-1, nk-k, \delta)}$.

Regra para obtenção do parâmetro de não-centralidade. Em geral,

$\mathbb{E}(\text{Soma de Quadrados Fator}/\sigma^2) = \text{g.l.} + \text{parâmetro de não centralidade}$

Assim, para um dado valor de δ e para um nível de significância fixado α , temos que o poder do teste é dado por

$$\psi = P(F_1 > f_c | H_0 \text{ é falsa}), F_1 \sim F_{(k-1, nk-k, \delta)},$$

em que f_c (valor crítico) é o valor da distribuição $F_{(k-1, nk-k)}$, $P(F_0 > f_c | H_0) = \alpha$, ($F_0 \sim F_{(k-1, nk-k)}$).

A função poder (em δ) é dada por:

$$\psi(\delta) = P(F_1 > f_c | H_0 \text{ é falsa}), \quad F_1 \sim F_{(k-1, nk-k, \delta)} \quad (1)$$

Para um determinado conjunto de dados, podemos estimar δ , através de

$$\hat{\delta} = n \frac{\sum_{i=1}^k (\hat{\alpha}_i - \hat{\bar{\alpha}})^2}{\hat{\sigma}^2},$$

em que $\hat{\alpha}_i, i = 1, 2, \dots, k$ são os estimadores de mínimos quadrados, $\hat{\bar{\alpha}} = \frac{1}{k} \sum_{i=1}^k \hat{\alpha}_i$ e $\hat{\sigma}^2 = QMR$.

Logo, o poder estimado é dado por

$$\hat{\psi} = \psi(\hat{\delta}),$$

ou seja, utiliza-se $\hat{\delta}$ na equação (1).

Exemplo Solvente

Uma bioquímica (Tecnologia de Alimentos) está interessada em estudar a extração de pigmentos naturais, com aplicação como corante em alimentos. Numa primeira etapa tem-se a necessidade de escolher o melhor solvente extrator. A escolha do(s) melhor(es) solventes foi realizada através da medida da absorbância de um pigmento natural do fruto de baguaçu.

- Fator = tipos de solvente;
- $k=5$ níveis;
- $n_k=5$ repetições.

```
fit.model <- lm(mabsor~solvfac)
summary(fit.model)
```

Call:

```
lm(formula = mabsor ~ solvfac)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.04024	-0.01874	-0.00086	0.01914	0.05136

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.53934	0.01128	47.826	< 2e-16 ***
solvfacE70	0.06854	0.01595	4.298	0.000351 ***
solvfacEAW	0.02752	0.01595	1.726	0.099843 .
solvfacM1M	-0.34258	0.01595	-21.481	2.75e-15 ***
solvfacMAW	-0.08970	0.01595	-5.624	1.67e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02522 on 20 degrees of freedom

Multiple R-squared: 0.977, Adjusted R-squared: 0.9725

F-statistic: 212.8 on 4 and 20 DF, p-value: 4.378e-16

```
fit.model$coef
```

```
(Intercept)  solvfacE70  solvfacEAW  solvfacM1M  solvfacMAW  
      0.53934      0.06854      0.02752     -0.34258     -0.08970
```

```
sigma2 <- (summary(fit.model)$sigma)^2  
sigma2
```

```
[1] 0.0006358708
```

```
sum(fit.model$residuals^2)/fit.model$df.residual
```

```
[1] 0.0006358708
```

```
v.alpha <- c(0, fit.model$coef[-1])  
delta <- 5*sum((v.alpha - mean(v.alpha))^2)/sigma2  
delta
```

```
[1] 851.2221
```

Da análise anterior, temos:

■ $\tilde{\alpha} = (0; 0,06854; 0,02752; -0,34258; -0,08970);$ e

■ $\tilde{\sigma}^2 = 0,0006358708.$

Isto implica que $\tilde{\delta} = 851,222$.

Neste caso, para um $\alpha = 0,05$, o valor crítico é igual à 2,866.

```
qf(p=0.95,df1=5-1,df2=25-5)
```

```
[1] 2.866081
```

Assim, o poder estimado será igual à

$$\tilde{\psi} = P(F_1 > 2,866 | H_0 \text{ é falsa}) \equiv P(F_1 > 2,866) > 0,9999.$$

```
pf(q=2.866081,df1=5-1,df2=25-5,ncp=delta)
```

```
[1] 1.440173e-123
```

Exemplo

Tem-se o interesse em se saber se a quantidade de fósforo existente (administrada) no solo afeta a produção de milho (de uma certa variedade).

Fator: quantidade de fósforo, $k = 5$ níveis, $n = 4$, $i = 1, 2, 3, 4$ repetições por tratamento (quantidade de fósforo administrada).

Procedimento: 20 porções de terras, chamadas de parcelas (em condições semelhantes) foram consideradas e cada uma delas recebeu uma determinada quantidade de fósforo, de modo aleatório (completamente casualizado).

Resposta: produção de milho (kg/parcela).

Experimento balanceado.

Dados:

Quantidade de Fósforo	Produção			
	1	2	3	4
0 kg/ha	2,38	6,77	3,50	5,94
25 kg/ha	6,15	8,78	8,99	9,10
50 kg/ha	9,07	8,73	6,92	8,48
75 kg/ha	9,55	8,95	10,24	8,66
100 kg/ha	9,14	10,17	9,75	9,50

Modelo Casela de Referência

As observações podem ser descritas pelo modelo:

$$Y_{ij} = \mu + \alpha_i + \xi_{ij},$$

com $i = 1, 2, \dots, 5$ (tratamentos); $j = 1, \dots, 4$ (u.e).

- Erros $\xi_{ij} \stackrel{i.i.d}{\sim} N(0, \sigma^2)$.
- μ, α_i não aleatórios.
- Restrição: $\alpha_1 = 0$.


```
fit.model <- lm(pmilho~fosfac)
summary(fit.model)
```

Call:

```
lm(formula = pmilho ~ fosfac)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.2675	-0.5475	0.1900	0.7438	2.1225

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.6475	0.6237	7.451	2.04e-06	***
fosfac25	3.6075	0.8820	4.090	0.000966	***
fosfac50	3.6525	0.8820	4.141	0.000871	***
fosfac75	4.7025	0.8820	5.331	8.39e-05	***
fosfac100	4.9925	0.8820	5.660	4.53e-05	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.247 on 15 degrees of freedom

Multiple R-squared: 0.7315, Adjusted R-squared: 0.6599

F-statistic: 10.22 on 4 and 15 DF, p-value: 0.0003379

```
anova(fit.model)
```

Analysis of Variance Table

Response: pmilho

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
fosfac	4	63.596	15.899	10.218	0.0003379 ***
Residuals	15	23.340	1.556		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Estimativas dos parâmetros do modelo

Parâmetro	Estimativa	EP	IC(95%)	Estat. t	p-valor
μ	4,6475	0,6237	[3,318; 5,977]	7,451	<0,001
α_2	3,6075	0,8820	[1,727; 5,488]	4,090	<0,001
α_3	3,6525	0,8820	[1,772; 5,533]	4,141	<0,001
α_4	4,7025	0,8820	[2,822; 6,583]	5,331	<0,001
α_5	4,9925	0,8820	[3,112; 6,873]	5,660	<0,001

Estimativas das médias

Parâmetro	Estimativa	EP	IC(95%)
μ_1	4,647	0,624	[3,318; 5,977]
μ_2	8,255	0,624	[6,926; 9,584]
μ_3	8,300	0,624	[6,971; 9,629]
μ_4	9,350	0,624	[8,021; 10,679]
μ_5	9,640	0,624	[8,311; 10,969]

```
fit.model$coef
```

(Intercept)	fosfac25	fosfac50	fosfac75	fosfac100
4.6475	3.6075	3.6525	4.7025	4.9925

```
sigma2 <- (summary(fit.model)$sigma)^2  
sigma2
```

```
[1] 1.556012
```

```
sum(fit.model$residuals^2)/fit.model$df.residual
```

```
[1] 1.556012
```

```
v.alpha <- c(0, fit.model$coef[-1])  
delta <- 4*sum((v.alpha - mean(v.alpha))^2)/sigma2  
delta
```

```
[1] 40.87108
```

Da análise anterior, temos:

■ $\tilde{\alpha} = (0; 3,6075; 3,6525; 4,7025; 4,9925)$ e

■ $\tilde{\sigma}^2 = 1,556012;$

Logo $\tilde{\delta} = 40,871$.

Assim, temos os seguintes resultados, conforme o valor de α escolhido.

α	f_c	$\tilde{\psi}$
0,10	2,36	0,9992
0,05	3,06	0,9965
0,01	4,89	0,9624

```
qf(0.90,5-1,20-5)
```

```
[1] 2.361433
```

```
1-pf(qf(0.90,5-1,20-5),5-1,20-5,delta)
```

```
[1] 0.9992473
```

```
qf(0.95,5-1,20-5)
```

```
[1] 3.055568
```

```
1-pf(qf(0.95,5-1,20-5),5-1,20-5,delta)
```

```
[1] 0.9965949
```

```
qf(0.99,5-1,20-5)
```

```
[1] 4.89321
```

```
1-pf(qf(0.99,5-1,20-5),5-1,20-5,delta)
```

```
[1] 0.9624809
```

Suponha que o pesquisador queira realizar um outro experimento semelhante à este em questão.

Ele quer, para $\alpha = 0,05$, um poder de pelo menos 0,90.

Qual deve ser o tamanho para cada tratamento (consequentemente o tamanho total) para obter este poder?

n	nk	f_c	δ	$\widetilde{\psi}$
2	10	5,19	20,43	0,6289
3	15	3,47	30,65	0,9536
4	20	3,06	40,87	0,9965
5	25	2,87	51,09	0,9998


```

k <- 5
ni <- c(2,3,4,5)
ptestes <- NULL
deltas <- NULL
quantfs <- NULL
for(i in 1:length(ni)){
n <- ni[i]
delta <- n*sum((v.alpha-mean(v.alpha))^2)/sigma2
deltas[i] <- delta
quantf <- qf(0.95,k-1,k*n-k)
quantfs[i] <- quantf
ptestes[i] <- 1-pf(quantf,k-1,k*n-k,delta)}
cbind(n=ni,nk=ni*k,fc=round(quantfs,2),delta=round(deltas,2),
      poder=round(pptestes,4))

```

	n	nk	fc	delta	poder
[1,]	2	10	5.19	20.44	0.6289
[2,]	3	15	3.48	30.65	0.9536
[3,]	4	20	3.06	40.87	0.9966
[4,]	5	25	2.87	51.09	0.9998

Como proceder

Perguntar ao pesquisador e/ou usar informações de experimentos anteriores sobre o nível de significância (α).

Perguntar ao pesquisador e/ou usar informações de experimentos anteriores sobre a variabilidade (σ^2).

Perguntar ao pesquisador e/ou usar informações de experimentos anteriores sobre a magnitude das diferenças entre as médias.

Exemplo artificial

Três grupos, experimento balanceado, $\alpha = 0,05$, $\sigma^2 = 5$, $k = 3$.

n	kn	f_c	$\sum_{i=1}^3 \alpha_i^2$							
			0,5		2		50		200	
			δ	ψ	δ	ψ	δ	ψ	δ	ψ
2	6	9,55	0,07	0,0522	0,30	0,0599	6,80	0,2790	30,24	0,7907
3	9	5,14	0,10	0,0549	0,45	0,0721	10,20	0,5882	45,36	0,9963
4	12	4,26	0,14	0,0575	0,60	0,0846	13,60	0,7970	60,48	>0,9999
5	15	3,89	0,17	0,0602	0,76	0,0974	17,00	0,9091	75,60	>0,9999
10	30	3,35	0,34	0,0737	1,51	0,1649	34,01	0,9993	151,20	>0,9999

```

k <- 3
ni <- c(2,3,4,5,10)
alphas<-rbind(sqrt(c(0,0.2,0.3)),sqrt(c(0,0.5,1.5)),sqrt(c(0,20,30)),sqrt(c(0,50,150)))
sigma2<-5
ptests <- NULL
deltas <- NULL
quantfs <- NULL
x=NULL
for(j in 1:nrow(alphas)){
  v.alpha<-alphas[j,]
  for(i in 1:length(ni)){
    n <- ni[i]
    delta <- n*sum((v.alpha-mean(v.alpha))^2)/sigma2
    deltas[i] <- delta
    quantf <- qf(0.95,k-1,k*n-k)
    quantfs[i] <- quantf
    ptests[i] <- 1-pf(quantf,k-1,k*n-k,delta)}
  x=cbind(x,n=ni,nk=ni*k,fc=round(quantfs,2),delta=round(deltas,2),poder=round(ptests,4))}
x

```

	n	nk	fc	delta	poder	n	nk	fc	delta	poder	n	nk	fc	delta
[1,]	2	6	9.55	0.07	0.0522	2	6	9.55	0.30	0.0599	2	6	9.55	6.80
[2,]	3	9	5.14	0.10	0.0549	3	9	5.14	0.45	0.0721	3	9	5.14	10.20
[3,]	4	12	4.26	0.14	0.0575	4	12	4.26	0.60	0.0846	4	12	4.26	13.60
[4,]	5	15	3.89	0.17	0.0602	5	15	3.89	0.76	0.0974	5	15	3.89	17.00
[5,]	10	30	3.35	0.34	0.0737	10	30	3.35	1.51	0.1649	10	30	3.35	34.01

	poder	n	nk	fc	delta	poder
[1,]	0.2790	2	6	9.55	30.24	0.7907
[2,]	0.5882	3	9	5.14	45.36	0.9963
[3,]	0.7970	4	12	4.26	60.48	1.0000
[4,]	0.9091	5	15	3.89	75.60	1.0000
[5,]	0.9993	10	30	3.35	151.20	1.0000

Curvas do poder do teste


Configurações:

- $\sigma^2 = 5, 10 \text{ e } 20$

- $n = 2, 5, 8 \text{ e } 10$


- $\alpha = 0,01, 0,05, \text{ e } 0,10$

$$\sigma^2 = 5$$



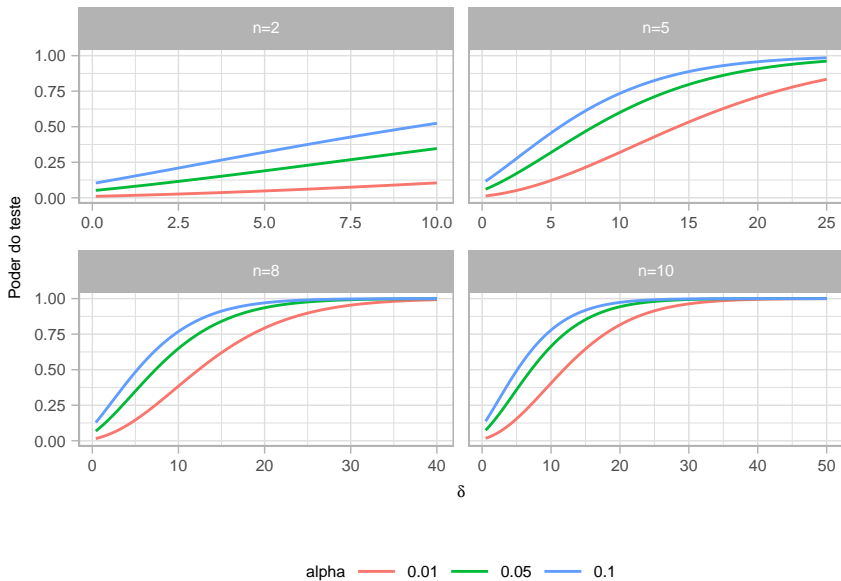
alpha — 0.01 — 0.05 — 0.1

$$\sigma^2 = 10$$



alpha — 0.01 — 0.05 — 0.1

$$\sigma^2 = 20$$



Comentários sobre o poder do teste

- Podemos notar que, quanto maior o valor do parâmetro de não centralidade (δ), maior o poder do teste.
- Quanto maior for a diferença entre as médias e menor for a variância, maior será o valor de δ , conseqüentemente, maior será o poder do teste.
- Além disso, quanto maior for o valor da probabilidade do erro do tipo I (α), maior será o poder do teste;

- Notas de aula do Prof. Caio Azevedo.
- Agresti, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley series in probability and statistics.