

# ME720 - Modelos Lineares Generalizados

Parte 7 - Parametrização, identificabilidade, estimabilidade e testabilidade em modelos normais lineares

Profa. **Larissa Avila Matos**

## Exemplo 2 (dados de absorbância)

Voltemos ao exemplo dos solventes (um único fator com vários níveis).

$$Y_{ij} = \mu + \alpha_i + \xi_{ij}, \quad i = 1, 2, \dots, k, \quad j = 1, \dots, n_i.$$

- Erros (parte aleatória):  $\xi_{ij} \stackrel{i.i.d}{\sim} N(0, \sigma^2)$ ;
- $\mu$ ,  $\alpha_i$  e  $\sigma^2$  parâmetros desconhecidos;
- $\mu$  : média geral.
- $\alpha_i$  : efeito relacionada ao  $i$ -ésimo fator.

Implicação das suposições acima:  $Y_{ij} \stackrel{ind.}{\sim} N(\mu + \alpha_i, \sigma^2)$ .

## Exemplo 2

Matricialmente:  $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\xi}$ , onde

$$\mathbf{Y} = \begin{bmatrix} Y_{11} \\ Y_{12} \\ Y_{13} \\ Y_{14} \\ Y_{15} \\ Y_{21} \\ \vdots \\ Y_{51} \\ \vdots \\ Y_{55} \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 0 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \end{bmatrix}, \quad \boldsymbol{\xi} = \begin{bmatrix} \xi_{11} \\ \xi_{12} \\ \xi_{13} \\ \xi_{14} \\ \xi_{15} \\ \xi_{21} \\ \vdots \\ \xi_{51} \\ \vdots \\ \xi_{55} \end{bmatrix}$$

# Identificabilidade

Seja  $L(\boldsymbol{\theta})$  a verossimilhança associada à um determinado modelo (probabilístico, estatístico, regressão).

O modelo é dito estar (globalmente) identificado (sob a ótica frequentista) se  $\forall \boldsymbol{\theta}_1 \neq \boldsymbol{\theta}_2, \boldsymbol{\theta}_i, i = 1, 2 \in \Theta$ , tivermos

$$L(\boldsymbol{\theta}_1) \neq L(\boldsymbol{\theta}_2).$$

Se o modelo está identificado, tem-se que, para um determinado método de estimação (em geral), teremos um único conjunto de estimativas, para uma dada amostra.

Se o modelo não está identificado, podemos ter mais de um conjunto de estimativas.

# Porque (re)parametrizar o modelo?

Interpretações mais apropriadas dos parâmetros (os modelos são mais facilmente interpretáveis).

Testes de hipótese mais simples (em termos dos parâmetros) principalmente para modelos mais complexos.

Para garantir a identificabilidade do modelo.

Mais facilidade na identificação de efeitos significativos.

Estimadores com propriedades mais interessantes (ortogonalidade).

# Parametrizações para o modelo em questão

*Modelo de médias.* Modelo identificado.

*Desvios com restrição:*  $\sum_{i=1}^k \alpha_i = 0$ . Modelo identificado.

*Casela (cela de referência):* igualar um único  $\alpha_i$  à 0, por exemplo  $\alpha_1$ . Modelo identificado.

*Desvios sem restrição:* não se coloca nenhuma restrição. Modelo não identificado. Neste caso, somente as funções estimáveis podem ser “estimadas”.

Para interpretação dos parâmetros basta lembrar que  $\mu_i = \mu + \alpha_i$

# Parametrização de médias

*Modelo de médias:*

$$Y_{ij} = \mu_i + \xi_{ij}, \quad i = 1, 2, \dots, k, \quad j = 1, \dots, n_i.$$

- Erros  $\xi_{ij} \stackrel{i.i.d}{\sim} N(0, \sigma^2)$ .
- $\mu_i$  não aleatório.
- $\mathbb{E}(Y_{ij}) = \mu_i, \quad \text{Var}(Y_{ij}) = \sigma^2$ .
- $\mu_i$  : média populacional relacionada ao i-ésimo fator.

# Parametrização de médias

Neste caso, temos que

$$\mathbf{Y} = \begin{bmatrix} Y_{11} \\ Y_{12} \\ Y_{13} \\ Y_{14} \\ Y_{15} \\ Y_{21} \\ \vdots \\ Y_{51} \\ \vdots \\ Y_{55} \end{bmatrix}, \mathbf{X} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}, \boldsymbol{\beta} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \\ \mu_5 \end{bmatrix}, \boldsymbol{\xi} = \begin{bmatrix} \xi_{11} \\ \xi_{12} \\ \xi_{13} \\ \xi_{14} \\ \xi_{15} \\ \xi_{21} \\ \vdots \\ \xi_{51} \\ \vdots \\ \xi_{55} \end{bmatrix}$$



# Desvios com restrição

*Desvios com restrição:*  $\sum_{i=1}^k \alpha_i = 0$ .

■  $\mu$  : média das médias dos grupos  $\mu = \bar{\mu} = \frac{1}{k} \sum_{i=1}^k \mu_i$ .

■  $\alpha_i$  : incremento (positivo ou negativo) da média do grupo  $i$  com relação à média das médias,  $\alpha_i = \mu_i - \bar{\mu}$ .

Em geral, considera-se que  $\alpha_k = -\sum_{i=1}^{k-1} \alpha_i$ .

# Desvios com restrição

Neste caso, temos que

$$\mathbf{Y} = \begin{bmatrix} Y_{11} \\ Y_{12} \\ Y_{13} \\ Y_{14} \\ Y_{15} \\ Y_{21} \\ \vdots \\ Y_{51} \\ \vdots \\ Y_{55} \end{bmatrix}, \mathbf{X} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & -1 & -1 & -1 & -1 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & -1 & -1 & -1 & -1 \end{bmatrix}, \boldsymbol{\beta} = \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \end{bmatrix}, \boldsymbol{\xi} = \begin{bmatrix} \xi_{11} \\ \xi_{12} \\ \xi_{13} \\ \xi_{14} \\ \xi_{15} \\ \xi_{21} \\ \vdots \\ \xi_{51} \\ \vdots \\ \xi_{55} \end{bmatrix}$$

# Casela de referências ( $\alpha_1 = 0$ )

*Casela de referência:*  $\alpha_1 = 0$ .

- $\mu$  : média do grupo 1 (grupo de referência),  $\mu = \mu_1$ .
- $\alpha_i$  : incremento (positivo ou negativo) da média do grupo  $i$  com relação à média do grupo 1 (grupo de referência),  $\alpha_i = \mu_i - \mu_1$ .

Em geral, esta será a parametrização utilizada no curso.

## Casela de referências ( $\alpha_1 = 0$ )

Neste caso, temos que

$$\mathbf{Y} = \begin{bmatrix} Y_{11} \\ Y_{12} \\ Y_{13} \\ Y_{14} \\ Y_{15} \\ Y_{21} \\ \vdots \\ Y_{51} \\ \vdots \\ Y_{55} \end{bmatrix}, \mathbf{X} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 0 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix}, \boldsymbol{\beta} = \begin{bmatrix} \mu \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \end{bmatrix}, \boldsymbol{\xi} = \begin{bmatrix} \xi_{11} \\ \xi_{12} \\ \xi_{13} \\ \xi_{14} \\ \xi_{15} \\ \xi_{21} \\ \vdots \\ \xi_{51} \\ \vdots \\ \xi_{55} \end{bmatrix}$$

# Desvios sem restrição

*Desvios sem restrição*:  $k$  médias e  $(k+1)$  parâmetros.

Os parâmetros, por si só, não tem interpretações mas, combinações lineares deles, podem ter:

- $\mu_i = \mu + \alpha_i$  (média do  $i$ -ésimo grupo).
- $\mu_i - \mu_j = \alpha_i - \alpha_j$  (diferença entre as médias do grupo  $i$  e do grupo  $j$ ).

As combinações lineares acima pertencem à classe das **funções estimáveis**.

# Desvios sem restrição

Neste caso, temos que

$$\mathbf{Y} = \begin{bmatrix} Y_{11} \\ Y_{12} \\ Y_{13} \\ Y_{14} \\ Y_{15} \\ Y_{21} \\ \vdots \\ Y_{51} \\ \vdots \\ Y_{55} \end{bmatrix}, \mathbf{X} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 0 & 0 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}, \boldsymbol{\beta} = \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \end{bmatrix}, \boldsymbol{\xi} = \begin{bmatrix} \xi_{11} \\ \xi_{12} \\ \xi_{13} \\ \xi_{14} \\ \xi_{15} \\ \xi_{21} \\ \vdots \\ \xi_{51} \\ \vdots \\ \xi_{55} \end{bmatrix}$$

# Estimação por MQO

O estimador de MQO é dado pela solução da seguinte equação:

$$(\mathbf{X}'\mathbf{X})\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$$

Nos casos das parametrizações: de médias, casela de referência e desvios com restrição, a matriz  $\mathbf{X}$  é de posto coluna completo e, portanto

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

Contudo, para a parametrização desvios sem restrição, a matriz  $\mathbf{X}$  é de posto coluna incompleto e, portanto

$$\hat{\beta} = \mathbf{GX}'\mathbf{Y},$$

em que  $\mathbf{G}$  é uma (entre várias) inversa generalizada (ig) de  $(\mathbf{X}'\mathbf{X})$ . Ou seja,  $(\mathbf{X}'\mathbf{X})\mathbf{G}(\mathbf{X}'\mathbf{X}) = \mathbf{X}'\mathbf{X}$ .

Desse modo, para um determinado conjunto de dados, podemos ter infinitos conjuntos de estimativas.

Que implicações (limitações) ocorrem neste caso?

Primeiramente, note que  $\hat{\beta} \sim N_p(\mathbf{GX}'\mathbf{X}\beta, \sigma^2\mathbf{GX}'\mathbf{XG}')$ .



# Resultados importantes

Se  $X'X = \mathbf{0} \rightarrow X = \mathbf{0}$ .

Se  $PX'X = QX'X \rightarrow PX' = QX'$ .

Se  $G$  é uma ig de de  $X'X$  (usando-se os dois itens acima), tem-se que

1  $G'$  é uma ig de  $X'X$ .

2  $GX'$  é uma ig de  $X$ , ou seja  $XGX'X = X$ .

3  $XGX'$  é invariante relativamente à escolha de  $G$ .

4  $XGX'$  é simétrica, mesmo quando  $G$  não o é.

# Somas de Quadrados

Seja  $\hat{\beta} = \mathbf{GX}'\mathbf{Y}$  (note que temos um conjunto de soluções).

Soma de quadrados dos resíduos

$$\begin{aligned} SQR &= (\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta}) = (\mathbf{Y} - \mathbf{XGX}'\mathbf{Y})'(\mathbf{Y} - \mathbf{XGX}'\mathbf{Y}) \\ &= \mathbf{Y}'(\mathbf{I} - \mathbf{XGX}')'(\mathbf{I} - \mathbf{XGX}')\mathbf{Y} \\ &= \mathbf{Y}'(\mathbf{I} - \mathbf{XGX}' - \mathbf{XGX}' + \underbrace{\mathbf{XGX}'\mathbf{X}}_{\mathbf{X}}\mathbf{GX}')\mathbf{Y} \\ &= \mathbf{Y}'(\mathbf{I} - \mathbf{XGX}')\mathbf{Y} \end{aligned}$$

Assim, tem-se que  $\mathbf{B} = \mathbf{I} - \mathbf{XGX}'$  é simétrica e idempotente. Além disso  $r(\mathbf{I} - \mathbf{XGX}') = n - r(\mathbf{X})$ .

Pode-se provar, então, que  $SQR/\sigma^2 \sim \chi^2_{(n-r(\mathbf{X}))}$ .

Defina agora  $SQM = \mathbf{Y}'(\mathbf{XGX}' - n^{-1}\mathbf{J})\mathbf{Y} = \mathbf{Y}'\mathbf{A}\mathbf{Y}$ .

Pode-se provar que:

- $n^{-1}\mathbf{XGX}'\mathbf{J} = n^{-1}\mathbf{J}$ .

- $\mathbf{A}$  é simétrica e idempotente, onde  $r(\mathbf{A}) = r(\mathbf{X}) - 1$ .

- $\mathbf{AB} = \mathbf{BA} = \mathbf{0}$

- Sob  $H_0$ ,  $SQM/\sigma^2 \sim \chi^2_{(r(\mathbf{X})-1)}$ .

- Sob  $H_1$ ,  $SQM/\sigma^2 \sim \chi^2_{(r(\mathbf{X})-1, \delta)}$ , em que

$$\delta = \frac{1}{\sigma^2} (\beta' \mathbf{X}' \mathbf{XGX}' \mathbf{X} \beta - n^{-1} \beta' \mathbf{X}' \mathbf{JX} \beta) = \frac{1}{\sigma^2} (\beta \mathbf{X}' \mathbf{X} \beta - n^{-1} \beta' \mathbf{X}' \mathbf{JX} \beta)$$

# Estatística do teste ANOVA

Assim, sob  $H_0$ ,

$$F = \frac{SQM/(r(\mathbf{X}) - 1)}{SQR/n - r(\mathbf{X})} \sim F_{(r(\mathbf{X})-1, n-r(\mathbf{X}))}.$$

Assim, sob  $H_1$ ,

$$F = \frac{SQM/(r(\mathbf{X}) - 1)}{SQR/n - r(\mathbf{X})} \sim F_{(r(\mathbf{X})-1, n-r(\mathbf{X}), \delta)},$$

em que

$$\delta = \frac{1}{\sigma^2} (\beta' \mathbf{X}' \mathbf{X} \mathbf{G} \mathbf{X}' \mathbf{X} \beta - n^{-1} \beta' \mathbf{X}' \mathbf{J} \mathbf{X} \beta) = \frac{1}{\sigma^2} (\beta \mathbf{X}' \mathbf{X} \beta - n^{-1} \beta' \mathbf{X}' \mathbf{J} \mathbf{X} \beta)$$

Os resultados apresentados valem, independentemente da escolha de  $\mathbf{G}$ .

## Funções estimáveis de $\beta$

Tendo estabelecido que não podemos estimar  $\beta$ , a próxima dúvida é saber se podemos estimar alguma combinação linear dos  $\beta$ 's, digamos  $\lambda'\beta$ , onde  $\lambda$  é um vetor  $p \times 1$ .

Considere o modelo normal linear usual e  $\mathbf{X}$  geral (de posto coluna completo ou incompleto) e  $\hat{\beta} = \mathbf{G}\mathbf{X}'\mathbf{Y}$ .

**Definição:** Uma função linear dos parâmetros  $\lambda'\beta$  é dita ser estimável se existe uma combinação linear das observações com um valor esperado igual a  $\lambda'\beta$ , ou seja, dizemos que  $\theta = \lambda'\beta$  é uma função estimável se  $\exists$  um vetor  $\mathbf{a}_{(p \times 1)}$  tal que

$$\mathbb{E}(\mathbf{a}'\mathbf{Y}) = \lambda'\beta = \theta.$$

# Funções estimáveis de $\beta$

**Teorema:** No modelo linear  $Y = X\beta + \xi$ , onde  $\mathbb{E}(Y) = X\beta$  e  $X$  é uma matriz  $n \times p$  de posto  $k < p \leq n$ , a função linear  $\lambda'\beta$  é estimável se e somente se qualquer uma das seguintes condições é satisfeita:

- 1  $\lambda'$  é uma combinação linear das linhas de  $X$ , isto é, existe um vetor  $a$  tal que  $a'X = \lambda'$ .
- 2  $\lambda'$  é uma combinação linear das linhas de  $X'X$  ou  $\lambda$  é uma combinação linear das colunas de  $X'X$ , isto é, existe um vetor  $r$  tal que  $r'X'X = \lambda'$  ou  $X'Xr = \lambda$ .
- 3  $\lambda$  ou  $\lambda'$  é tal que  $X'X(X'X)^-\lambda = \lambda$  ou  $\lambda'(X'X)^-X'X = \lambda'$ , onde  $(X'X)^-$  é qualquer inversa generalizada (simétrica) de  $X'X$ .

# Funções estimáveis de $\beta$ - Exemplo

Voltando ao exemplo anterior, temos

**1**  $\mathbf{X}' = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$ , então  $\theta = \mu$ .

**2**  $\mathbf{X}' = \begin{bmatrix} 0 & 1 & -1 & 0 & 0 & 0 \end{bmatrix}$ , então  $\theta = \alpha_1 - \alpha_2$ .

**3**  $\mathbf{X}' = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 \end{bmatrix}$ , então  $\theta = \mu + \alpha_1$ .

Para o segundo caso, se tomarmos

$$\mathbf{a}' = \left[ \begin{array}{cccccccccccc} \frac{1}{5} & \frac{1}{5} & \frac{1}{5} & \frac{1}{5} & \frac{1}{5} & -\frac{1}{5} & -\frac{1}{5} & -\frac{1}{5} & -\frac{1}{5} & -\frac{1}{5} & 0 & \dots & 0 \end{array} \right],$$

temos que  $\mathbf{a}'\mathbf{Y} = \bar{Y}_1 - \bar{Y}_2$ , logo  $\mathbf{a}'\mathbb{E}(\mathbf{Y}) = \mathbb{E}(\bar{Y}_1 - \bar{Y}_2) = \alpha_1 - \alpha_2$ .

Para o terceiro caso, se tomarmos

$\mathbf{a}' = \left[ \begin{array}{ccccccccc} 1/5 & 1/5 & 1/5 & 1/5 & 1/5 & 0 & \dots & 0 \end{array} \right]$ , temos que  $\mathbf{a}'\mathbf{Y} = \bar{Y}_1$ ,  
logo  $\mathbf{a}'\mathbb{E}(\mathbf{Y}) = \mathbb{E}(\bar{Y}_1) = \mu + \alpha_1$ .

Para o primeiro caso, não é possível encontrar  $\mathbf{a}$  que satisfaça à restrição em questão.

Observação, se  $\mathbf{a}'\mathbb{E}(\mathbf{Y}) = \boldsymbol{\lambda}'\boldsymbol{\beta} \rightarrow \mathbf{a}'\mathbf{X}\boldsymbol{\beta} = \mathbf{a}'\boldsymbol{\beta} \rightarrow \mathbf{a}'\mathbf{X} = \boldsymbol{\lambda}'$ .



**Teorema:** No modelo de posto incompleto ( $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\xi}$ ), o número de funções estimáveis linearmente independentes de  $\boldsymbol{\beta}$  é igual ao posto de  $\mathbf{X}$ .

# Estimadores de $\lambda'\beta$

O valor esperado de cada observação é estimável.

Combinações lineares de funções estimáveis são funções estimáveis.

Dos slides acima temos os estimadores  $\mathbf{a}'\mathbf{Y}$  e  $\mathbf{r}'\mathbf{X}'\mathbf{Y}$  para  $\lambda'\beta$ , onde  $\mathbf{a}'$  e  $\mathbf{r}'$  satisfazem  $\lambda' = \mathbf{a}'\mathbf{X}$  e  $\lambda = \mathbf{r}'\mathbf{X}'\mathbf{X}$ , respectivamente. Um terceiro estimador de  $\lambda'\beta$  é  $\lambda'\hat{\beta}$ , onde  $\hat{\beta}$  é uma solução de  $\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y}$ .

Nós iremos focar nos estimadores  $\mathbf{r}\mathbf{X}'\mathbf{Y}$  e  $\lambda'\hat{\beta}$ .

# Resultados sobre funções estimáveis

Seja  $\lambda'\beta$  uma função estimável de  $\beta$  no modelo  $Y = X\beta + \xi$ , onde  $E(Y) = X\beta$  e  $X$  é  $n \times p$  de posto  $k < p \leq n$ . Seja  $\hat{\beta}$  qualquer solução do sistema de equações normais  $X'X\hat{\beta} = X'Y$ , e seja  $r$  qualquer solução para  $X'Xr = \lambda$ . Então os dois estimadores  $\lambda'\hat{\beta}$  e  $r'X'Y$  têm as seguintes propriedades:

- 1  $E(\lambda'\hat{\beta}) = E(r'X'Y) = \lambda'\beta$ .
- 2  $\lambda'\hat{\beta} = r'X'Y$  para qualquer  $\hat{\beta}$  e qualquer  $r$ .
- 3  $\lambda'\hat{\beta}$  e  $r'X'Y$  são invariantes para escolhas de  $\hat{\beta}$  ou  $r$ .

Prova: ??

# Resultados sobre funções estimáveis

A variância de  $\lambda'\beta$  ou de  $\mathbf{r}'\mathbf{X}'\mathbf{Y}$  tem as seguintes propriedades:

**1**  $Var(\mathbf{r}'\mathbf{X}'\mathbf{Y}) = \sigma^2 \mathbf{r}'\mathbf{X}'\mathbf{X}\mathbf{r} = \sigma^2 \mathbf{r}'\boldsymbol{\lambda}.$

**2**  $Var(\boldsymbol{\lambda}'\hat{\boldsymbol{\beta}}) = \sigma^2 \boldsymbol{\lambda}'(\mathbf{X}'\mathbf{X})^{-}\boldsymbol{\lambda}.$

**3**  $Var(\boldsymbol{\lambda}'\hat{\boldsymbol{\beta}})$  é única, ou seja, é invariante para as escolhas de  $\mathbf{r}$  ou de  $(\mathbf{X}'\mathbf{X})^{-}.$

Se  $\boldsymbol{\lambda}'_1\beta$  e  $\boldsymbol{\lambda}'_2\beta$  são duas funções estimáveis do modelo, então

$$Cov(\boldsymbol{\lambda}'_1\hat{\boldsymbol{\beta}}, \boldsymbol{\lambda}'_2\hat{\boldsymbol{\beta}}) = \sigma^2 \mathbf{r}'_1\boldsymbol{\lambda}_2 = \sigma^2 \boldsymbol{\lambda}_1'\mathbf{r}_2 = \sigma^2 \boldsymbol{\lambda}_1'(\mathbf{X}'\mathbf{X})^{-}\boldsymbol{\lambda}_2,$$

onde  $\mathbf{X}'\mathbf{X}\mathbf{r}_1 = \boldsymbol{\lambda}_1$  e  $\mathbf{X}'\mathbf{X}\mathbf{r}_2 = \boldsymbol{\lambda}_2.$

Prova: ??

# Resultados sobre funções estimáveis

Então, temos o seguinte Teorema:

[TEO.] Se  $\lambda'\beta$  é uma função estimável no modelo  $Y = X\beta + \xi$ , onde  $X$  é  $n \times p$  de posto  $k < p \leq n$ , então os estimadores  $\lambda'\hat{\beta}$  e  $r'X'Y$  são os melhores estimadores não viesados (BLUE) de  $\lambda'\beta$ .

Prova: ??

## Estimador de $\sigma^2$

Assim como nos modelos com posto completo, minimizar a soma de quadrados  $\boldsymbol{\xi}\boldsymbol{\xi}'$  não fornece um estimador para  $\sigma^2$ . No entanto, um estimador não viaciado de  $\sigma^2$  baseado nas estimativas de mínimos quadrados e dado por

$$\hat{\sigma}^2 = \frac{1}{n-k} \left( \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}} \right)' \left( \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}} \right)$$

O qual é não-viciado. Além disso, pode-se provar que  $\hat{\boldsymbol{\beta}} \perp \hat{\sigma}^2$  e  $\frac{(n-p)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{(n-k)}$ .  $\hat{\sigma}^2$  é invariante a escolha de  $\hat{\boldsymbol{\beta}}$  ou a escolha da inversa generalizada  $(\mathbf{X}\mathbf{X})^-$ .

# Estimação por máxima verossimilhança

Seja  $\mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I})$ , onde  $\mathbf{X}$  é  $n \times p$  de posto  $k < p \leq n$ .

Então, os estimadores de máxima verossimilhança  $\hat{\boldsymbol{\beta}}$  e  $\hat{\sigma}^2$  (corrigindo o viés) são dados por

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \quad \text{e} \quad \hat{\sigma}^2 = \frac{n}{n-k}(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}),$$

e têm as seguintes propriedades:

- 1  $\hat{\boldsymbol{\beta}} \sim N_p((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1});$
- 2  $\frac{(n-k)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{(n-k)};$
- 3  $\hat{\boldsymbol{\beta}}$  e  $\hat{\sigma}^2$  são independentes.

Se  $\boldsymbol{\lambda}'\boldsymbol{\beta}$  é uma função estimável no modelo, então  $\boldsymbol{\lambda}'\hat{\boldsymbol{\beta}}$  tem variância mínima dentre todos os estimadores não viesados.

# Hipóteses testáveis

Uma hipótese tal como  $H_0 : \beta_1 = \beta_2 = \cdots = \beta_q$  é dita ser testável se existe um conjunto de funções estimáveis linearmente independentes  $\lambda'_1\beta, \lambda'_2\beta, \cdots, \lambda'_t\beta$ , tal que  $H_0$  é verdadeira se e somente se  $\lambda'_1\beta = \lambda'_2\beta = \cdots = \lambda'_t\beta = 0$ .



# Hipóteses testáveis

Sejam as hipóteses

$$H_0 : \mathbf{C}_{(q \times p)} \boldsymbol{\beta}_{(p \times 1)} = \mathbf{M}_{(q \times 1)} \text{ vs } H_1 : \mathbf{C}_{(q \times p)} \boldsymbol{\beta}_{(p \times 1)} \neq \mathbf{M}_{(p \times 1)}.$$

A estatística (usual) do teste dependerá de  $\mathbf{C}\hat{\boldsymbol{\beta}} - \mathbf{M}$ .

Se  $\mathbf{C} = \begin{bmatrix} \boldsymbol{\lambda}'_1 & \boldsymbol{\lambda}'_2 & \dots & \boldsymbol{\lambda}'_q \end{bmatrix}$ , com  $\boldsymbol{\lambda}_i \boldsymbol{\beta}$  sendo uma função estimável,  $i = 1, 2, \dots, q$ , então  $\mathbf{C}\boldsymbol{\beta} = \mathbf{M}$  é uma hipótese testável.

Antes de discutirmos sobre a situação em que  $\mathbf{X}$  tem posto coluna incompleto, voltemos ao caso anterior.

# Construção da Estatística do Teste (posto coluna completo)

Vimos que:

$$\hat{\boldsymbol{\theta}} = \mathbf{C}\hat{\boldsymbol{\beta}} - \mathbf{M} \sim N_q(\mathbf{C}\boldsymbol{\beta} - \mathbf{M}, \sigma^2 \mathbf{C}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{C}').$$

Como  $\hat{\boldsymbol{\beta}} \perp \hat{\sigma}^2$ , então  $\hat{\boldsymbol{\theta}} \perp \hat{\sigma}^2$ , em que

$$\hat{\sigma}^2 = \frac{1}{n-p}(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \frac{1}{n-p}\mathbf{Y}'(\mathbf{I} - \mathbf{H})\mathbf{Y} = \frac{SQR}{n-p} = QMR$$

Portanto, sob  $H_0(\mathbf{C}\boldsymbol{\beta} = \mathbf{M})$  e usando alguns resultados de distribuições de formas quadráticas, temos que

$$Q^* = \frac{1}{\sigma^2} \left( \mathbf{C}\hat{\boldsymbol{\beta}} - \mathbf{M} \right)' \left( \mathbf{C}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{C}' \right)^{-1} \left( \mathbf{C}\hat{\boldsymbol{\beta}} - \mathbf{M} \right) \sim \chi_{(q)}^2$$

Além disso, vimos que  $(n-p)\widehat{\sigma}^2/\sigma^2 \sim \chi_{(n-p)}^2$ .

Portanto, pelos resultados acima, temos, sob  $H_0$ , que:

$$F = \frac{Q^*/q}{\widehat{\sigma}^2/\sigma^2} = \frac{1}{q\widehat{\sigma}^2} \left( C\widehat{\beta} - M \right)' \left( C(X'X)^{-1}C' \right)^{-1} \left( C\widehat{\beta} - M \right) \sim F_{(q,n-p)}$$

$p$ -valor =  $P(F > f|H_0)$ , em que  $f$  é o valor calculado da estatística definida acima, e  $F \sim F_{(q,n-p)}$ .

Sob  $H_1$ ,  $F \sim F_{\left[ q, n-p, \delta = \frac{1}{\sigma^2} \left( (C\beta - M)'(C(X'X)^{-1}C')^{-1}(C\beta - M) \right) \right]}$ .

# Construção da Estatística do Teste (posto incompleto)

Posto coluna incompleto: Os desenvolvimentos são semelhantes ao caso em que  $\mathbf{X}$  tem posto coluna completo.

Sabemos que:

$$\hat{\beta} = \mathbf{GX}'\mathbf{Y} \sim N_{col(\mathbf{X})}(\mathbf{GX}'\mathbf{X}\beta, \mathbf{GX}'\mathbf{XG}'\sigma^2).$$

Portanto, segue que:

$$\hat{\theta} = \mathbf{C}\hat{\beta} - \mathbf{M} \sim N_q(\mathbf{CGX}'\mathbf{X}\beta - \mathbf{M}, \mathbf{CGX}'\mathbf{XG}'\mathbf{C}'\sigma^2).$$

Defina:

$$\hat{\sigma}^2 = \frac{1}{n - r(\mathbf{X})} \mathbf{Y}' (\mathbf{I} - \mathbf{XGX}') \mathbf{Y} = \frac{SQR}{n - r(\mathbf{X})}$$

Temos que  $(n - r(\mathbf{X}))\hat{\sigma}^2/\sigma^2 \sim \chi^2_{(n-r(\mathbf{X}))}$ .

Portanto, sob  $H_0(\mathbf{C}\beta = \mathbf{M})$  e usando alguns resultados de distribuições de formas quadráticas e algebrismos, temos que

$$Q^{**} = \frac{1}{\sigma^2} \left( \mathbf{C}\hat{\beta} - \mathbf{M} \right)' (\mathbf{C}\mathbf{G}\mathbf{C}')^{-1} \left( \mathbf{C}\hat{\beta} - \mathbf{M} \right) \sim \chi^2_{(q)}$$

Para provar o resultado acima, usa-se a seguinte igualdade

$$Q^{**} = \frac{1}{\sigma^2} (\mathbf{Y} - \mathbf{X}\mathbf{C}'(\mathbf{C}\mathbf{C}')^{-1}\mathbf{M})' (\mathbf{X}\mathbf{G}'\mathbf{C}'(\mathbf{C}\mathbf{G}\mathbf{C}')^{-1}\mathbf{C}\mathbf{G}\mathbf{X}') (\mathbf{Y} - \mathbf{X}\mathbf{C}'(\mathbf{C}\mathbf{C}')^{-1}\mathbf{M}) \quad (1)$$

Através da expressão (1), pode-se demonstrar ainda que  $\hat{\boldsymbol{\theta}} \perp \hat{\sigma}^2$ , verificando que

$$(\mathbf{X}\mathbf{G}'\mathbf{C}'(\mathbf{C}\mathbf{G}\mathbf{C}')^{-1}\mathbf{C}\mathbf{G}\mathbf{X}')(\mathbf{I} - \mathbf{X}\mathbf{G}\mathbf{X}') = \mathbf{0}$$

Finalmente, com os desenvolvimentos acima, conclui-se que, sob  $H_0$

$$F^* = \frac{Q^{**}/q}{\hat{\sigma}^{*2}/\sigma^2} = \frac{1}{q\hat{\sigma}^{*2}} \left( \mathbf{C}\hat{\boldsymbol{\beta}} - \mathbf{M} \right)' (\mathbf{C}\mathbf{G}\mathbf{C}')^{-1} \left( \mathbf{C}\hat{\boldsymbol{\beta}} - \mathbf{M} \right) \sim F_{(q, n-r(\mathbf{X}))}$$

e, sob  $H_1$   $F^* \sim F_{(q, n-r(\mathbf{X}), \delta)}$

$$\delta = \frac{1}{\sigma^2} \left[ (\mathbf{C}\boldsymbol{\beta} - \mathbf{M})' (\mathbf{C}\mathbf{G}\mathbf{C}')^{-1} (\mathbf{C}\boldsymbol{\beta} - \mathbf{M}) \right]$$

## Exemplo 2 (dados de absorbância)

Utilizando o modelo desvios sem restrição, obtemos:

$$\hat{\beta} = (0,393; 0,145; 0,173; 0,056; 0,214; -0,196).$$

As médias dos grupos estimadas pelo modelo são

$$\hat{\mu} = (0,539; 0,566; 0,449; 0,607; 0,197).$$

as quais correspondem às médias amostrais (como esperado).

As diferenças entre a média do grupo (E50) e os demais grupos, estimadas pelo modelo foram

$$\hat{\alpha} = (0,028; -0,090; 0,069; -0,343).$$

as quais correspondem às estimativas obtidas anteriormente sob a parametrização casela de referência.

- Notas de aula do Prof. Caio Azevedo.
- Agresti, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley series in probability and statistics.