

ME720 - Modelos Lineares Generalizados

Parte 9 - Inferência em MLGs

Profa. **Larissa Avila Matos**

Estimação dos parâmetros

Uma vez definido cada componente do modelo, obteremos expressões gerais para a função de verossimilhança e para as distribuições assintóticas dos estimadores de máxima verossimilhança dos parâmetros para os MLGs.

Para n observações independentes, temos que a função de verossimilhança do modelo é dada por $\ell(\boldsymbol{\beta}, \phi) = \sum_{i=1}^n \ell_i(\boldsymbol{\beta}, \phi)$, onde

$$\ell_i(\boldsymbol{\beta}, \phi) = \frac{[y_i \theta_i - b(\theta_i)]}{a(\phi)} + c(y_i, \phi).$$

Então,

$$\ell(\boldsymbol{\beta}, \phi) = \sum_{i=1}^n \frac{[y_i \theta_i - b(\theta_i)]}{a(\phi)} + \sum_{i=1}^n c(y_i, \phi).$$

Para um GLM $\eta_i = \sum_{j=1}^p \beta_j x_{ij} = g(\mu_i)$ com função de ligação g , o sistema de equações de verossimilhança para β são

$$\frac{\partial \ell(\beta, \phi)}{\partial \beta_j} = \sum_{i=1}^n \frac{\partial \ell_i}{\partial \beta_j} = 0, \quad \forall j.$$

Para diferenciar a log-verossimilhança, usamos a regra da cadeia,

$$\frac{\partial \ell_i}{\partial \beta_j} = \frac{\partial \ell_i}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_j}.$$

Uma vez que,

$$\frac{\partial \ell_i}{\partial \theta_i} = \frac{[y_i - b'(\theta_i)]}{a(\phi)} \quad \text{e} \quad \mu_i = b'(\theta_i), \quad \text{Var}(Y_i) = b''(\theta_i)a(\phi),$$

temos que

$$\frac{\partial \ell_i}{\partial \theta_i} = \frac{(y_i - \mu_i)}{a(\phi)} \quad \text{e} \quad \frac{\partial \mu_i}{\partial \theta_i} = b''(\theta_i) = \frac{\text{Var}(Y_i)}{a(\phi)}.$$

Também uma vez que $\eta_i = \sum_{j=1}^p \beta_j x_{ij}$, então $\frac{\partial \eta_i}{\partial \beta_j} = x_{ij}$.

Finalmente, $\eta_i = g(\mu_i) \Rightarrow \frac{\partial \mu_i}{\partial \eta_i}$, depende da função de ligação para o modelo escolhido.

Resumindo, temos que

$$\begin{aligned} \frac{\partial \ell_i}{\partial \beta_j} &= \frac{\partial \ell_i}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_j} \\ &= \frac{(y_i - \mu_i)}{a(\phi)} \frac{a(\phi)}{\text{Var}(Y_i)} \frac{\partial \mu_i}{\partial \eta_i} x_{ij} = \frac{(y_i - \mu_i) x_{ij}}{\text{Var}(Y_i)} \frac{\partial \mu_i}{\partial \eta_i} \end{aligned}$$

A soma das n observações produz o sistema de equações de verossimilhança para um MLG.

Equações de verossimilhança para um MLG

Equações de verossimilhança para um MLG:

$$\frac{\partial \ell(\boldsymbol{\beta}, \phi)}{\partial \beta_j} = \sum_{i=1}^n \frac{(y_i - \mu_i) x_{ij}}{\text{Var}(Y_i)} \frac{\partial \mu_i}{\partial \eta_i} = 0, \quad j = 1, 2, \dots, p, \quad \text{e}$$

$$\frac{\partial \ell(\boldsymbol{\beta}, \phi)}{\partial \phi} = 0,$$

onde $\eta_i = \sum_{j=1}^p \beta_j x_{ij} = g(\mu_i)$ para uma função de ligação g .

Seja V a matriz diagonal de variâncias das n observações, e seja D uma matriz diagonal com os elementos de $\frac{\partial \mu_i}{\partial \eta_i}$.

Para as expressões GLM $\eta = X\beta$ com matriz de planejamento X , as equações de verossimilhança têm a forma

$$XDV^{-1}(y - \mu) = 0.$$

Apesar de β não aparecer nessas equações, ele aparece implicitamente através de $\mu_i = g^{-1}(\sum_{j=1}^p \beta_j x_{ij})$.

Diferentes funções de ligação gera diferentes conjuntos de equações.

Essas equações são funções não lineares de β , e esse problema deve ser resolvido iterativamente. Há várias opções de algoritmos numéricos para resolução de sistemas não lineares: Newton-Raphson, Escore de Fisher (EF), Nelder-Mead, BFGS entre outros.

Exercício

- Encontrar as equações de máxima verossimilhança para o Modelo Poisson Log Linear.

Relação entre média e variância

Os sistema de equações de máxima verossimilhança depende da distribuição de Y_i somente pela média ($\mathbb{E}(Y_i)$) e pela variância ($\text{Var}(Y_i)$).

Além disso, a variância depende da média pela forma

$$\text{Var}(Y_i) = V(\mu_i),$$

para alguma função $V(\cdot)$.

Ou seja, a relação entre a média e a variância caracteriza a distribuição de Y_i .

Exemplo: Se Y_i tem distribuição pertencente a família exponencial e $\text{Var}(Y_i) = \mu_i$, então necessariamente Y_i tem distribuição de Poisson.

Distribuição Assintótica de $\hat{\beta}$

Através das propriedades de máxima verossimilhança, e sob condições de regularidade, para n grande o estimador de máxima verossimilhança $\hat{\beta}$ de β para um MLG é eficiente e tem distribuição Normal.

Temos que a matrix de informação \mathbf{I} , tem elementos dados por

$$\begin{aligned}\mathbb{E} \left(-\frac{\partial^2 \ell_i}{\partial \beta_j \partial \beta_k} \right) &= \mathbb{E} \left(\frac{\partial \ell_i}{\partial \beta_j} \frac{\partial \ell_i}{\partial \beta_k} \right) \\&= \mathbb{E} \left(\frac{(Y_i - \mu_i) x_{ij}}{\text{Var}(Y_i)} \frac{\partial \mu_i}{\partial \eta_i} \frac{(Y_i - \mu_i) x_{ik}}{\text{Var}(Y_i)} \frac{\partial \mu_i}{\partial \eta_i} \right) \\&= \frac{x_{ij} x_{ik}}{\text{Var}(Y_i)^2} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \underbrace{\mathbb{E} ((y_i - \mu_i)^2)}_{=\text{Var}(Y_i)} = \frac{x_{ij} x_{ik}}{\text{Var}(Y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2.\end{aligned}$$

A matriz \mathbf{I} é chamada de matriz de informação esperada.

Então,

$$\mathbb{E} \left(-\frac{\partial^2 \ell}{\partial \beta_j \partial \beta_k} \right) = \sum_{i=1}^n \frac{x_{ij} x_{ik}}{\text{Var}(Y_i)} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2$$

Seja, \mathbf{W} uma matriz diagonal com elementos dados por

$$w_i = \frac{(\partial \mu_i / \partial \eta_i)^2}{\text{Var}(Y_i)}$$

$$\Rightarrow \mathbf{I} = \mathbf{X}' \mathbf{W} \mathbf{X}$$

A forma de \mathbf{W} depende da função de ligação $g(\cdot)$, uma vez que $\partial \mu_i / \partial \eta_i = g'(\mu_i)$.

Portanto, a matriz de covariância de $\hat{\boldsymbol{\beta}}$ é dada pela inversa da matriz de informação \mathbf{I} .

Distribuição Assintótica de $\hat{\beta}$ para um MLG $\eta = X\beta$:

$\hat{\beta}$ tem distribuição aproximadamente normal $N(\beta, (X'WX)^{-1})$,

onde W é a matriz diagonal com elementos $w_i = \frac{(\partial\mu_i/\partial\eta_i)^2}{\text{Var}(Y_i)}$.

A matriz de covariância assintótica é estimada por $\widehat{\text{Var}}(\hat{\beta}) = (X'\widehat{W}X)^{-1}$, onde \widehat{W} é W avaliado em $\hat{\beta}$.

Obs:

- 1 Para a FE com parâmetro de escala, θ e ϕ são parâmetros ortogonais.
- 2 $\hat{\beta}$ e $\hat{\phi}$ são assintoticamente independentes.

Matriz de covariância para os valores ajustados

O preditor linear estimado é dado por

$$\hat{\eta} = \mathbf{X}\hat{\beta}.$$

Para n grande, temos

$$\text{Var}(\hat{\eta}) = \mathbf{X}'\text{Var}(\hat{\beta})\mathbf{X} \approx \mathbf{X}'(\mathbf{X}'\mathbf{W}\mathbf{X})^{-1}\mathbf{X}.$$

Podemos obter a variância assintótica de $\hat{\mu}$ ($\text{Var}(\hat{\mu})$) por $\text{Var}(\hat{\eta})$, através do método delta. Então,

$$\text{Var}(\hat{\mu}) \approx \mathbf{D}'\text{Var}(\hat{\eta})\mathbf{D} \approx \mathbf{D}\mathbf{X}'(\mathbf{X}'\mathbf{W}\mathbf{X})^{-1}\mathbf{X}\mathbf{D},$$

onde \mathbf{D} é uma matriz diadonal com elementos $\partial\mu_i/\partial\eta_i$.

Exercício: Pesquisar sobre o método delta.

Exercício

- Voltando ao exemplo da Poisson, encontre os elementos da matriz W .

Estimação de β

Como encontramos os estimadores de máxima verossimilhança dos parâmetros de um MLG?

Problema: O sistema de equações são geralmente não-lineares em β .

Solução: Métodos iterativos para resolver sistema de equações não lineares. Focaremos em dois métodos:

- *Newton-Raphson*

- *Escore de Fisher*

Método de Newton-Raphson

O algoritmo Newton-Raphson, método de Newton-Raphson, foi desenvolvido por Isaac Newton e Joseph Raphson e tem o objetivo estimar as raízes de uma função.

Suponha que queremos encontrar a solução da equação $g(x_0) = 0$, onde g é uma função diferenciável. Dado um numero x próximo de x_0 , segue da expansão em série de Taylor em torno de x que

$$0 = g(x_0) \approx g(x) + g'(x)(x_0 - x).$$

Resolvendo para x_0 , temos

$$x_0 \approx x - \frac{g(x)}{g'(x)}.$$

Assim, dado um valor estimado x_t , então podemos ter um novo valor estimado x_{t+1} por

$$x_{t+1} \approx x_t - \frac{g(x_t)}{g'(x_t)}.$$

Este procedimento é repetido para $t = 1, 2, 3, \dots$ até $|g(x_t)/g'(x_t)|$ ser suficientemente pequeno.

Método de Newton-Raphson

Voltando ao nosso problema, queremos encontrar a solução da equação $\frac{\partial \ell(\beta)}{\partial \beta} = \mathbf{0}$.

No passo t , o processo iterativo ($t = 0, 1, 2, \dots$) aproxima $\ell(\beta)$ próximo de $\beta^{(t)}$ pela expansão em série de Taylor de segunda ordem,

$$\ell(\beta) \approx \ell(\beta^{(t)}) + \mathbf{u}^{(t)}(\beta - \beta^{(t)}) + \left(\frac{1}{2}\right) (\beta - \beta^{(t)})' \mathbf{H}^{(t)} (\beta - \beta^{(t)}),$$

onde $\mathbf{u}^{(t)}$ e $\mathbf{H}^{(t)}$ são \mathbf{u} e \mathbf{H} avaliados em $\beta^{(t)}$ respectivamente, com

- $\mathbf{u} = \left(\frac{\partial \ell(\beta)}{\partial \beta_1}, \frac{\partial \ell(\beta_2)}{\partial \beta_p}, \dots, \frac{\partial \ell(\beta)}{\partial \beta} \right)'$, e
- \mathbf{H} a matrix *Hessiana*, onde $H_{ij} = \frac{\partial^2 \ell(\beta)}{\partial \beta_i \partial \beta_j}$.

Obs: $\beta^{(o)}$ valor inicial (chute inicial).

Resolvendo, $\frac{\partial \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} \approx \mathbf{u}^{(t)} + \mathbf{H}^{(t)}(\boldsymbol{\beta} - \boldsymbol{\beta}^{(t)}) = \mathbf{0}$, temos a seguinte aproximação

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} - (\mathbf{H}^{(t)})^{-1} \mathbf{u}^{(t)},$$

assumindo que $\mathbf{H}^{(t)}$ é não singular.

O procedimento descrito é repetido até que mudanças em $\ell(\boldsymbol{\beta}^{(t)})$ entre ciclos sucessivos são suficientemente pequenas.

Para muitos MLGs, a matriz Hessian é negativa definida, e a log verossimilhança é uma função estritamente côncava. Então, as estimativas de máxima verossimilhança dos parâmetros do modelo existem e são únicas sob condições bastante gerais. A convergência de $\boldsymbol{\beta}^{(t+1)}$ para $\hat{\boldsymbol{\beta}}$ na vizinhança de $\hat{\boldsymbol{\beta}}$ é rápida.




Figure 4.2 Illustration of a cycle of the Newton–Raphson method.

Figura ilustrativa do livro texto (Agresti, A. (2015)).

Método de Escore de Fisher

O método de Escore de Fisher é um método iterativo alternativo para resolver o sistema de equações de verossimilhança.

A diferença entre o método de Escore de Fisher e o método de Newton-Raphson está na maneira como escolhe a matriz *Hessiana*.

O método de Escore de Fisher usa o valor esperado da matriz *Hessiana*, chamada de matriz de informação esperada, enquanto método de Newton-Raphson usa a própria matriz hessiana, chamada de matriz de informação observada.

Portanto, temos a seguinte aproximação

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} - (\mathbf{I}^{(t)})^{-1} \mathbf{u}^{(t)},$$

onde $\mathbf{I}^{(t)}$ é \mathbf{I} avaliado em $\boldsymbol{\beta}^{(t)}$, ou seja $\mathbf{I}^{(t)}$ tem elementos $-\mathbb{E}(\frac{\partial^2 \ell(\boldsymbol{\beta})}{\partial \beta_i \partial \beta_j})$ avaliado em $\boldsymbol{\beta}^{(t)}$.

Os algoritmos de Escore de Fisher e de Newton-Raphson são idênticos para os MLGs que usam a função de ligação canônica (Nelder e Wedderburn, 1972).

Estimação do parâmetro de escala

- 1 Maximizar $\ell(\boldsymbol{\beta}, \phi)$ com respeito a ϕ . (Muito sensível a suposição da distribuição)
- 2 Sabemos que $\text{Var}(Y_i) = a(\phi)V(\mu_i)$, então

$$\frac{\mathbb{E}((Y_i - \mu_i)^2)}{V(\mu_i)} = a(\phi)$$

$$\Rightarrow \hat{a}(\phi) = \frac{1}{n-p} \sum_{i=1}^n \frac{\mathbb{E}((Y_i - \hat{\mu}_i)^2)}{\text{Var}(\hat{\mu}_i)}.$$

- [Notas](#) de aula do Prof. Gilberto de Paula.
- Agresti, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley series in probability and statistics.