

# ME720 - Modelos Lineares Generalizados

## Parte 13 - Modelos para Dados de Contagem - Poisson

Profa. **Larissa Avila Matos**

# Modelos para Dados de Contagem

Muitas variáveis de resposta tem contagens como possíveis resultados.

Exemplos:

- 1 número de bebidas alcoólicas que você tomou na semana anterior;
- 2 número de dispositivos que você possui que podem acessar a Internet (laptops, telefones celulares inteligentes, tablets, etc.).

Essas contagens também ocorrem nas entradas das caselas nas tabelas de contingência que classificam as variáveis categóricas. Iremos ver modelos lineares generalizados (MLGs) para variáveis de resposta de contagens, como

- 1 modelos que assumem uma distribuição Poisson para a resposta. Esse modelo pode ser adaptado para modelar uma taxa quando a contagem é baseada em um índice, como espaço ou tempo;
- 2 modelos que assumem uma distribuição binomial negativa para a resposta; e
- 3 modelos que lidam com excesso de zeros na variável de resposta.

## MLGs de Poisson para dados de contagem e taxas

A distribuição mais simples para dados de contagem, colocando sua massa no conjunto de valores inteiros não negativos, é a distribuição de Poisson. Suas probabilidades dependem de um único parâmetro, a média  $\mu > 0$ .

Vimos que, se  $Y$  é uma v.a. com distribuição de Poisson ( $Y \sim P(\mu_i)$ ), a f.d.p. é dada por

$$f(y; \mu) = \frac{e^{-\mu} \mu^y}{y!} = \exp[y \log(\mu) - \mu - \log(y!)] , \quad y = 0, 1, 2, \dots,$$

e  $Y \in \text{F.E.}$ , com  $\mathbb{E}(Y) = \text{Var}(Y) = \mu$ .

Além disso, a distribuição de Poisson é uma distribuição unimodal e sua assimetria é descrita por

$$\frac{\mathbb{E}[(Y - \mu)^3]}{\sigma^3} = \frac{1}{\sqrt{\mu}}.$$

A medida que  $\mu$  aumenta, a distribuição de Poisson é menos assimétrica e se aproxima de uma distribuição Normal, sendo uma aproximação razoavelmente boa quando  $\mu > 10$ .

A distribuição de Poisson é frequentemente usada para contagens de eventos que ocorrem aleatoriamente ao longo do tempo ou no espaço a uma taxa específica, quando os resultados em períodos ou regiões disjuntos são independentes.

Por exemplo, um fabricante de telefones celulares pode indicar que a distribuição de Poisson descreve razoavelmente bem o número de reclamações de garantia recebidas a cada semana.

A distribuição de Poisson também pode ser utilizada para a aproximação de uma distribuição Binomial quando o número de ensaios  $n$  é grande e  $\pi$  é muito pequeno, com  $n\pi = \mu$ .

Para a Binomial, se  $n \rightarrow \infty$  e  $\pi \rightarrow 0$  tal que  $n\pi = \mu$  é fixo, a distribuição Binomial converge para a Poisson.

### Demonstração

Por exemplo, se um fabricante tiver vendido 5.000 celulares de um tipo específico e cada um independentemente tiver probabilidade 0,001 de ter uma reivindicação de garantia em uma determinada semana, o número de reclamações por semana terá aproximadamente uma distribuição de Poisson com uma média de  $5000(0,001) = 5$ .

## Modelo Poisson Log Linear

## Modelo Poisson Log Linear

Assumindo que  $Y_1, \dots, Y_n$  são v.a.'s independentes, com  $Y_i \sim \text{Poisson}(\mu_i)$ .

Então, como já vimos, o modelo Poisson Log Linear, é dado por:

**Modelo Poisson Log Linear:**

$$\log(\mu_i) = \sum_{j=1}^p \beta_j x_{ij}, \quad i = 1, \dots, n;$$

ou

$$\log(\boldsymbol{\mu}) = \mathbf{X}\boldsymbol{\beta} \text{ (na forma matricial).}$$

## Ajustando um modelo Poisson Log Linear

Para  $\eta_i = \log(\mu_i)$  e  $\frac{\partial \mu_i}{\partial \eta_i} = \mu_i$ , as equações de log-verossimilhança são dadas por

$$\sum_{i=1}^n (y_i - \mu_i) x_{ij} = 0,$$

com visto anteriormente.

Para um modelo log-linear de Poisson vimos também que

$$\mu_i = \exp \left( \sum_{j=1}^p \beta_j x_{ij} \right) = (e^{\beta_p})^{x_{ip}} \dots (e^{\beta_1})^{x_{i1}}.$$

O aumento de uma unidade em  $x_{ij}$  tem o impacto multiplicativo de  $e^{\beta_j}$ , ou seja, a média em  $x_{ij} + 1$  é igual a média em  $x_{ij}$  multiplicado por  $e^{\beta_j}$ , fixando as outras covariáveis.



A matriz da informação é dada por

$$-\frac{\partial^2 \ell(\boldsymbol{\beta}; \mathbf{y})}{\partial \beta_j \partial \beta_k} = \sum_{i=1}^n x_{ij} x_{ik} \mu_i$$

Então, temos que a matriz Hessiana é definida-negativa, portanto a função de log-verossimilhança é côncava e possui um máximo único.

As matrizes de informação observada e esperada são idênticas. Portanto, o método Newton-Raphson é equivalente ao Escore de Fisher, uma consequência de usarmos a função de ligação canônica.

Além disso para o modelo log-linear de Poisson a matriz de covariância assintótica de  $\widehat{\boldsymbol{\beta}}$  é dada por

$$\widehat{\text{Var}} \left( \widehat{\boldsymbol{\beta}} \right) = \left( \mathbf{X}' \widehat{\mathbf{W}} \mathbf{X} \right)^{-1},$$

onde  $\mathbf{W}$  é uma matriz diagonal com elementos  $w_{ii} = \frac{(\partial \mu_i / \partial \eta_i)^2}{\text{Var}(Y_i)} = \mu_i$ .

O desvio para modelo Poisson Log Linear é

$$D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = 2 \sum_{i=1}^n \left[ y_i \log \left( \frac{y_i}{\hat{\mu}_i} \right) - y_i + \hat{\mu}_i \right].$$

Se o modelo tem intercepto, temos que  $\sum_{i=1}^n \hat{\mu}_i = \sum_{i=1}^n y_i$ , então o desvio é dado por

$$D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = 2 \sum_i y_i \log \left( \frac{y_i}{\hat{\mu}_i} \right).$$

Além disso temos que  $\text{Var}(y_i) = V(\mu_i) = \mu_i$ , com  $\phi = 1$ , a estatística de escore para comparar o modelo escolhido com o modelo saturado é

$$X^2 = \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i} \quad (\text{Estatística de Pearson}).$$

## Modelando Taxas

## Modelando Taxas: incluindo um *offset* no modelo

Frequentemente, o valor esperado de uma resposta de contagem  $Y_i$  é proporcional a um índice  $t_i$ .

Por exemplo,  $t_i$  pode ser uma quantidade de tempo e/ou um tamanho da população, como na modelagem da contagem de crimes para várias cidades. Pode ser também uma área espacial, como na modelagem da contagem de um determinado animal ou espécie vegetal.

Então, a taxa de amostragem é  $\frac{Y_i}{t_i}$ , com valor esperado  $\frac{\mu_i}{t_i}$ .

Considerando variáveis explicativas, um modelo log-linear para a taxa esperada tem a forma

$$\log \left( \frac{\mu_i}{t_i} \right) = \sum_{j=1}^p \beta_j x_{ij}.$$

Como  $\log\left(\frac{\mu_i}{t_i}\right) = \log(\mu_i) - \log(t_i)$ , o modelo faz a correção  $-\log(t_i)$  na função de ligação da média.

Esse termo de correção é chamado de *offset* (deslocamento).

O ajuste corresponde ao uso de  $\log(t_i)$  como uma variável explicativa no preditor linear para  $\log(\mu_i)$  e força seu coeficiente ser igual a 1, ou seja,

$$\begin{aligned}\log(\mu_i) - \log(t_i) &= \sum_{j=1}^p \beta_j x_{ij} \\ \log(\mu_i) &= \sum_{j=1}^p \beta_j x_{ij} + \log(t_i).\end{aligned}$$

Para esse modelo, a contagem da resposta esperada satisfaz

$$\mu_i = t_i \exp \left( \sum_{j=1}^p \beta_j x_{ij} \right).$$

A média possui uma constante de proporcionalidade para  $t_i$  que depende dos valores das variáveis explicativas.

O modelo usando a função de ligação identidade, é dada por

$$\frac{\mu_i}{t_i} = \sum_{j=1}^p \beta_j x_{ij}, \quad \text{ou} \quad \mu_i = \sum_{j=1}^p \beta_j x_{ij} t_i,$$

ou seja, esse modelo corresponde a um MLG de Poisson comum a função de ligação identidade sem intercepto e com variáveis explicativas  $x_{i1}t_i, \dots, x_{ip}t_i$ . Esse modelo fornece efeitos aditivos, e não multiplicativos, das variáveis explicativas.

## Exemplo

## Exemplo: Crimes no campus

Os alunos querem se sentir seguros quando frequentam uma faculdade ou universidade.

Todas as instituições de ensino superior americana que participam de programas federais de auxílio estudantil são obrigadas a coletar e relatar dados sobre crimes que ocorrem no campus para o Departamento de Educação.

Esses dados estão disponíveis publicamente no site [U.S. Department of Education](#).

Estamos interessados em verificar se existem diferenças regionais em crimes violentos no campus, controlando diferenças no tipo de instituição.



Os dados para esse exemplo não foram retirados do site do departamento americano mas do conjunto de **dados** do livro *Broadening Your Statistical Horizons (BYSH): Generalized Linear Models and Multilevel Models*.

Cada linha do conjunto de dados contém informações sobre os crimes de uma instituição do ensino superior, uma faculdade ou universidade. As variáveis incluem:

- **tipo** = tipo de instituição: faculdade (C) ou universidade (U);
- **regiao** = região do país (C = Central, MW = Midwest, NE = Northeast, SE = Southeast, SW = Southwest, e W = West);
- **nc** = número de crimes violentos para na instituição no ano determinado;
- **matric** = número de matriculados na instituição;
- **matric1000** = número de matriculados na instituição, em milhares;
- **nctaxa** = número de crimes violentos por 1000 estudantes.


Combinamos a região SW e SE para formar uma única categoria do sul S.

```

dados = read.table("Crimes.txt", header=T)
dados2<-dados[,1:5]
regiaoS<-dados$regiao
dados2$regiao <- as.factor(ifelse(regiaoS %in% c('SE','SW'), 'S',as.character(regiaoS)))
dados2[1:10,]

```

	matric	tipo	nc	nctaxa	matric1000	regiao
1	5590	U	30	5.36672630	5.590	S
2	540	C	0	0.00000000	0.540	S
3	35747	U	23	0.64341064	35.747	W
4	28176	C	1	0.03549120	28.176	W
5	10568	U	1	0.09462528	10.568	S
6	3127	U	0	0.00000000	3.127	S
7	20675	U	7	0.33857316	20.675	W
8	12548	C	0	0.00000000	12.548	W
9	30063	U	19	0.63200612	30.063	C
10	4429	C	4	0.90313841	4.429	C



O histograma do número de crimes violentos, revela que muitas escolas não relataram crimes violentos ou muito poucos crimes. Algumas instituições têm um grande número de crimes.

Podemos usar um modelo de Poisson para modelar nossos dados, uma vez que são dados de contagem (número de crimes violentos).

Número de crimes:

```
dados2 %>%  
  group_by(regiao, tipo) %>%  
  summarize(mean=mean(nc), var=var(nc), n=length(nc))
```

```
# A tibble: 10 x 5  
# Groups:   regiao [5]  
  regiao tipo    mean    var     n  
  <fct>  <fct>  <dbl>  <dbl> <int>  
1 C      C      1.6    3.3     5  
2 C      U      4.75  30.9    12  
3 MW     C      0.333  0.333     3  
4 MW     U      8.71  30.9     7  
5 NE     C      6      32.9     8  
6 NE     U      5.92  79.2    13  
7 S      C      1.12   5.84     8  
8 S      U      9.88  90.9    17  
9 W      C      0.5    0.333     4  
10 W     U     12.5   57       4
```

Analisando as covariáveis de interesse: tipo de instituição e região, temos que a maioria das instituições são universidades (65% das 81 instituições) e apenas 35% são faculdades.

A Tabela a seguir resume a proporção do tipo de instituição por região. A proporção de faculdades varia de 29% no sudoeste (S) a 50% no oeste (W).

```
tab<-table(dados2$tipo,dados2$regiao)  
round(prop.table(tab,2),3)
```

	C	MW	NE	S	W
C	0.294	0.300	0.381	0.320	0.500
U	0.706	0.700	0.619	0.680	0.500

Embora um modelo de Poisson seja uma boa escolha, pois as respostas são contadas por ano, é importante observar que essas contagens não são diretamente comparáveis uma vez que são provenientes de instituições de tamanhos diferentes.

Ou seja, esperamos que instituições com mais alunos tenham mais relatos de crimes violentos, pois há mais estudantes que podem ser afetados.

Não podemos comparar a primeira instituição no conjunto de dados que tem 30 crimes violentos com a segunda instituição que tem nenhum crime violento quando suas matrículas são muito diferentes; 5.590 para a instituição 1 versus 540 para a instituição 2.

Primeiro vamos analisar a contagem de crimes violentos em termos da taxa por 1.000 matriculados  $\frac{\text{número de crimes violentos}}{\text{número matriculados}} * 1000$ .


A Tabela e a Figura a seguir mostram as taxas médias de crimes violentos. Essas taxas são geralmente mais baixas nas faculdades de uma região (com exceção do Nordeste (NE), Centro). Além disso, o padrão regional das taxas nas universidades parecem diferir do das faculdades.



## Taxa de crimes:

```
dados2 %>%  
  group_by(regiao, tipo) %>%  
  summarize(mean=mean(nctaxa), var=var(nctaxa), n=length(nctaxa))
```

```
# A tibble: 10 x 5  
# Groups:   regiao [5]  
  regiao tipo    mean    var     n  
  <fct>  <fct>  <dbl>  <dbl> <int>  
1 C      C      0.398  0.278     5  
2 C      U      0.222  0.0349    12  
3 MW     C      0.0163 0.000793    3  
4 MW     U      0.402  0.0621     7  
5 NE     C      1.12   1.18     8  
6 NE     U      0.436  0.385    13  
7 S      C      0.187  0.105     8  
8 S      U      0.853  1.61    17  
9 W      C      0.0680 0.0129     4  
10 W     U      0.468  0.0247     4
```



# Modelo

Estamos interessados principalmente nas diferenças de crimes violentos entre os tipos instituições e regiões. Então, vamos considerar o seguinte modelo

$$\log \left( \frac{\mu_i}{matric1000} \right) = \beta_0 + \beta_1 \text{ tipo}_i + \beta_2 \text{ regio}_i, \quad i = 1, \dots, 81,$$

onde  $\mu_i$  é o número médio de crimes violentos por ano na instituição  $i$ , então  $\mu_i/matric1000$  é a taxa anual de crimes por matriculados em milhares na instituição  $i$ .

Portanto, ajustamos um modelo considerando a região e o tipo de instituição à nossa compensação. A região central(C) é o nível de referência no nosso modelo.

```
fit<-glm(formula = nc ~ tipo + regiao, family = poisson, data = dados2,  
         offset = log(matric1000))  
summary(fit)
```

Call:

```
glm(formula = nc ~ tipo + regiao, family = poisson, data = dados2,  
     offset = log(matric1000))
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-4.5671	-1.9636	-0.7205	1.0170	8.8476

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	-1.59629	0.17115	-9.327	< 2e-16 ***
tipoU	0.33415	0.13235	2.525	0.0116 *
regiaoMW	0.09939	0.17752	0.560	0.5756
regiaoNE	0.78081	0.15305	5.102	3.37e-07 ***
regiaoS	0.74926	0.14503	5.166	2.39e-07 ***
regiaoW	0.27223	0.18742	1.453	0.1464

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 491.00 on 80 degrees of freedom  
Residual deviance: 431.45 on 75 degrees of freedom  
AIC: 661.32

Do modelo ajustado, o Nordeste (NE) e o Sul (S) diferem significativamente da região Central (p-valor=  $3.37e - 07$  e p-valor=  $2.39e - 07$ , respectivamente).

O coeficiente estimado de 0,778 significa que a taxa de crimes violentos por 1.000 matriculados no Nordeste (NE) é de quase 2,2 ( $e^{0,781}$ ) vezes a da região Central, fixando o tipo de instituição.

Um intervalo de confiança de Wald para esse fator pode ser construído calculando primeiro um IC para o coeficiente ( $0,781 \pm 1,96 * 0,153$ ) e, em seguida, exponenciando (1,62; 2,95).

Os resultados da análise exploratória sugerem que o efeito do tipo de instituição pode variar dependendo da região; portanto, consideramos um modelo com interação entre região e tipo.

## O ajuste é dado por

```
fit2<-glm(formula = nc ~ tipo + regiao + regiao:tipo, family = poisson, data = dados2,  
  offset = log(matric1000))  
summary(fit2)
```

Call:

```
glm(formula = nc ~ tipo + regiao + regiao:tipo, family = poisson,  
  data = dados2, offset = log(matric1000))
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-3.7292	-1.7103	-0.8095	0.8828	8.6480

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	-1.4741	0.3536	-4.169	3.05e-05 ***
tipoU	0.1959	0.3775	0.519	0.60377
regiaoMW	-1.9765	1.0607	-1.863	0.06239 .
regiaoNE	1.5529	0.3819	4.066	4.77e-05 ***
regiaoS	-0.1562	0.4859	-0.322	0.74779
regiaoW	-1.8337	0.7906	-2.319	0.02037 *
tipoU:regiaoMW	2.1965	1.0765	2.040	0.04132 *
tipoU:regiaoNE	-1.0698	0.4200	-2.547	0.01086 *
tipoU:regiaoS	0.9873	0.5095	1.938	0.05265 .
tipoU:regiaoW	2.4106	0.8140	2.962	0.00306 **

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 491.00 on 80 degrees of freedom  
Residual deviance: 355.99 on 71 degrees of freedom  
AIC: 593.86

Number of Fisher Scoring iterations: 6

Esses resultados fornecem evidências de uma interação entre o efeito da região e o tipo de instituição.

Um teste de desvio mostra que temos evidências estatisticamente significativas ( $\chi^2 = 75,463$ ,  $g.l. = 4$ ,  $p < 0,001$ ) que a diferença entre faculdades e universidades na taxa de crimes violentos difere por região.

Por exemplo, esse modelo estima que as taxas de crimes violentos sejam 13,6 ( $e^{0.196+2.411}$ ) vezes superior nas universidades do oeste (W) em comparação com as faculdades.

Enquanto no Nordeste(NE), estimamos que as taxas de crimes violentos sejam 0,42( $e^{-1.07+0.196}$ ) vezes maior nas universidades em comparação com as faculdades, ou estimamos que as taxas de crimes violentos sejam 2,4( $\frac{1}{e^{-1.07+0.196}}$ )) vezes maior nas universidades em comparação com as faculdades.

```
anova(fit, fit2, test="Chisq")
```

### Analysis of Deviance Table

Model 1: nc ~ tipo + regiao

Model 2: nc ~ tipo + regiao + regiao:tipo

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	75	431.45			
2	71	355.99	4	75.463	1.591e-15 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
deviance(fit) - deviance(fit2)
```

```
[1] 75.4625
```

```
df.residual(fit) - df.residual(fit2)
```

```
[1] 4
```



fitted(fit2)

1	2	3	4	5	6
3.57474021	0.10576484	17.73023966	1.03118138	6.75811351	1.99968026
7	8	9	10	11	12
10.25464249	0.45922998	8.37401286	1.01416836	5.53348034	12.04868813
13	14	15	16	17	18
9.45984002	7.87593925	2.09140171	16.46235012	0.71312920	3.92920299
19	20	21	22	23	24
0.03997462	7.75006353	4.01388835	6.23837914	1.87268365	15.28441247
25	26	27	28	29	30
9.90503597	2.62531827	4.83084484	4.95186432	5.07423850	5.60562618
31	32	33	34	35	36
6.02749270	4.69461726	13.27481281	0.30977157	16.17251758	3.25553608
37	38	39	40	41	42
10.79328537	0.25814455	3.61249951	0.65901480	6.34088510	1.78995465
43	44	45	46	47	48
11.56307039	0.35488947	16.09830047	7.40708683	15.18976819	2.27402078
49	50	51	52	53	54
1.81438910	2.92749739	16.30311751	0.32767513	3.27684820	0.52483041
55	56	57	58	59	60
6.50378365	0.65025381	16.05371703	0.38408304	1.46261978	2.05788477
61	62	63	64	65	66
6.44112645	8.41114417	14.70823341	0.94388489	2.57936198	16.64780176
67	68	69	70	71	72
2.49448325	4.71239009	8.51350919	7.70688846	5.17709019	2.09435954
73	74	75	76	77	78
4.45117663	10.45204746	0.15469917	10.28394656	3.32377603	14.20288354
79	80	81			
3.66126334	3.44453458	0.62489624			

```

X<-cbind(rep(1,length(dados2$nc)), ifelse(dados2$tipo=="U",1,0), ifelse(dados2$regiao=="MW",1,0),
        ifelse(dados2$regiao=="NE",1,0), ifelse(dados2$regiao=="S",1,0), ifelse(dados2$regiao=="W",1,0),
        ifelse(dados2$tipo=="U",1,0)*ifelse(dados2$regiao=="MW",1,0),
        ifelse(dados2$tipo=="U",1,0)*ifelse(dados2$regiao=="NE",1,0),
        ifelse(dados2$tipo=="U",1,0)*ifelse(dados2$regiao=="S",1,0),
        ifelse(dados2$tipo=="U",1,0)*ifelse(dados2$regiao=="W",1,0))
betas<-matrix(fit2$coefficients,10,1)

cbind(exp(X%*%betas+log(dados2$matric1000)),dados2$matric1000*exp(X%*%betas),fitted(fit2))[1:15,]

```

	[,1]	[,2]	[,3]
1	3.5747402	3.5747402	3.5747402
2	0.1057648	0.1057648	0.1057648
3	17.7302397	17.7302397	17.7302397
4	1.0311814	1.0311814	1.0311814
5	6.7581135	6.7581135	6.7581135
6	1.9996803	1.9996803	1.9996803
7	10.2546425	10.2546425	10.2546425
8	0.4592300	0.4592300	0.4592300
9	8.3740129	8.3740129	8.3740129
10	1.0141684	1.0141684	1.0141684
11	5.5334803	5.5334803	5.5334803
12	12.0486881	12.0486881	12.0486881
13	9.4598400	9.4598400	9.4598400
14	7.8759392	7.8759392	7.8759392
15	2.0914017	2.0914017	2.0914017

Outra forma de incluir o *offset*:

```
fit3<-glm(formula = nc ~ tipo + regiao + offset(log(matric1000)), family = poisson,  
          data = dados2)  
fit3
```

```
Call: glm(formula = nc ~ tipo + regiao + offset(log(matric1000)), family = poisson,  
          data = dados2)
```

Coefficients:

(Intercept)	tipoU	regiaoMW	regiaoNE	regiaoS
-1.59629	0.33415	0.09939	0.78081	0.74926
regiaoW				
0.27223				

Degrees of Freedom: 80 Total (i.e. Null); 75 Residual

Null Deviance: 491

Residual Deviance: 431.4 AIC: 661.3

## Exercício

- Ler a sub seção 7.1.5 do livro texto: Modelo de Análise de Variância.

- Legler, J, and Roback,P. (2019). Bookdown: *Broadening Your Statistical Horizons (BYSH): Generalized Linear Models and Multilevel Models*.
- Paula, G.A. (2013). Modelos de Regressão com Apoio Computacional.
- Agresti, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley series in probability and statistics.
- Faraway, J. J. (2006). *Extending the Linear Model with R. Generalized Linear, Mixed Effects and Nonparametric Regression Models*. Chapman and Hall/CRC.