

# Mais sobre testes de comparação múltipla / Seleção e comparação de modelos

Notas de aula do Prof. Caio Azevedo modificadas pela Profa.  
Larissa Avila Matos

- Já vimos como realizar comparações de interesse (em termos de igualdade de médias, existência de interação etc), através dos testes para a comparações  $H_0 : \mathbf{C}\boldsymbol{\beta} = \mathbf{0}$ .
- Como também já visto, o teste para testar a hipótese acima, pode ser facilmente adaptado para testar as hipóteses

$$H_0 : \mathbf{C}_{(r \times p)} \boldsymbol{\beta}_{(p \times 1)} = \mathbf{M}_{(r \times 1)} \text{ vs } H_1 : \mathbf{C}_{(r \times p)} \boldsymbol{\beta}_{(p \times 1)} \neq \mathbf{M}_{(r \times 1)}.$$

- Vimos que, basta utilizar a seguinte estatística

$$Q = \frac{1}{r\hat{\sigma}^2} \left( \mathbf{C}\hat{\boldsymbol{\beta}} - \mathbf{M} \right)' \left( \mathbf{C} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{C}' \right)^{-1} \left( \mathbf{C}\hat{\boldsymbol{\beta}} - \mathbf{M} \right)$$

e proceder da mesma forma anterior ( $\mathbf{M} = \mathbf{0}$ ).

- Entretanto, existem outros testes que servem para realizar comparações específicas (não tão gerais quanto as comparações de tipo  $C\beta = M$ ).
- Veremos alguns desses testes.
- Uma preocupação (dado que podem existir muitas comparações de interesse) é controlar o nível de significância geral (considerando-se todos os testes).

- No caso de comparações do tipo  $C\beta$  é aconselhável usar, em cada teste, um  $\alpha^* = \alpha/m$ , em que  $\alpha$  é o nível de significância usado para os testes da tabela ANOVA e  $m$  é o número total de comparações de interesse.
- O processo acima é chamado de **controle de Bonferroni**.
- Os testes que veremos controlam, cada um à sua maneira, o nível de significância global.

- Vamos nos concentrar no PCA com um único fator (embora os desenvolvimentos possam ser estendidos para outros planejamentos).
- Primeiramente, lembremos o conceito de contraste.
- Um vetor  $\mathbf{C}_{(1 \times p)} = [c_1 \ c_2 \ \dots \ c_p]$  é dito ser um contraste se  $\sum_{i=1}^k n_i c_i = 0$ . No caso de experimentos balanceados, basta que  $\sum_{i=1}^k c_i = 0$ .
- Uma matriz  $\mathbf{C}_{(q \times p)}$  é dita ser uma matriz de contrastes se suas linhas forem contrastes.

- Lembrando: temos  $\mu_1, \mu_2, \dots, \mu_k$  médias e supomos que o teste F relativo à ANOVA rejeitou a igualdade simultânea das médias.
- Nosso interesse então é testar hipóteses do tipo

$$H_0 : \mathbf{C}_{(1 \times k)} \boldsymbol{\mu}_{(k \times 1)} = 0 \text{ vs } H_1 : \mathbf{C}_{(1 \times k)} \boldsymbol{\mu}_{(k \times 1)} \neq 0$$

em que  $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_k)$ .

- Defina, para um dado  $\mathbf{C}$ , o parâmetro  $\gamma = \mathbf{C}\boldsymbol{\mu} = \sum_{i=1}^k c_i \mu_i$ .
- Um estimador natural para  $\gamma$  é  $\hat{\gamma} = \sum_{i=1}^k c_i \bar{Y}_i$ , em que  $\bar{Y}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij}$  (estimador de mínimos quadrados do modelo completo).

- Portanto, tem-se que  $\mathcal{V}(\hat{\gamma}) = \sigma^2 \sum_{i=1}^k \frac{c_i^2}{n_i}$ .
- Se o experimento for balanceado, temos que  $\mathcal{V}(\hat{\gamma}) = \frac{\sigma^2}{n} \sum_{i=1}^k c_i^2$ , onde  $n$  é o número de unidades experimentais em cada tratamento.
- Um estimador para variância de  $\hat{\gamma}$  é dado por  $\widehat{\mathcal{V}}(\hat{\gamma}) = \hat{\sigma}^2 \sum_{i=1}^k \frac{c_i^2}{n_i}$
- Dessa forma, temos que  $\frac{\hat{\gamma} - \gamma}{\sqrt{\widehat{\mathcal{V}}(\hat{\gamma})}} \sim t_{(n-k)}$ , e temos uma estatística do teste definida.
- Sob  $H_0$  temos,

$$t_0 = \frac{\sum_{i=1}^k c_i \bar{Y}_i}{\sqrt{\hat{\sigma}^2 \sum_{i=1}^k \frac{c_i^2}{n_i}}} \sim t_{(n-k)},$$

onde  $p - \text{valor} = P(|t_{n-k}| > t_0)$ .

- Assim, um intervalo de confiança para o contraste é dado por

$$IC[\gamma; 1 - \alpha] = \left[ \hat{\gamma} - t_{(\alpha/2, n-k)} \sqrt{\hat{\mathcal{V}}(\hat{\gamma})}; \hat{\gamma} + t_{(\alpha/2, n-k)} \sqrt{\hat{\mathcal{V}}(\hat{\gamma})} \right].$$

- Portanto, podemos construir intervalos de confiança para contrastes de interesse e utilizá-los para avaliar a veracidade das hipóteses em questão.
- Ou seja, a relação do IC com o teste de hipótese é dada por: Se o IC contém zero, então não temos evidência para rejeitar  $H_0$ .



- Podemos testar contraste também utilizando a estatística F.
- Tomando-se o quadrado da estatística  $t_0$  anterior, temos a estatística  $F_0$  (sob  $H_0$ ),

$$F_0 = t_0^2 = \frac{(\sum_{i=1}^k c_i \bar{Y}_i)^2}{\hat{\sigma}^2 \sum_{i=1}^k \frac{c_i^2}{n_i}} \sim F_{(1, n-k)},$$

onde  $p\text{-valor} = P(F_{(1, n-k)} > F_0)$ .

- Então, rejeitamos  $H_0$  se  $p\text{-valor} < \alpha$  ou, de forma equivalente, se  $F_0 > F_{(1, n-k)}$ .

# Contrastes Ortogonais

- Seja  $D = (d_1, d_2, \dots, d_k)$  um outro contraste.
- Dizemos que  $C$  e  $D$  são contrastes ortogonais se

$$\sum_{i=1}^k n_i c_i d_i = 0.$$

No caso de um experimento balanceado, basta que  $\sum_{i=1}^k c_i d_i = 0$ .

- Em geral, para um conjunto de  $k$  tratamentos, podemos definir diversos contrastes (ortogonais) entre si, que representem hipóteses de interesse.
- Quando temos  $k$  tratamentos, sempre existe um conjunto de  $k - 1$  contrastes ortogonais que particiona  $SQF$  em componentes com 1 *gl*.

# Método de Scheffé para comparação de contrastes

- Considere um conjunto de  $m$  contrastes de interesse dados por

$$\gamma_u = c_{1u}\mu_1 + c_{2u}\mu_2 + \dots + c_{ku}\mu_k, \quad u = 1, \dots, m.$$

- Os respectivos estimadores são dados por:

$$\hat{\gamma}_u = \delta_u = c_{1u}\bar{Y}_1 + c_{2u}\bar{Y}_2 + \dots + c_{ku}\bar{Y}_k, \quad u = 1, \dots, m.$$

- O erro-padrão associado ao  $u$ -ésimo estimador, é dado por

$$S_{\delta_u} = \sqrt{\hat{\sigma}^2 \sum_{i=1}^k \frac{c_{iu}^2}{n_i}},$$

onde  $\hat{\sigma}^2 = QMR = \frac{SQR}{n-k}$ .

- Scheffé estabeleceu um valor crítico para o teste, da seguinte forma:

$$\text{Rejeita-se } H_0 \text{ se } |\delta_u| > S_{\alpha,u} = S_{\delta_u} \sqrt{(k-1)F_{\alpha,k-1,n-k}},$$

em que  $\alpha$  é o nível de significância apropriado e

$$P(F > F_{\alpha,k-1,n-k}) = \alpha, \quad F \sim F_{(k-1,n-k)}.$$

- Scheffé provou que a probabilidade do erro do tipo I para cada um dos testes não ultrapassa  $\alpha$ .

## Exemplo 2

- Quanto maior a absorbância, melhor o solvente.
- Unidade experimental: 10 gramas de polpa do fruto de baguaçu.
- Casualização: a partir de 1 kg de polpa, foram sendo retiradas amostras de 10 gramas, onde foram aplicados os tratamentos, numa ordem aleatória.
- Experimento balanceado : mesmo número de observações (unidades experimentais) por nível do fator.
- Lembrando: tratamentos 1,2,3,4 e 5, representam respectivamente os tipos de solvente E50, E70, EAW, M1M, MAW.

- Hipóteses de interesse:

$$H_0 : 2\mu_1 + 2\mu_2 + 2\mu_3 = 3\mu_4 + 3\mu_5$$

$$H_0 : \mu_1 + \mu_3 = 2\mu_2$$

$$H_0 : \mu_1 = \mu_3$$

$$H_0 : \mu_4 = \mu_5$$

- Implicam nos seguintes contrastes

$$\mathbf{C}_1 = \begin{bmatrix} 2 & 2 & 2 & -3 & -3 \end{bmatrix}$$

$$\mathbf{C}_2 = \begin{bmatrix} 1 & -2 & 1 & 0 & 0 \end{bmatrix}$$

$$\mathbf{C}_3 = \begin{bmatrix} 1 & 0 & -1 & 0 & 0 \end{bmatrix}$$

$$\mathbf{C}_4 = \begin{bmatrix} 0 & 0 & 0 & 1 & -1 \end{bmatrix}$$

- As estimativas dos constrastes 1 e 2 são dadas por:

$$\delta_1 = 1,488 \text{ e } \delta_2 = -0,109,$$

e os respectivos erros-padrão, são dados por

$$S_{\delta_1} = 0,061 \text{ e } S_{\delta_2} = 0,028.$$

- Assim, dado que para  $\alpha = 0,05$ , temos que  $F_{(0,05,4,20)} = 2,866$ , os valores críticos para cada teste, são dados por:

$$S_{0,05,1} = 0,209 \text{ e } S_{0,05,2} = 0,094.$$

- Portanto,  $|\delta_1| > 0,209$  e  $|\delta_2| > 0,094$ . Assim, rejeita-se ambas as hipóteses.

- As estimativas dos contrastes 3 e 4 são dadas por:

$$\delta_3 = -0,027 \text{ e } \delta_4 = -0,253,$$

e os respectivos erros-padrão, são dados por

$$S_{\delta_3} = 0,016 \text{ e } S_{\delta_4} = 0,016.$$

- Assim, dado que para  $\alpha = 0,05$ , temos que  $F_{(0,05,4,20)} = 2,866$ , os valores críticos para cada teste, são dados por:

$$S_{0,05,3} = 0,054 \text{ e } S_{0,05,4} = 0,054.$$

- Portanto,  $|\delta_3| < 0,054$  e  $|\delta_4| > 0,054$ . Assim, rejeita-se a hipótese para o contraste  $C_4$  e não rejeita-se a hipótese para o contraste  $C_3$ .



# Comandos no R

```
> library(DescTools)
> C1 <- cbind(2,2,2,-3,-3); C2 <- cbind(1,-2,1,0,0)
> C3 <- cbind(1,0,-1,0,0); C4 <- cbind(0,0,0,1,-1)
> ScheffeTest(aov(mabsor~solvfac), contrasts=t(rbind(C1,C2,C3,C4)))
```

Posthoc multiple comparisons of means :

Scheffe Test 95% family-wise confidence level

```
$solvfac
```

	diff	lwr.ci	upr.ci	pval	
E50,E70,EAW-M1M,MAW	1.48896	1.27982134	1.69809866	1.8e-14	***
E50,EAW-E70	-0.10956	-0.20308965	-0.01603035	0.0163	*
E50-EAW	-0.02752	-0.08151937	0.02647937	0.5731	
M1M-MAW	-0.25288	-0.30687937	-0.19888063	4.8e-11	***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

# Utilizando o R

- O teste de Scheffé também permite comparar médias par a par, dado que todas essas comparações estão relacionadas à contrastes.
- O procedimento é similar ao anterior.
- Existe uma pacote no R chamado *agricolae* que permite fazer comparações desse tipo, usando o método de Scheffé e outros que veremos.
- Vamos utilizá-lo em nosso exemplo.

## Resultado da aplicação do teste de Scheffe

	Tratamento	Média	Grupo	n	erro-padrão
1	E70	0,61	a	5	0,01
2	EAW	0,57	ab	5	0,01
3	E50	0,54	b	5	0,01
4	MAW	0,45	c	5	0,02
5	M1M	0,20	d	5	0,01

# Comandos no R

```
> library("agricolae")  
> rsch<-scheffe.test(ranova,"solvfac",group=TRUE)  
> rsch$groups
```

	trt	means	M
1	E70	0.60788	a
2	EAW	0.56686	ab
3	E50	0.53934	b
4	MAW	0.44964	c
5	M1M	0.19676	d

# Testes específicos para comparação de pares de médias

- Apesar do teste de Scheffé também permitir comparação de médias duas a duas, ele tende a ser muito conservativo (rejeita igualdades entre as médias menos do que deveria).
- Veremos outros testes: Tukey, LSD de Fisher, Duncan e Dunnet.
- As hipóteses são

$$H_0 : \mu_i = \mu_j \text{ vs } H_1 : \mu_i \neq \mu_j, \forall i, j.$$

# Teste de Tukey

- O teste de Tukey faz uso de percentis da distribuição da seguinte estatística

$$Q = \frac{\max\{T_i\} - \min\{T_i\}}{\sqrt{QMR/n}} = \frac{\bar{Y}_{max} - \bar{Y}_{min}}{\sqrt{QMR/n}} \quad (1)$$

em que  $T_i = \bar{Y}_i - (\mu + \alpha_i)$ ,  $n$  é o tamanho amostral para cada tratamento. Se o experimento for desbalanceado, pode-se usar uma média aritmética dos tamanhos amostrais. Além disso,  $\bar{Y}_{max}$  é a maior média amostral e  $\bar{Y}_{min}$  é a menor média amostral.

- O nível de significância global (considerando todos os testes) é exatamente igual à  $\alpha$ .

- Rejeita-se  $H_0$ , para um dado  $\alpha$ , se

$$|\bar{Y}_i - \bar{Y}_j| > T_\alpha,$$

em que  $\bar{Y}_i$  é a média amostral do  $i$ -ésimo tratamento e

$$T_\alpha = w_T \sqrt{QMR \left( \frac{1}{n_i} + \frac{1}{n_j} \right)},$$

com

$$w_T = \frac{q_\alpha(k, f)}{\sqrt{2}},$$

$f$  o número de graus de liberdade do resíduo e  $q_\alpha(k, f)$  o quantil de ordem  $\alpha$  da distribuição da estatística (1).

- **Obs.:** Os valores de  $q_\alpha(k, f)$  são tabelados.

- Assim, um conjunto de intervalos de confiança simultâneos de  $100(1 - \alpha)\%$  para todas as diferenças de pares  $\mu_i - \mu_j$ ,  $i \neq j$ , é dado por

$$IC[\mu_i - \mu_j; 1 - \alpha] = \left[ (\bar{Y}_i - \bar{Y}_j) - w_T \sqrt{QMR \left( \frac{1}{n_i} + \frac{1}{n_j} \right)}; \right. \\ \left. (\bar{Y}_i - \bar{Y}_j) + w_T \sqrt{QMR \left( \frac{1}{n_i} + \frac{1}{n_j} \right)} \right].$$



## Resultado da aplicação do teste de Tukey


	Tratamento	Média	Grupo	n	erro-padrão
1	E70	0,61	a	5	0,01
2	EAW	0,57	ab	5	0,01
3	E50	0,54	b	5	0,01
4	MAW	0,45	c	5	0,02
5	M1M	0,20	d	5	0,01

# Comandos no R

```
> rtuk1
Tukey multiple comparisons of means 95% family-wise confidence level
Fit: aov(formula = mabsor ~ solvfac1)
$solvfac1
```

	diff	lwr	upr	p adj
2-1	0.06854	0.02081671	0.116263292	0.0028819
3-1	0.02752	-0.02020329	0.075243292	0.4416646
4-1	-0.34258	-0.39030329	-0.294856708	0.0000000
5-1	-0.08970	-0.13742329	-0.041976708	0.0001465
3-2	-0.04102	-0.08874329	0.006703292	0.1141101
4-2	-0.41112	-0.45884329	-0.363396708	0.0000000
5-2	-0.15824	-0.20596329	-0.110516708	0.0000000
4-3	-0.37010	-0.41782329	-0.322376708	0.0000000
5-3	-0.11722	-0.16494329	-0.069496708	0.0000038
5-4	0.25288	0.20515671	0.300603292	0.0000000

```
> plot(rtuk1)
```



# Comparação entre Bonferroni, Scheffé e Tukey

- Suponha que  $k = 5$ ,  $n = 35$  e  $\alpha = 0.05$ , e que apenas as 10 comparações entre os pares de médias ( $\mu_i - \mu_j$ ,  $i \neq j$ ) são de interesse para o pesquisador e estas foram especificamente selecionadas antes da pesquisa (ou seja, foram pré-planejadas). Se compararmos os coeficientes críticos para os três métodos, obtemos

Bonferroni:	$w_B = t_{30;0,025/10} = 3,02;$
Scheffé:	$w_S = \sqrt{4 F_{4;30;0.05}} = 3,28;$
Tukey:	$w_T = \frac{1}{\sqrt{2}} q_{5;30;0.05} = 2,91.$

- Uma vez que  $w_T$  é inferior a  $w_B$ , que é menor do que  $w_S$  para este exemplo, os intervalos de Tukey serão mais curtos que os intervalos de Bonferroni, que serão mais curtos que os intervalos de Scheffé.

# Teste LSD de Fisher

- O teste LSD (“Least significance difference”) de Fisher, baseia-se na seguinte estatística

$$T = \frac{\bar{Y}_i - \bar{Y}_j}{\sqrt{QMR \left( \frac{1}{n_i} + \frac{1}{n_j} \right)}}$$

- Rejeita-se  $H_0$  se

$$|\bar{Y}_i - \bar{Y}_j| > LSD,$$

em que  $LSD = t_{(\alpha/2, n-k)} \sqrt{QMR \left( \frac{1}{n_i} + \frac{1}{n_j} \right)}$  e temos que  $P(T > t_{(\alpha/2, n-k)}) = \alpha/2, T \sim t_{(n-k)}$ .

- Se o teste F da ANOVA é significativo a um nível  $\alpha$ , cada par de média é então testado por um teste t de nível  $\alpha$ .
- **Desvantagem:** controla apenas o nível  $\alpha$  de cada teste, mas não controla o nível de significância geral.
- **Regra de decisão:** duas médias  $\mu_i$  e  $\mu_j$  são significativamente diferentes se  $|\bar{Y}_i - \bar{Y}_j| > LSD$ .

## Resultado da aplicação do teste LSD

	Tratamento	média	grupo	n	erro-padrão	LIIC	LSIC
1	E70	0,61	a	5	0,01	0,59	0,62
2	EAW	0,57	b	5	0,01	0,55	0,58
3	E50	0,54	b	5	0,01	0,51	0,56
4	MAW	0,45	c	5	0,02	0,41	0,48
5	M1M	0,20	d	5	0,01	0,17	0,22

# Teste de Duncan

- No teste de Duncan as médias amostrais são dispostas de modo crescente e para cada uma delas é calculado o erro-padrão:

$$S_{\bar{Y}_i} = \sqrt{QMR/n_h}, n_h = \frac{k}{\sum_{i=1}^k n_i^{-1}}.$$

- Obtem-se quantis tabelados por Duncan, denotados por  $r_\alpha(p, f)$ ,  $p = 2, 3, \dots, k$ ,  $\alpha$  é o nível de significância e  $f$  são os graus de liberdade do resíduo.
- Calcula-se  $R_p = r_\alpha(p, f)S_{\bar{Y}_i}$ ,  $p = 2, 3, \dots, k$ .
- Compara-se, então a maior média com a menor (tal diferença é comparada com  $R_k$ ).



- Depois, compara-se a maior média com a segunda menor (tal diferença é comparada com  $R_{k-1}$ ).
- Continua-se o processo acima até que todas as médias tenham sido comparadas com a maior.
- Depois, compara-se a segunda maior com a menor (tal diferença é comparada com  $R_{k-1}$ ).
- Repete-se o processo até que todas as  $\frac{k(k-1)}{2}$  diferenças tenham sido consideradas.

- Se a diferença observada for maior que  $R$ , rejeita-se  $H_0$ .
- Para evitar-se contradições, duas médias não serão consideradas diferentes, se elas estiverem entre duas outras médias que não foram consideradas diferentes.

## Resultado da aplicação do teste de Duncan

	Tratamento	Média	Grupo	n	erro-padrão
1	E70	0,61	a	5	0,01
2	EAW	0,57	b	5	0,01
3	E50	0,54	b	5	0,01
4	MAW	0,45	c	5	0,02
5	M1M	0,20	d	5	0,01

# Teste de Dunnett (comparação com um tratamento controle)

- Seja  $\mu_r, r \in \{1, 2, \dots, k\}$  a média correspondente ao tratamento controle.
- As hipóteses de interesse são:

$$H_0 : \mu_i = \mu_r \text{ vs } \mu_i \neq \mu_r, \forall i \neq r.$$

- Rejeita-se  $H_0$  se

$$|\bar{Y}_i - \bar{Y}_j| > d_\alpha(k-1, f) \sqrt{QMR \left( \frac{1}{n_i} + \frac{1}{n_r} \right)},$$

em que a constante  $d_\alpha(k-1, f)$  corresponde à valores tabelados por Dunnett, para um dado nível de significância  $\alpha$  e graus de liberdade para o resíduo  $f$ .

## Resultado da aplicação do teste de Dunnett

Hipótese	Estimativa	Erro-padrão	Estatística	pvalor
E70 - E50 = 0	0,07	0,02	4,30	0,001
EAW - E50 = 0	0,03	0,02	1,73	0,279
M1M - E50 = 0	-0,34	0,02	-21,48	< 0,001
MAW - E50 = 0	-0,09	0,02	-5,62	< 0,001

- Neste caso, pode-se usar o pacote **multcomp**.

```
> rdunn<- glht(ranova, linfct=mcp(solvfac="Dunnett"))
> summary(rdunn)
Simultaneous Tests for General Linear Hypotheses
Multiple Comparisons of Means: Dunnett Contrasts
Fit: aov(formula = mabsor ~ solvfac)
Linear Hypotheses:

```

	Estimate	Std. Error	t value	Pr(> t )	
E70 - E50 == 0	0.06854	0.01595	4.298	0.00119	**
EAW - E50 == 0	0.02752	0.01595	1.726	0.27881	
MIM - E50 == 0	-0.34258	0.01595	-21.481	< 0.001	***
MAW - E50 == 0	-0.08970	0.01595	-5.624	< 0.001	***

```
-----
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Adjusted p values reported -- single-step method)
```

# Seleção e comparação de modelos

# Comparação dos modelos

- Vimos como verificar se um determinado modelo (normal-linear-homocedástico) se ajusta adequadamente aos dados.
- Uma outra questão de interesse surge quando se dispõe de diversos modelos (que se ajustam adequadamente aos dados) e respondem às perguntas de interesse, e queremos escolher um como o “mais apropriado”.
- Há diversas técnicas disponíveis para este fim.
- Veremos técnicas baseadas em testes de hipótese e comparação de estatísticas de ajuste.



# Teste da razão de verossimilhanças

- Sejam  $M_1$  e  $M_2$  dois modelos, em que  $M_1$  está encaixado em  $M_2$ , ou seja, o modelo  $M_1$  é um caso particular de  $M_2$ .
- Por exemplo,  $M_1$  é um modelo linear e  $M_2$  é um modelo quadrático.
- Neste caso temos que  
 **$H_0$  : o modelo  $M_1$  é preferível ao modelo  $M_2$ .**
- Denote por  $L_i(\tilde{\theta})$  e  $l_i(\tilde{\theta})$  o máximo da verossimilhança e da log-verossimilhança do modelo  $i$ , respectivamente.
- $\tilde{\theta}$  corresponde à estimativa de máxima verossimilhança obtida sob o modelo  $i$ .

- A estatística do TRV é dada por  $\Delta = \frac{L_1(\hat{\theta})}{L_2(\hat{\theta})}$ .
- Rejeita-se  $H_0$  se  $\Delta < \delta_c$ , em que  $\delta_c$  é um valor critico adequado.
- Alternativamente, rejeitamos  $H_0$  se

$$\Lambda = -2\ln(\Delta) = -2 \left( l_1(\hat{\theta}) - l_2(\hat{\theta}) \right) > \lambda_c,$$

em que  $P(Q > \lambda_c) = \alpha$ ,  $Q \sim \chi^2_{(\gamma)}$  e  $\gamma$  = número de parâmetros do modelo  $M_2$  - número de parâmetros do modelo  $M_2$ .

- $p$ -valor =  $P(Q > \lambda)$ , em que  $\lambda$  é o valor observado da estatística  $\Lambda$ .

# Estatísticas de comparação de modelos

- O TRV é apropriado na comparação de modelos encaixados.
- Além disso, ele não leva em consideração (diretamente) o número de parâmetros do modelo (somente na distribuição da estatística).
- Existem várias alternativas, em termos de estatística para comparar modelos, que “penalizam” a verossimilhança em relação ao número de parâmetros, tamanho da amostra entre outros fatores.
- Veremos o AIC e o BIC.

- O AIC e BIC são dados, respectivamente, por:

$$\begin{aligned}AIC &= -2l_i(\tilde{\theta}) + 2k, \\BIC &= -2l_i(\tilde{\theta}) + 2k \ln(n),\end{aligned}$$


que  $l_i(\tilde{\theta})$  denota a log-verossimilhança do  $i$ -ésimo modelo avaliada em alguma estimativa,  $k$  é o número de parâmetros e  $n$  é o número de observações.

- Portanto, o modelo que apresentar os menores valores, será o modelo “melhor ajustado” aos dados.

# Exemplo Censo

- O conjunto de dados em questão foi extraído do censo do IBGE de 2000 e apresenta para cada unidade da federação o número médio de anos de estudo e a renda média mensal (em reais) do chefe ou chefes do domicílio.
- Um dos objetivos é estudar o relacionamento da renda média mensal em função do número médio de anos de estudo.

# Dispersão entre anos de escolaridade e renda







■ Modelo 1:  $Y_j = \beta_0 + \beta_1 x_j + \xi_j$

■ Modelo 2:  $Y_j = \beta_0 + \beta_1 x_j + \beta_2 x_j^2 + \xi_j$

em que





$$\xi_j \stackrel{ind.}{\sim} N(0, \sigma^2)$$

# Modelo 1





# Modelo 2



■ Modelo 1

Parâmetro	Estimativa	EP	Estat. t	p-valor
$\beta_0$	-381,28	69,40	-5,49	<0,0001
$\beta_1$	199,83	13,03	15,34	<0,0001

■ Modelo 2

Parâmetro	Estimativa	EP	Estat. t	p-valor
$\beta_0$	546,98	196,80	2,78	0,0104
$\beta_1$	-152,62	72,86	-2,09	0,0469
$\beta_2$	31,92	6,54	4,88	0,0001

■ Estatísticas de comparação dos modelos

Estatística	Modelo 1	Modelo 2
AIC	315,26	298,66
BIC	319,15	303,85
log-verossim.	-154,63	-145,33

■ TRV, estatísticas e pvalor entre parênteses: 18,80 ( $< 0,0001$ ).

# Modelos ajustados

