

# ME951 - Estatística e Probabilidade I

## Parte 14

Notas de aula de ME414 produzidas pelos professores **Samara Kiihl**, **Tatiana Benaglia** e **Benilton Carvalho** modificadas e alteradas pela Profa. **Larissa Avila Matos**

# Fundamentos de Inferência

# Introdução


Um dos principais objetivos da Estatística é tirar conclusões a partir dos dados.

Dados em geral consistem de uma amostra de elementos de uma população de interesse.

O objetivo é usar a amostra e tirar conclusões sobre a população.

Quão confiável será utilizar a informação obtida apenas de uma amostra para concluir algo sobre a população?

# Inferência Estatística




**Variável Aleatória:** Característica numérica do resultado de um experimento.

**População:** todos os elementos ou resultados de um problema que está sendo estudado.

**Amostra:** qualquer subconjunto da população que contém os elementos que podem ser observados e é onde as quantidades de interesse podem ser medidas.

# Inferência Estatística



**Parâmetros:** Característica numérica (desconhecida) da distribuição dos elementos da população.

**Estimador/Estatística:** Função da amostra, construída com a finalidade de representar, ou estimar um parâmetro de interesse na população.

**Estimativa:** Valor numérico que um estimador assume para uma dada amostra.

Seja  $X_1, \dots, X_n$  uma amostra,  $T = f(X_1, \dots, X_n)$  é uma estatística.

- $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n}(X_1 + \dots + X_n)$ : a média amostral é uma estatística.
- $X_{(1)} = \min\{X_1, \dots, X_n\}$ .
- $X_{(n)} = \max\{X_1, \dots, X_n\}$ .
- $X_{(i)}$  é o  $i$ -ésimo valor da amostra ordenada.

Note que uma estatística é uma função que em uma determinada amostra assume um valor específico (estimativa).

Para que serve uma estatística? Para “estimar” os valores de uma distribuição, ou características de uma população.

## ■ População:

- média<sub>P</sub>.
- variância<sub>P</sub>.


## ■ Amostra:

- média<sub>A</sub> =  $\sum_{i=1}^n \frac{X_i}{n}$  “estima” a média<sub>P</sub>.
- variância<sub>A</sub> =  $\sum_{i=1}^n \frac{(X_i - \text{média}_A)^2}{n}$  “estima” a variância<sub>P</sub>

# Exemplo

Temos interesse em conhecer a média e variância das alturas dos brasileiros adultos. Sabemos que a distribuição das alturas pode ser representada por um modelo normal.

- Solução 1: Medir a altura de todos os brasileiros adultos.
- Solução 2: Selecionar de forma aleatória algumas pessoas (amostra), analisá-las e inferir propriedades para toda a população.





## Exemplo

Seja  $\theta$  a proporção de alunos na Unicamp que concorda com a presença da PM no campus.

Inviável perguntar para todos os estudantes: coleta-se uma amostra.

Planejamento amostral: obter uma amostra aleatória simples de tamanho  $n = 100$  alunos, sem reposição.

Cada  $X_i$ ,  $i = 1, \dots, 100$ , vai assumir o valor 1 se o aluno  $i$  concorda com presença da PM, e 0 se não.

Estatística:  $T = \frac{X_1 + \dots + X_{100}}{100}$ .

Uma vez que a coleta foi implementada,  $T$  assume um valor, por exemplo, 0.63, que será usado para estimar  $\theta$ , ou seja,  $\hat{\theta} = 0.63$ .

# Parâmetro

Cada quantidade de interesse (como  $\theta$  no exemplo anterior) é chamada de parâmetro da população.

Para apresentar uma estimativa de um parâmetro ( $\hat{\theta}$ ), devemos escolher uma estatística ( $T$ ).

Note que da maneira que o plano amostral foi executado (amostra aleatória simples), a estatística  $T$  é uma variável aleatória, visto que cada vez que executarmos o plano amostral poderemos obter resultados diversos.

Portanto, a estatística  $T$  possui uma distribuição de probabilidade, chamada de **distribuição amostral** de  $T$ .

## Distribuição Amostral

## Exemplo

Imagine um fenômeno de interesse que possa ser representado por uma v.a.  $X$  que assume os valores 1 ou 2 com igual probabilidade.

$$\begin{aligned}\mu = E(X) &= 1 \times P(X = 1) + 2 \times P(X = 2) \\ &= 1 \times \frac{1}{2} + 2 \times \frac{1}{2} = \frac{3}{2}\end{aligned}$$

$$\begin{aligned}\sigma^2 = Var(X) &= E[(X - \mu)^2] \\ &= (1 - 1.5)^2 \times P(X = 1) + (2 - 1.5)^2 \times P(X = 2) \\ &= \frac{1}{4}\end{aligned}$$

## Exemplo

Imagine que uma população de interesse tenha distribuição como a de  $X$  definida anteriormente.

Imagine também que, embora saibamos que os valores possíveis sejam 1 e 2, não tenhamos conhecimento sobre suas respectivas probabilidades.

Isto é, se temos  $N$  elementos nessa população, podemos pensar que a característica de interesse de cada elemento  $i$  segue uma v.a.  $X_i$  em que  $P(X_i = 1) = P(X_i = 2) = 1/2$ , mas nós não sabemos disso.

Imagine que o interesse seja  $\mu$ .

# Exemplo

Vamos coletar uma amostra aleatória simples com reposição ( $AAS_c$ ) de tamanho  $n = 2$  e calcular a média amostral.

Usaremos esta média amostral para estimar  $\mu$ .

Quão útil é esta estimativa que se baseia em apenas 2 elementos da população?

Quão precisa?

# Exemplo

Imagine que o aluno  $A$  coleta uma  $AAS_c$  com  $n = 2$  a partir da população, obtém os dados e calcula  $\bar{x}$ .

O aluno  $B$  coleta uma  $AAS_c$  com  $n = 2$  a partir da população, obtém os dados e calcula  $\bar{x}$ .

As duas médias amostrais serão necessariamente iguais?

A média amostral é uma v.a. e, portanto, tem uma distribuição de probabilidade.

## Exemplo

Todas as combinações possíveis de valores para o primeiro e para o segundo elemento amostrados segundo o plano  $AAS_c$  com  $n = 2$  são:

Possibilidades	$(X_1 = 1, X_2 = 1)$	$(X_1 = 1, X_2 = 2)$
$\bar{x}$	1	1.5
$P(X_1 = i, X_2 = j)$	0.25	0.25

Possibilidades	$(X_1 = 2, X_2 = 1)$	$(X_1 = 2, X_2 = 2)$
$\bar{x}$	1.5	2
$P(X_1 = i, X_2 = j)$	0.25	0.25



$$E(\bar{X}) = 1 \times \frac{1}{4} + 1.5 \times \frac{1}{2} + 2 \times \frac{1}{4} = \frac{3}{2}$$

$$\begin{aligned} Var(\bar{X}) &= E[(\bar{X} - E(\bar{X}))^2] \\ &= (1 - 1.5)^2 \times \frac{1}{4} + (1.5 - 1.5)^2 \frac{1}{2} + (2 - 1.5)^2 \frac{1}{4} = \frac{1}{8} \end{aligned}$$

Repare que:


$$E(\bar{X}) = \mu = E(X)$$

e

$$Var(\bar{X}) = \frac{\sigma^2}{n} = \frac{Var(X)}{n}.$$

# Exemplo

Distribuição de probabilidade de  $X$  (esquerda) e de  $\bar{X}$  (direita):



# Distribuição Amostral

## Resultado:

Seja  $X$  uma v.a. com média  $\mu$  e variância  $\sigma^2$ .

Seja  $X_1, \dots, X_n$  uma amostra aleatória simples de  $X$ .

$$\bar{X}_n = \frac{X_1 + \dots + X_n}{n}.$$

$$E(\bar{X}_n) = \mu.$$

$$Var(\bar{X}_n) = \frac{\sigma^2}{n}.$$

Ou seja, embora  $\mu$  seja desconhecido, sabemos que o valor esperado da média amostral é  $\mu$ . Além disso, conforme o tamanho amostral aumenta, a imprecisão da média amostral para estimar  $\mu$  fica cada vez menor, pois  $Var(\bar{X}) = \sigma^2/n$ .

## Exemplo

**Exemplo:**  $X_1, X_2, X_3$  ensaios de Bernoulli( $p$ ) independentes.

$$\mu = E(X_i) = 0.3 \Rightarrow E(\bar{X}_3) = 0.3.$$

$$\sigma^2 = Var(X_i) = p(1-p) = 0.3(0.7) = 0.21 \Rightarrow Var(\bar{X}_3) = \frac{0.21}{3} = 0.07$$

## Teorema do Limite Central

# Teorema do Limite Central

Usando o resultado enunciado anteriormente, temos a esperança e a variância da média amostral  $\bar{X}$ :  $E(\bar{X}) = \mu$  e  $Var(\bar{X}) = \frac{\sigma^2}{n}$ .

No entanto, para conhecermos a distribuição de probabilidade de  $\bar{X}$ , como foi feito no exemplo anterior, é preciso conhecer todos os valores possíveis de  $X$  e suas respectivas probabilidades.

Mas, se conhecermos tudo isso, não precisamos fazer amostragem nem inferência: saberemos tudo o que desejarmos daquela população!

O exemplo anterior foi um caso hipotético apenas para demonstrar como a média amostral  $\bar{X}$  se comporta quando realizamos a amostragem.

Na prática, não teremos informações suficientes para de fato descrevermos a distribuição exata de  $\bar{X}$ .

# Teorema Central do Limite (TLC)


## Resultado

Para uma amostra aleatória simples  $X_1, \dots, X_n$  coletada de uma população com média  $\mu$  e variância  $\sigma^2$ , a distribuição amostral de  $\bar{X}_n$  aproxima-se de uma **distribuição Normal** de média  $\mu$  e variância  $\frac{\sigma^2}{n}$ , quando  $n$  for suficientemente grande.

Definimos também:

$$Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

# Teorema do Limite Central





## Exemplo

Seja  $X_1, \dots, X_n$  uma amostra aleatória de tamanho  $n$  tal que  $X \sim \text{Exp}(2)$ :

$$f_{X_i}(x) = 2e^{-2x}, \quad \text{para } x \geq 0$$

Então  $E(X_i) = \frac{1}{2}$  e  $\text{Var}(X_i) = \frac{1}{4}$ .

Suponha que  $X_i$  modela o tempo de vida de um transistor em horas. Os tempos de vida de 100 transistores são coletados. Desejamos estudar a variável aleatória  $\bar{X}_{100}$  (média amostral de uma amostra de tamanho 100). Sabemos:

$$E(\bar{X}_{100}) = \frac{1}{2} \quad \text{e} \quad \text{Var}(\bar{X}_{100}) = \frac{1/4}{100} = \frac{1}{400}.$$

Pelo TLC, temos que:  $\bar{X}_n \sim N\left(\frac{1}{2}, \frac{1}{400}\right)$

## Exemplo

$$\begin{aligned} F_{\bar{X}_{100}}(x) &= P(\bar{X}_{100} \leq x) = P\left(\frac{\bar{X}_{100} - (1/2)}{(1/2)/\sqrt{100}} \leq \frac{x - (1/2)}{(1/2)/\sqrt{100}}\right) \\ &= P(Z \leq 10(2x - 1)) \end{aligned}$$

e

$$\begin{aligned} P(\bar{X}_{100} \geq x) &= 1 - P(\bar{X}_{100} < x) \\ &= 1 - P\left(\frac{\bar{X}_{100} - (1/2)}{(1/2)/\sqrt{100}} \leq \frac{x - (1/2)}{(1/2)/\sqrt{100}}\right) \\ &= 1 - P(Z \leq 10(2x - 1)) \end{aligned}$$

# Exemplo

$X$  = resultado obtido no lançamento de um dado honesto.

$x$	1	2	3	4	5	6
$p(x) = P(X = x)$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$

$$E(X) = \frac{1}{6} \times (1 + 2 + 3 + 4 + 5 + 6) = \frac{21}{6} = 3.5$$

$$Var(X) = \frac{1}{6}[(1 + 4 + 9 + 16 + 25 + 36) - \frac{1}{6} \times (21)^2] = \frac{35}{2} = 17.5$$

$X_i$ : resultado do  $i$ -ésimo lançamento de um dado honesto.

$X_i$  tem distribuição uniforme discreta  $\forall i$ .

$$\mu = E(X_i) = 3.5 \quad \text{e} \quad \sigma^2 = Var(X_i) = 17.5, \forall i.$$

## Exemplo

Se temos uma amostra aleatória simples de tamanho  $n$ :


$X_1, X_2, \dots, X_n$ , pelo TLC sabemos que a distribuição amostral de  $\bar{X}_n$  é aproximadamente  $\text{Normal}\left(3.5, \frac{17.5}{n}\right)$ .

O primeiro histograma a seguir mostra o resultado de 10000 repetições do seguinte experimento: observar o resultado do lançamento de 1 dado. Repare que é muito próximo de uma distribuição uniforme discreta (chance  $1/6$  para cada resultado).


O segundo histograma mostra o resultado de 10000 repetições do seguinte experimento: observar a média do lançamento de 2 dados (equivalente a observar a média de 2 lançamentos de um dado).

# Exemplo


Média de 1 dado




Média de 2 dados




Média de 3 dados




Média de 10 dados



Média de 50 dados



Média de 100 dados



## Exemplo

O último histograma mostra o resultado de 10000 repetições do seguinte experimento: observar a média do lançamento de 100 dados (equivalente a observar a média de 100 lançamentos de um dado).

Repare que conforme o número de dados (tamanho amostral) aumenta, a distribuição da média amostral se aproxima da distribuição normal com média 3.5 e variância cada vez menor ( $17.5/n$ ).

# Teorema do Limite Central (TLC)

Você pode verificar o comportamento de  $\bar{X}$  para vários tipos de distribuição de  $X$ :

[https://nishantsbi.shinyapps.io/CLT\\_Shiny](https://nishantsbi.shinyapps.io/CLT_Shiny)

[https://gallery.shinyapps.io/CLT\\_mean/](https://gallery.shinyapps.io/CLT_mean/)

# Aproximação da Distribuição Binomial pela Normal



# Aproximação da Binomial pela Normal

Consideremos uma população em que a proporção de indivíduos portadores de uma certa característica seja  $p$ .

$$X_i = \begin{cases} 1, & \text{se o indivíduo } i \text{ possui a característica} \\ 0, & \text{caso contrário} \end{cases}$$

$$\Rightarrow X_i \sim \text{Bernoulli}(p); i = 1, 2, \dots, n.$$

Se as observações são independentes:

$$S_n = X_1 + \dots + X_n \sim \text{Bin}(n, p).$$

Após a coleta de uma amostra aleatória simples de  $n$  indivíduos, podemos considerar:

$$\hat{p} = \frac{S_n}{n} \text{ (média amostral como estimador da média populacional).}$$

# Aproximação da Binomial pela Normal

Utilizando a distribuição exata (n pequeno):

$$P\left(\hat{p} = \frac{k}{n}\right) = P\left(\frac{S_n}{n} = \frac{k}{n}\right) = P(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k},$$

para  $k = 0, 1, \dots, n$ .

Utilizando a aproximação para a Normal (n grande):

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

## Exemplo

Se  $p$  for a proporção de fumantes no estado de SP,  $p = 0.2$  e tivermos coletado uma amostra aleatória simples de 500 indivíduos:

$$X_i = \begin{cases} 1, & \text{se o indivíduo } i \text{ é fumante} \\ 0, & \text{caso contrário} \end{cases}$$

$$\hat{p} = \frac{\sum_{i=1}^{500} X_i}{500}.$$

$$\hat{p} \sim N\left(0.2, \frac{0.2 \times 0.8}{500}\right) = N(0.2, 0.00032)$$

$$P(\hat{p} \leq 0.25) = P(Z \leq 2.795) = \Phi(2.795) = 0.9974$$

# Aproximação da Binomial pela Normal

$$\hat{p} = \frac{S_n}{n} \Rightarrow S_n = n\hat{p}.$$

Quando  $n$  é grande o suficiente  $\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$ .

Qual a distribuição de  $S_n$  quando  $n$  é grande o suficiente?

$$S_n = X_1 + \dots + X_n$$

$$\hat{p} = \frac{S_n}{n} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

$$S_n = n\hat{p} \sim N(np, np(1-p))$$

Portanto:  $Bin(n, p) \approx N(np, np(1-p))$  quando  $n$  é grande.

## Exemplo

$$X \sim \text{Bin}(100, 0.4)$$

$$E(X) = 100 \times 0.4 = 40$$

$$\text{Var}(X) = 100 \times 0.4 \times 0.6 = 24$$

$$X \approx N(40, 24)$$

$$P(X \leq 50) = P\left(Z \leq \frac{50-40}{\sqrt{24}}\right) \approx \Phi\left(\frac{10}{\sqrt{24}}\right) = \Phi(2.04) \approx 0.9793$$

- [Ross](#): capítulo 7.
- [OpenIntro](#): seção 4.1
- Magalhães: capítulo 7.